

学校代码	10699
分 类 号	V11
密 级	公开
学 号	XXXX

题目

基于强化学习的无人机集群

对地目标自主决策方法研究

作者

XXX

专 业 领 域

XXXX

指 导 教 师

XX

培 养 单 位

XXXXXXX

申 请 日 期

2025 年 1 月

西北工业大学

硕士学位论文

题目：基于强化学习的无人机集群
对地目标自主决策方法研究

专业领域：XXXXXXXX

作者：XXXXXXXX

指导教师：XXXXXXXX

2025 年 1 月

Title: Research on Autonomous Decision-Making Methods for
UAV Swarms to Ground Targets Based on Reinforcement Learning

By
XXXX
Under the Supervision of Professor
XXXX

A Dissertation Submitted to
XXXXXXX

In Partial Fulfillment of The Requirement
For The Degree of
Master of XXXXXXX

Xi'an P. R. China
January 2025

学位论文评阅人和答辩委员会名单

学位论文评阅人名单

姓名

职称

工作单位

答辩委员会名单

答辩日期

年 月 日

答辯委員会

姓名

职称

工作单位

主席

委员

委员

委员

委员

委员

委员

秘书

摘要

无人机集群作为未来智能化作战的关键组成部分，在动态战场环境中执行复杂任务时，其自主决策能力直接影响任务完成度与战场态势掌控。面对动态目标变化与资源受限等挑战，研究高效的无人机集群对地目标自主决策方法具有重要意义。本文聚焦开放战场环境下无人机集群对地打击任务级决策问题，结合强化学习与智能优化算法，设计了目标划分、资源分配、打击次序规划及任务执行的流程解决方案，研究随机森林、粒子群优化及近端策略优化等算法在决策问题中的应用，提出了适应动态任务变化的无人机集群智能决策方法，提升了集群自主决策能力与任务执行效率。研究内容及相关成果研究梳理如下：

（1）针对战场目标动态变化场景下摧毁目标集决策与目标区域划分问题，基于随机森林算法和近端策略优化方法解决了任务目标集构建和子群聚类问题。量化了目标的空间分布、防御能力和重要程度，建立了包含敌方目标多维属性的态势模型。基于随机森林算法，研究了摧毁目标分类策略，实现对摧毁目标集的有效判定；基于粒子群优化和近端策略优化算法，研究摧毁目标集在任务均衡性和区域紧凑条件下的子群划分策略，实现了目标动态变化场景下的自主分群决策。

（2）针对目标态势变化以及无人机集群损失突发条件下的自主决策问题，提出了基于资源评估、打击次序决策与动态支援机制的解决方案。建立了资源评估指标体系，通过蒙特卡洛分析方法设定任务完成率阈值，确保资源合理分配和任务可行性。引入基于深度 Q 网络的打击次序决策算法，利用经验回放和注意力机制优化训练过程，提高决策效率与收益。考虑到集群内作战资源损失，利用启发式算法设计动态支援机制，实现高效资源协调和任务调整。

（3）为了验证自适应智能动态决策模型的自主决策能力，构建了高效的仿真环境，模拟静态和动态场景以验证决策模型的有效性。针对目标新增或消失及无人机资源损毁等典型场景，设计动态响应流程，涵盖任务目标集的判定、资源评估与集群支援以及打击次序调整等关键步骤，仿真结果验证了动态响应机制的有效性，完成了无人机集群资源分配和任务规划流程实现，确保任务连续性和决策鲁棒性。

本文针对无人机集群在动态战场环境中的自主决策问题，研究了任务级目标划分、资源分配与打击次序规划方法，以提升任务完成度与决策效率。仿真结果表明，基于强化学习的无人机集群决策方法在动态任务场景下具有良好的适应性和鲁棒性。本文研究为无人机集群智能化任务级动态决策提供了理论支撑与实践参考。

关键词：无人机集群；任务级自主决策；强化学习；动态场景；自适应智能动态决策模型

Abstract

As a critical component of the future intelligent warfare, the autonomous decision-making ability of UAV cluster directly affects the task completion and battlefield situation when it performs complex tasks in the dynamic battlefield environment. Facing the challenges of dynamic target changes and resource constraints, it is of great significance to study the efficient autonomous decision-making method of UAV cluster for ground targets. This paper focuses on the task level decision-making problem of UAV cluster attacking the ground target in the open battlefield environment. Combined with reinforcement learning and intelligent optimization algorithm, the process solutions of target division, resource allocation, strike sequence planning and task execution are designed. The applications of random forest, particle swarm optimization and near end strategy optimization algorithms in decision-making problems are studied, and the intelligent decision-making method of UAV cluster adapting to dynamic task changes is proposed, which improves the autonomous decision-making ability and task execution efficiency of the cluster. The research contents and related achievements are summarized as follows:

(1) Aiming at the problem of destruction target set decision and target area division in the dynamic scene of battlefield targets, the problem of task target set construction and subgroup clustering is solved based on random forest algorithm and near end strategy optimization method. The spatial distribution, defense capability and importance of targets are quantified, and a situation model including multi-dimensional attributes of enemy targets is established. Based on the random forest algorithm, the destruction target classification strategy is studied to achieve the effective judgment of the destruction target set; Based on particle swarm optimization and near end strategy optimization algorithm, the sub group division strategy of destroying target set under the condition of task balance and region compactness is studied, and the autonomous grouping decision-making in the scene of dynamic target changes is realized.

(2) Aiming at the problem of autonomous decision-making under the condition of target situation change and UAV cluster combat resource loss, a solution based on resource evaluation, strike order decision-making and dynamic support mechanism is proposed. The resource evaluation index system is established, and the threshold of task completion rate is set by Monte Carlo analysis method to ensure the rational allocation of resources and the feasibility of tasks. The decision-making algorithm of strike order based on deep Q network is introduced, and the experience playback and attention mechanism are used to optimize the training process, so as to improve the decision-making efficiency and benefit. Considering the loss of combat resources in the cluster, a heuristic algorithm is used to design a dynamic support mechanism to achieve efficient resource coordination and task adjustment.

(3) In order to verify the autonomous decision-making ability of the adaptive intelligent dynamic decision-making model, an efficient simulation environment was constructed to simulate static and dynamic scenarios to verify the effectiveness of the decision-making model.

For typical scenarios such as target addition or disappearance and UAV resource damage, the dynamic response process is designed, which covers key steps such as task target set determination, resource evaluation and cluster support, and strike order adjustment. The effectiveness of the dynamic response mechanism is verified, and the resource allocation and task planning process of UAV cluster are completed to ensure task continuity and decision robustness.

This paper addresses the autonomous decision-making problem of unmanned aerial vehicle (UAV) swarms in dynamic battlefield environments, and studies efficient target partitioning, resource allocation, and strike sequence planning methods to enhance mission completion and decision-making efficiency. The simulation results show that the UAV cluster decision-making method based on reinforcement learning has good adaptability and robustness in dynamic mission scenarios. This paper provides theoretical support and practical reference for intelligent task level dynamic decision-making of UAV cluster.

Key words: UAV Cluster; Task Level Autonomous Decision-Making; Reinforcement Learning; Dynamic Scene; Adaptive Intelligent Dynamic Decision Model

目 录

摘 要.....	I
ABSTRACT.....	III
目 录.....	V
第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究概述.....	2
1.2.1 无人机集群技术研究进展.....	2
1.2.2 强化学习在无人机集群领域的应用.....	5
1.2.3 无人机集群自主决策的研究难点.....	7
1.3 主要研究内容与结构安排.....	8
第 2 章 开放战场态势模型建立与分析.....	11
2.1 开放战场态势模型概述.....	11
2.2 敌方目标态势的数学模型.....	12
2.2.1 敌方目标属性.....	13
2.2.2 目标态势的数学模型.....	16
2.3 无人机集群作战资源模型.....	18
2.3.1. 无人机质点模型.....	18
2.3.2 无人机类型与集群资源.....	18
2.3.3 无人机作战资源数学模型.....	20
2.4 无人机集群目标攻击杀伤链模型.....	21
2.4.1 攻击条件与杀伤链模型.....	21
2.4.2 无人机作战决策模型.....	22
2.5 本章小结.....	23
第 3 章 动态战场下的摧毁目标决策和区域目标分群.....	25
3.1 摧毁目标集决策与区域目标分配问题描述.....	25
3.1.1 摧毁目标集决策问题描述.....	25
3.1.2 目标集区域划分.....	26
3.2 基于随机森林算法的摧毁目标集决策.....	27
3.2.1 随机森林算法原理.....	27
3.2.2 基于 RF 实现目标集决策.....	28
3.3 基于粒子群优化算法的目标集区域划分.....	30
3.3.1 PSO 算法原理与设计.....	31

3.3.2 PSO 算法实现目标集区域划分.....	32
3.4 面向动态事件的近端策略优化目标分群.....	34
3.4.1 PPO 算法原理与优势.....	35
3.4.2 PPO 算法设计与创新.....	36
3.5 摧毁目标决策和区域目标分配仿真分析.....	40
3.5.1 摧毁目标集决策仿真.....	40
3.5.2 基于粒子群算法的区域目标仿真分析.....	41
3.5.3 基于 PPO 的区域目标分配仿真分析.....	43
3.6 本章小结.....	45
第 4 章 无人机集群打击次序决策及自适应杀伤链构建.....	47
4.1 问题描述与数学建模.....	47
4.1.1 作战资源评估及资源协调问题建模.....	47
4.1.2 目标集打击次序决策问题建模.....	48
4.1.3 无人机集群动态调整支援问题建模.....	50
4.2 作战资源评估与任务完成率阈值分析.....	51
4.2.1 作战资源评估指标体系.....	51
4.2.2 基于蒙特卡洛分析的任务完成率阈值设定.....	52
4.3 基于 DQN 的打击次序决策.....	53
4.3.1 DQN 算法原理与优化.....	53
4.3.2 打击次序决策环境构建.....	56
4.3.3 区域目标打击决策流程.....	58
4.4 无人机集群动态支援机制设计.....	59
4.4.1 无人机集群任务执行突发状况剖析.....	59
4.4.2 支援机制设计.....	61
4.5 仿真实验与分析.....	62
4.5.1 任务完成率阈值设定仿真分析.....	62
4.5.2 打击次序决策仿真分析.....	64
4.5.3 无人机集群支援机制仿真分析.....	66
4.6 本章小结.....	69
第 5 章 面向典型场景下的无人机集群对地打击自主决策仿真.....	71
5.1 仿真设置及总体框架.....	71
5.1.1 仿真环境与关键参数设置.....	71
5.1.2 总体仿真流程框架.....	72
5.2 静态场景下的无人机集群对地目标决策仿真.....	74

5.2.1 静态场景下的决策过程	74
5.2.2 仿真结果及分析	75
5.3 动态场景下的无人机集群自主决策仿真	79
5.3.1 场景描述与动态变化设定	79
5.3.2 原有目标消失仿真结果及分析	80
5.3.3 新增目标出现仿真结果及分析	82
5.3.4 无人机资源损失仿真结果及分析	85
5.4 本章小结	92
第 6 章 全文总结与展望	93
6.1 全文总结	93
6.2 后续工作展望	94
参考文献	95
致 谢	103
在学期间发表的学术成果和参加科研情况	105

第1章 绪论

1.1 研究背景及意义

习近平总书记视察空军航空大学时发表重要讲话,指出“现在各类无人机系统大量出现,无人作战正在深刻改变战争面貌。要加强无人作战研究,加强无人机专业建设,加强实战化教育训练,加快培养无人机运用和指挥人才”。总书记准确把握未来战争形态和装备发展的趋势,高屋建瓴地指出了无人机装备未来发展建设的方向。无人机凭借高灵活性、低成本及强机动性等优点,在军事对抗中得到快速发展和广泛应用^[1]。然而,随着任务和环境的复杂变化,单一无人机在实际应用上存在一定的局限性^[2],已难以满足现代战争任务的需求。由多个无人机组成的无人机集群因其高鲁棒、多功能及可扩展等优势逐渐成为各国关注的研究热点^[3]。特别是在复杂动态战场环境中,无人机集群任务级决策能力直接关系到作战任务的完成度与战场态势发展。因此,针对无人机集群对地打击的自主决策技术研究已成为当前无人作战领域亟待解决的重要课题。

2016年,宾夕法尼亚大学 Kumar 教授在 CCF-GAIR 全球智能与机器人峰会上提出的无人机发展“5S”趋势:小型(Small)、安全(Safe)、智能(Smart)、敏捷(Speed)、集群(Swarm),首次明确将无人机集群作为一种颠覆性技术。在统一目标任务之下,集群内无人机之间密切协同,形成有机整体^[4]。目前,世界大国竞相发展和部署无人机集群装备,它将成为未来“空一天一地一海一潜”一体信息化战争中不可或缺的武器装备之一。值得一提的是,执行任务的集群任务范围广,数量多,目标重要程度差异等特点迫使集群协同任务分配问题亟待解决,以提高任务执行效率^[5]。无人机集群任务规划旨在根据任务需求、自身特性等要求对目标任务进行综合调度,从而建立无人机与任务目标之间合理的映射协同关系^[6-7],实现全局层面的任务分配。

自2022年俄乌战争爆发以来,双方投入各类无人机装备数十型,总量超4000架,其中重量在100千克以下的小型无人机占比超过80%,执行侦察监视、定点清除、自杀式攻击等任务,具有强时敏性、高效费比和高自主化作战优势,发挥了不可估量的作战效果,极大地改变了双方空中战场的攻防局面。其中以沙赫德-136自杀式无人机组成的无人机蜂群游荡在乌克兰上空,四处袭扰,令乌军苦不堪言,更让乌克兰民众提心吊胆。该蜂群中的个体无人机遵循简单的行为规则,却能够相互协作完成复杂的团队活动,表现出分布式、自组织、协作性、稳定性等特点,形成了极强的环境适应能力,通过规模优势提高整体作战效能。

综合国内外研究发现,无人机集群的特点主要包括^[8]:集群内的无人机是分布式的,没有中心控制,不会因为个体出现不确定的状况而影响整体;集群内无人机无法直接获取全局信息,只能感知部分信息,并遵循自治规则;无人机之间基于通信网络进行协作

包含的个体越多，通信消耗量就越大；集群内的无人机个体具有良好的自主性，能够协同执行相对复杂的任务。综上所述，无人机集群不是简单地将无人机个体进行叠加，不可以把“一群”等同于“集群”，集群强调的是“有机”的整体。从复杂程度上理解，无人机集群是由多无人机和无人机簇进一步提升发展而来，是二者的高阶形式。

本研究根据开放战场环境中的动态任务需求，开展了针对目标和无人机集群的系列研究，重点解决集群在任务执行过程中应对突发动态场景下的自主决策，包括环境中的目标变化和集群内作战资源的损毁等事件。相关研究成果，能够有效解决在多任务高动态战场中的集群智能决策问题，为无人机集群智能化发展及工程实践提供了理论参考。

1.2 国内外研究概述

无人机集群在高动态多任务的开放战场环境下的决策问题较为复杂，涉及多学科、多领域的交叉融合。根据研究内容的需要，本节将逐层递进介绍无人机集群技术研究进展及其强化学习在该领域的研究进展。

1.2.1 无人机集群技术研究进展

国外对于无人机集群技术的相关研究起步较早，主要应用于军事领域。2010年起，美国国防部高级研究计划局(Defense Advanced Research Projects Agency, DARPA)基于无人机系统和有人/无人系统的协同作战先后启动了拒止环境下的协同作战(Collaborative Operations in Denied Environment, CODE)项目、小精灵(Gremlins)项目和远射(LongShot)项目等，不断探索无人机协同作战的新模式，以提高无人机的协同能力^[9]。

DARPA 于 2014 年提出 CODE 项目，其目标是发展一套包含协同算法的软件系统，增强无人系统的自主协同能力，以提高军队在拒止环境中的作战能力。CODE 项目设想图如图 1-1 所示。2015 年，DARPA 启动 Gremlins 项目^[10]，旨在开发搭载各类载荷的小型空射无人机，以及多架无人机的空中发射与回收技术，并进行演示和验证，如图 1-2 所示。DARPA 在 2021 年公布 LongShot 项目，其目标是显著增加空对空武器的攻击范围以及提高任务执行效率。此外，美国空军的“天空博格”与澳大利亚“忠诚僚机”等项目相关研究和验证，将具备自组织和智能协同能力的无人机蜂群投入实战^[11-12]。



图 1-1 CODE 项目概念示意图



图 1-2 Gremlins 项目设想图

得益于通信技术的迅速发展,国内的无人机集群技术也日趋成熟。自 2016 年以来,中国电子科技集团在陆续开展多次陆空协同攻击的无人机集群实验,数量由最初的 67 架到近期的 200 余架,机型覆盖弹射固定翼无人机、小型固定翼无人机、小型折叠翼无人机等众多类型,可实现在短时间内完成无人机蜂群的空中编队,对敌方实施蜂群作战行动。



图 1-3 中电科折叠翼无人机试飞

与此同时,国内外学者对无人机协同作战进行了广泛研究, Moseley^[13]等提出了一种协同系统,将 iRobot PackBot 无人车和 Raven 无人机平台采集的视觉图像进行去中心化融合,用于无人机与无人车对目标进行远距离协同跟踪。Zhao 等提出一种多无人机跟踪多目标的分布式决策方法,用于无人机协同目标跟踪^[14]。Gu 等提出一种新型多无人机协同监控网络架构来实现无人机传感器网络的集成,用于对多运动目标进行监控^[15]。Xia 等提出了一种解决地面运动目标多无人机协同任务分配和航迹规划问题的系统框架^[16]。该框架使用预测相交点的方法将运动目标作为航迹规划的目标点,通过自适应参数和蚁群优化算法实现航迹规划。Wang 等使用领导者-跟随者和势场法的编队控制算法,实现了多无人机持续跟踪目标^[17]。Zhou 等提出一种集成无人机运动控制、目标状态估计和网络拓扑控制的系统,用于实现多无人机在有限通信距离下的协同目标跟踪^[18]。Yao 等提出一种多无人机目标跟踪航迹规划的混合方法,实现了在城市环境下对目标进行跟

踪^[19]。Li 等将多无人机协同侦察与监视任务分解为三个顺序任务：协同运动、传感器探测和协同信息融合，通过解决三个顺序任务以完成协同侦察任务^[20]。Ni 等把协同跟踪问题建模为一个潜在博弈论问题，并提出了一种改进的二进制对数线性学习（BLLL）算法，用于无人机协同侦察^[21]。Liu 等研究一种新型无人机无人车合作路由问题，用于无人机和无人车协同执行 ISR 任务^[22]。Yang 等把蚁群算法用于多无人机对目标区域进行协同侦察，通过改进蚁群算法的行为准则和信息素的更新规则来确定无人机航点的计算规则，从而实现协同侦察^[23]。Duan 等提出一种混合架构的动态离散鸽群优化算法，用于解决多无人机的侦察-攻击任务规划问题^[24]。

以上学者的研究工作都集中在无人机协同以及集群控制算法上，很少关注在具体的任务环境中如何进行无人机的协同作战。相应的，Sauter 等提出了一种无人机-无人车协同作战部署方案，用于城市地区的协同作战^[25]。Collier 等介绍了在蒙特利举行的技术合作项目^[26]，该项目成功演示了无人机系统与地面部队进行协同作战，从而提高作战人员在复杂城市环境中的态势感知能力。自无人机集群的出现开始，就被广泛用于解决协同路径规划^[27]、协同感知^[28]和协同任务分配^[29]等分布式协作任务。目前而言，无人机集群技术的发展受制于多机自主协同的难题，主要通过预设指令或者远程操控的方式实现，这与真正的智能集群含义并不相符。现有研究工作中无人机集群协同控制技术由无自主决策能力逐渐向具有高效的自主学习和决策能力发展^[30]。

由于大规模集群的复杂性，任务规划及分配是无人机集群自主策的关键一环，合理的无人机集群任务分配模型和算法将大大提高集群整体性能，释放各 UAV 的潜力。针对无人机协同任务分配问题，国内外众多专家学者进行了相关的研究。无人机集群任务分配有多种分类方式，按照无人机任务之间的相关性，可归类为协同任务分配^[31-32]和独立任务分配^[33]；按照无人机任务所处的环境，可归类为静态任务分配^[34]和动态任务分配^[35-36]；按照无人机任务的分配方法，又可归类为从集中式任务分配和分布式任务分配^[37]。




图 1-4 任务分配方法

集中式任务分配与分布式任务分配方法所依赖的控制节点不同,集中式任务分配依赖中央控制节点进行全局优化,适合小规模或静态任务,但通信依赖高、扩展性差;分布式任务分配基于无人机自主协作和局部信息共享,适应动态环境和大规模任务,具备更高的鲁棒性和实时性,但可能陷入局部最优。常见的集中式任务分配方式有最优化方法^[38]和启发式方法^[39],分布式方法更适合动态环境下的任务分配,常见的分布式任务分配方法主要有拍卖算法^[40-41]和博弈论^[42-44]等。

作为交叉性研究领域,无人机集群自主决策与控制理论、通信技术以及人工智能与机器学习等有着密切的联系。博弈论、信息论、运筹学、模式识别、最优化方法等构成了该研究领域的理论基础。近年来,随着人工智能的发展,无人机集群自主决策融合人工智能涌现了许多新兴方法。

1.2.2 强化学习在无人机集群领域的应用

随着任务复杂性和环境不确定性的不断攀升,传统的控制方法已难以满足无人机集群高效协同作业的需求。作为一种强大的人工智能技术,强化学习凭借其独特的试错学习和动态决策能力,在无人机集群领域展现出了巨大的应用潜力,为解决无人机集群在复杂环境下的自主决策、任务分配、路径规划等核心问题提供了全新的思路与方法,成为推动无人机集群技术发展的重要驱动力。

由于强化学习是一种不需要事先准备样本集的学习算法,比较适合应用于无样本或样本采集困难的军事领域^[45]。罗德林等利用专家系统构建作战行为集和决策方法集,用于无人机集群对抗的决策过程,具有简单决策规则的单架无人机聚集到一起涌现出了复杂的集群对抗现象^[46]。深度强化学习方法已被大量应用于集群决策领域,DeepMind 研究人员 Joel Z. Leibo 等将深度 Q 网络(Deep Q-network, DQN)用于多智能体(Multi-Agent)的矩阵博弈,并通过三个多智能体博弈案例证明通过 DQN 算法学习,智能体能够获得更好的决策能力^[47]。OpenAI 研究人员 Ryan Lowe 等将 Actor-Critic 算法用于合作-竞争(Cooperative-Competitive)环境下的多智能体决策问题,利用信息交流机制解决了多智能体决策问题中环境动态变化导致的算法不收敛的问题^[48]。上海交通大学的张伟楠团队开发了高效的基于深度强化学习的大规模集群系统软件仿真平台,达到业界领先水平,并将深度强化学习用于智能交通控制^[49]。

针对无人机集群的深度强化学习应用多见于多机运动规划问题。Liu M 等人^[50]利用 DQN 算法实现了基于虚拟领航者-跟随者结构的集群规划。跟随者的奖励函数设计根据 Reynolds 三原则^[51]和跟随领导者要遵循的要求而设计。在此基础上,Xiao J 等人^[52-53]通过引入图网络来加强算法效果。提出了一种适用于通信受限环境的多智能体协作强化学习方法(MACRL),实现了最多 20 个智能体在无障碍物环境下的集群规划。Wang C, Yan C 等人构建了一套从仿真到半实物仿真的平台,在领航者-跟随者结构下,进行了一些算法的改进和验证。其对固定翼无人机的模型进行了二维简化,早期研究为在无障碍物环

境中跟随者策略的研究^[54-59]。其团队最新的研究,已进展到了更具挑战的有障碍物的场景,最新研究主要提出了一种基于课程的多智能体深度强化学习算法(MADRL),将集群防碰撞任务分解为多个子任务,并以阶段性的方式逐步增加需要解决的子任务数量。

区别于领航者-跟随者结构,分散式结构通过集群中心坐标来启发聚集行为。Wang W 等人^[60]基于参数共享的 TD3 算法,在局部通信条件下,通过启发无人机向无人机集群中心靠拢来形成聚集和保持聚集。Bai C^[61]等人在二维环境和局部通信感知下,通过启发无人机向无人机集群中心靠拢形成聚集,通过结合一个与无人机速度相关的斥力函数来改进 SAC 算法,通过斥力函数来避免无人机之间的碰撞,通过设计奖励函数来避免和障碍物的碰撞。Zhu P 等人^[62]通过设计两个奖励函数,将多智能体算法 MADDPG 引入到多无人机规划领域,实现了三个无人机的规划。Meng L 等人^[63]通过添加一个改进的人工势场函数作为奖励函数来启发无人机学习聚集和避障行为,实现了五架无人机在有障碍物场景中的集群规划。

将经典的多智能体深度强化学习算法引进解决多智能体规划问题时,容易遇到环境奖励稀疏、环境动态复杂、高价值经验数据采集困难等问题。一般采用三种方法对多智能体深度强化学习算法进行改进。这三种方法为专家演示型、任务分解型、和改进通信型^[64]。专家演示型的强化学习是模仿学习和强化学习的交叉点。它融合先验经验和在线经验来引导强化学习过程^[65]。Wang J 等人^[66]利用人工势场法和 PID 结合来生成专家经验数据,对网络进行预训练,减少无效探索和加快学习速度。Wan K 等人^[67]混合人工势场法的经验来改进 MADDPG 算法的经验池,实现了多机器人从不同起点搜索各自任务目标的多机器人的规划任务。Hu Z 等人^[68]用模型控制和模拟退火来生成专家经验来提高 DDPG 算法的效果。Pfeiffer M 等人^[69]利用模仿学习和强化学习相结合的方式进行训练,将基于约束的强化学习应用在无地图的导航中。Liu Y 等人^[70]研究了专家经验和在线经验的比例对算法效果的影响。

利用人类先验经验进行分层设计,可以提高算法效率和降低神经网络的维度。赵国权^[71]针对机械臂的规划问题,用分层强化学习进行求解,有效降低了策略神经网络的输入维度。程先峰等人^[72]针对无人机和有人机协同完成任务的场景,设计了一种基于 MaxQ 的多智能体分层强化学习协调方法,有效提升了无人机和有人机的协调能力。Le H 等人^[73]将模仿学习引入分层结构,在不同层级上使用模仿学习或者强化学习来提升学习效率。

此外,在面临时变任务和突发条件下,无人机集群的实时协同任务分配和决策优化在当前和未来一段时间内将是集群任务分配的难点。Yang L^[74]中提出了一种用于无人机任务调度的深度强化学习算法,提高了每架无人机任务的执行效率。在文献^[75]中针对任务随机下发场景中由于任务完成时间约束带来的任务完成度低的问题,通过强化学习方法进行无人机的行为决策,提高任务完成度。Chen J 等^[76]提出了一种基于强化学习的

多无人机辅助网络资源分配方法,降低了能耗和系统延时。Afghah F 等^[77]考虑了资源约束无人机异构网络任务分配问题,提出了一种基于声誉的联盟形成机制,形成最优联盟。陈璞^[78]提出了一种基于合同网的分布式无人机集群任务分配方法,建立了异构无人机与新目标任务之间的适当协作约束。Liu D^[79]研究了环境不确定性条件下面向异构无人机动态任务分配问题,构建了基于多智能体强化学习的协调网络,便于快速响应目标任务的分配。Qi N 等^[80]提出了一种异构无人机网络资源分配的重叠联盟形成对策,优化无人机任务分配。宋佰霖等^[81]针对协同电子战中干扰协同决策难题,通过构建“整体优化、逐站决策”的协同决策模型,基于深度强化学习技术,能够输出资源利用率最高的干扰方案,并大幅提高决策效率。

尽管面向无人机集群不同领域的有关强化学习的研究不少,但目前已披露的复杂网络应用到具体的军事应用的研究并不多,而面向无人集群系统的复杂网络研究更是屈指可数。北京航空航天大学的王立志首次尝试用多层复杂网络对无人集群系统进行建模,打开了使用复杂网络理论分析无人集群系统的大门^[82-83]。北京航空航天大学的王晓红利用复杂网络理论,从通信网络、实体关系、载荷关系三个方面对无人集群系统进行建模,建立了一套无人集群系统的鲁棒性评估方法^[84]。

综上分析,当前无人机集群在借助强化学习方法的研究,大多针对同模式、同价值的任务目标进行集群的协同分配,针对开放战场环境下发生动态事件后在无人机集群层面任务自主决策及群间的自适应支援协同研究较少,缺乏处理无人机集群多任务高动态战场环境下的自主决策的完整研究框架,亟待在该领域的研究探索。

1.2.3 无人机集群自主决策的研究难点

无人机集群自主决策能力是其在复杂战场环境中执行任务的核心竞争力,直接影响任务规划、资源分配和战术调整的效果。然而,当前无人机集群自主决策仍面临诸多挑战,这些挑战主要源于战场环境的动态性、任务需求的复杂性以及系统性能的实时性要求。为了进一步提高无人机集群的智能化水平,需要重点解决以下几方面的关键问题。

(1) 战场动态环境的准确表征。战场环境的动态性是无人机集群决策中的首要挑战,此外,敌方目标的多维特征,包括防御能力、威胁等级和战略价值等方面的差异性,提高了态势建模的复杂度。以往研究多采用简化假设,忽略动态突发因素或仅考虑静态场景,导致模型的适用性和鲁棒性受到一定限制。因此,亟需建立多维动态态势模型,全面描述战场目标属性和无人机资源约束,以支撑复杂环境下的智能决策与任务执行。

(2) 考虑多决策要素和多类型约束的智能决策。无人机集群需要在高维状态空间中应对多目标、多约束条件下的任务决策问题。近年来的研究引入了机器学习和强化学习方法,旨在通过大规模数据训练提升模型的自适应能力。这些方法在实际环境中的应用仍面临算法收敛速度慢、鲁棒性不足和多约束条件处理能力有限等问题。故需进一步优化智能决策算法,提高无人机集群在复杂多约束环境中的任务适应性与决策效率。

(3) 动态突发事件的快速响应是无人机集群自主决策系统面临的核心挑战之一。近年来,研究者针对突发事件响应提出了多种算法和框架,但这些研究在应对突发事件时大多依赖预设规则,缺乏对动态环境的持续感知和自适应调整能力。需进一步结合深度强化学习与自适应优化策略,实现高效的在线智能响应与控制。

综上所述,无人机集群自主决策研究面临动态环境建模、复杂任务分配以及多目标优化与协调控制等多重挑战。本研究需要进一步探索智能算法和集中式架构的结合,以提高无人机集群在复杂环境中的自主决策水平和任务执行效率。

1.3 主要研究内容与结构安排

本文研究基于强化学习的无人机集群对地目标自主决策方法,围绕动态战场环境中的目标优先级评估、集群任务分配及自适应打击次序优化展开。重点分析无人机资源约束与目标特性对决策过程的影响,并结合动态调整机制提升任务执行效率与鲁棒性。本文整体行文组织框架如图 1-5 所示。




图 1-5 论文章节框架图

第一章为绪论。首先阐述研究背景及意义,分析国内外研究现状及相关技术发展。

其次总结无人机集群自主决策方法的研究难点及挑战，提出本文研究目标与创新点，最后介绍行文结构与各章节安排。

第二章主要内容为开放战场态势模型建立与模型分析。针对无人机集群自主决策任务，建立开放战场目标态势数学模型，并分析目标动态变化特性。随后构建无人机集群作战资源模型和攻击伤害链模型，为后续决策算法提供理论基础与输入特征支持。

第三章主要内容为动态战场下的摧毁目标决策和区域目标分配。在第二章所建立的目标态势数学模型基础上，设计随机森林决策模型筛选高综合价值的目标纳入摧毁目标集，其次基于粒子群优化算法，对目标进行分群规划，并提出面向动态事件的近端策略优化方案，提升无人机集群的区域任务适应能力。结合资源评估模型与群决策策略，优化群体资源分配，确保任务的动态调整与稳定执行。

第四章主要内容为无人机集群打击次序决策及自适应杀伤链构建。设计基于深度强化学习的打击次序优化方法，通过任务完成率阈值分析评估任务收益与打击优先级。进一步提出无人机集群的支援机制，针对动态资源损耗场景进行自适应调整，给出了在不同动态事件下的无人机集群支援案例仿真结果，提升无人机群体打击效率和生存能力。

第五章是基于前文方法基础的面向典型场景下的无人机集群对地目标自主决策仿真。结合静态与动态场景，验证无人机集群自主决策模型的有效性。在静态场景中分析目标优先级与分群任务分配策略，在动态场景中模拟目标新增与无人机损耗条件下的决策调整过程，评估模型的任务适应性与鲁棒性。

第六章为全文总结与未来展望。总结全文研究内容与主要结论，分析研究成果的理论与应用价值，同时指出当前研究的不足之处，并展望后续研究方向，为未来无人机集群自主决策方法的进一步优化提供参考。

第2章 开放战场态势模型建立与分析

开放战场态势模型的建立是智能化无人机集群作战决策分析的基础。本章首先介绍了开放战场的环境特征与目标布局，分析了敌方目标的动态变化及其对无人机集群作战的影响；其次，针对战场中复杂的多任务、多目标情境，建立了敌方目标态势的数学模型，并对不同类型目标的属性进行了详细分析；进一步，构建了无人机集群作战资源模型，包含了无人机类型与集群资源的定义，以及无人机作战资源的数学建模，为无人机集群在战场中的协同作战提供了模型基础；最后，针对战场中可能发生的敌方干扰与资源约束，构建了目标攻击杀伤链模型，为后续的决策与优化算法提供了理论支持与模型基础。

2.1 开放战场态势模型概述

现代战争中，战场态势的复杂性和动态性日益增加。无人机集群在战场上的应用，尤其是在高动态环境中的多任务协同作战，面临着多样化的挑战。为了提高无人机集群的作战效率，必须构建准确的战场态势模型，以描述敌我双方在战场上的相互作用以及无人机集群的决策基础。

无人机集群在作战过程中，需要综合考虑敌方目标的重要程度、威胁程度和防御能力等因素，并根据这些特征对战场目标进行分类和处理。因此，开放战场态势模型的建立不仅是无人机集群任务分配与决策的基础，也是后续任务执行和资源分配优化的前提条件。现代战场环境日益复杂和动态化，尤其在高动态对抗情形下，无人机集群面对的战场态势包含多种多样的目标、威胁和任务需求。为了应对这些挑战，构建一个有效的开放战场态势模型对于无人机集群的多任务规划和决策至关重要。该模型不仅需要描述敌方目标和防御的分布情况，还需反映出无人机集群在战场中的侦察、通信和火力资源分布及其动态变化。

开放战场态势模型的建立，需要充分反映以下几个方面的特征：

（1）动态适应性：模型能够实时适应战场环境的变化，包括新目标的出现、原有目标的消失、无人机损毁等情况。

（2）任务决策支持：模型为集群的多任务规划提供支持，特别是根据任务优先级、威胁等级和防御程度进行任务分配与决策。

（3）集群协同：支持无人机集群内多架无人机协同工作，通过智能决策实现高效的任务分配和打击目标。

本论文研究的应用场景想定为：无人机集群飞向交战战场，基于群体摧毁能力对战场敌方目标进行择优攻击而非全部攻击，在充分发挥集群作战资源的基础上尽可能多的摧毁敌方不同类型重要目标，直至无人机集群耗尽进攻资源。

在此应用场景下，开放战场态势模型将以无人机集群对地目标择优攻击的应用场景为核心，重点解决以下问题：

（1）建立描述无人机集群作战资源与敌方重要目标态势的数学模型。无人机集群需最大化利用进攻资源，但由于有限的集群作战资源与摧毁目标需求之间存在不对称性，以及不同目标类型在防御、威胁、重要性等特征上的差异性，模型需同时考虑多种约束条件，导致集群作战资源与摧毁不同类型重要目标需求之间关系的数学表示具有较高的复杂性。

（2）战场态势动态变化情形下的摧毁目标集决策与目标区域划分问题。在战场态势动态变化的情形下，无人机集群需结合任务需求和无人机资源分布，实时更新任务规划和分配策略，针对目标集决策与目标区域划分问题进行动态调整，以应对作战环境的复杂性与不确定性。

（3）目标态势变化以及无人机集群作战资源损失条件下的自主决策问题。在该场景要求下，自主决策问题的核心是确保无人机集群在资源受损和战场环境动态变化的情况下，通过打击次序决策和动态组网等方法构建自适应杀伤链，实时响应战场动态事件，保障高效完成作战任务。



图 2-1 开放战场态势效果示意图

基于以上分析，开放战场态势模型是无人机集群在高动态环境中实现任务决策与协同作战的核心基础。为构建该模型，需要分别从敌方目标态势与无人机集群作战资源两个层面进行深入研究。

2.2 敌方目标态势的数学模型

为了实现无人机集群对地面目标的精确打击，构建敌方目标态势的数学模型至关重要。该模型能够量化敌方目标的关键属性（如重要性、威胁程度和防御能力），为无人机集群的任务规划与打击决策提供科学依据。本节将详细探讨目标态势建模的理论框架、关键指标及其数学表达式。

2.2.1 敌方目标属性

敌方目标态势模型需要能够动态描述战场上的多样化目标属性，并结合目标之间的关联性进行综合分析。根据对美国中央测量与特征情报机构（CMO）建立的国家目标与威胁特性数据库系统的相关资料分析，对于战场目标特性的一般描述主要包括：位置与空间关系、战略价值、威胁度、防御能力以及动态特性等多维信息，下面给出战场一般目标属性的定义。

（1）位置与空间关系

在战场环境中，目标的地理位置和空间分布对无人机集群的任务规划具有重要影响。目标的地理位置及与其他目标的空间关系直接影响打击顺序和资源分配。距离远近不仅影响攻击消耗，还可能影响打击效果。在无人机的续航能力和攻击资源有限（如弹药、航程）的情况下，相邻目标的优先打击可以降低飞行路径的资源消耗，并提升任务执行效率。除此之外，目标之间的空间分布可能呈现聚集或分散的状态，这将直接影响打击策略。聚集的高优先级目标可以形成集群打击的优先区域，而分散的目标则需要权衡路径规划与资源消耗。实时评估目标的空间特性，确保无人机对动态目标的快速响应，是任务成功的关键。

目标的空间特性可以通过无人机集群 U_k 位置坐标和目标 i 之间的距离表示如下：

$$P_{ik} = \sqrt{(x_i - x_k)^2 + (y_i - y_k)^2} \quad (2-1)$$

其中： (x_i, y_i) 和 (x_k, y_k) 分别是目标 i 和无人机集群 U_k 的在二维平面上的坐标。

在目标聚类的情況下，可以计算目标 i 与其所在簇中心的距离和，用于评估簇内目标分布离散程度：

$$D = \sum_{i=1}^n \sqrt{(x_i - x_{cluster})^2 + (y_i - y_{cluster})^2} \quad (2-2)$$

其中： n 为目标簇内包含的目标数量； $(x_{cluster}, y_{cluster})$ 是目标簇中心的坐标。

目标与簇中心的距离和越小，说明该目标簇内目标分布越集中，无人机集群可以根据目标的空间分布设计打击路径，优先攻击相邻目标，形成最短路径打击序列，既提升命中率，又减少能量消耗。

（2）目标的战略价值

目标的战略价值是战场态势建模中至关重要的一项指标，它反映了目标在作战行动中对敌我双方的战略影响。在无人机集群任务规划和决策中，目标的战略价值决定了优先打击的对象，有助于集群合理分配资源、提高任务执行效率。在战场态势中，不同目标对完成任务的影响不同，通常与目标的类型（如指挥中心、通信节点、普通火力点）和其所处任务情境有关。对于指挥中心而言，通常是优先摧毁的目标，重要程度高。普通火力点则对任务影响小，重要程度低。此外，目标的价值不仅与其本身的属性相关，还与当前任务的需求密切相关。

目标的重要程度 V_i 可以由多个特性加权求和，包括目标类型及任务需求。目标类型即不同类型目标的重要性值不同，任务需求是指目标与当前任务优先级相关。其数学表达式如下：

$$V_i = \omega_t \cdot \text{type}_i + \omega_m \cdot \text{priority}_i \quad (2-3)$$

其中： ω_t 和 ω_m 是权重参数，需通过经验或优化方法确定； type_i 表示目标 i 的类型值； priority_i 是任务对目标的优先级评分。

基于目标的价值计算结果，集群可以进行任务排序并分配资源。对于具有高重要性的目标，可以优先分配攻击资源；而对低重要性的目标，则可以延迟攻击或分配较少资源。

(3) 防御能力

防御能力是战场态势模型中的关键特征之一，它衡量目标自身的保护程度，包括各种物理防护、电子防护及环境适应性等。防御能力直接影响目标的生存概率和摧毁难度，是决定目标是否能有效被摧毁、需要投入多少资源进行打击的重要因素。在实际作战中，敌方目标的防御能力可能会表现为多种形式，这些形式的复杂性和多样性使得防御能力的建模成为一项挑战。防御能力越强，目标就越难摧毁，意味着无人机集群在执行任务时，需要投入更多的时间、火力、甚至可能需要更多的无人机资源来完成攻击任务。

防御能力 D_i 可以表示为多个防御因子的加权和，这些因子包括但不限于物理防护、电子对抗、防空能力、机动性和隐身性等。每种防御因子可以通过一定的数学模型进行量化，最终通过加权求和得到目标的综合防御能力。

物理防护 $D_{\text{phy},i}$ 可以根据目标的类型和具体设施来量化。假设目标 i 具有一个防护强度 P_i ，其物理防护的贡献可以表示为：

$$D_{\text{phy},i} = \alpha_1 P_i \quad (2-4)$$

其中： P_i 可以是目标的装甲厚度、地下掩体深度等度量； α_1 是一个调节系数，用于考虑不同类型物理防护的相对重要性。防空能力 $D_{\text{aa},i}$ 可以通过目标所配备的防空系统的特性来表示。目标的防空射程 R_i 、拦截概率 I_i 和反应速度 ρ_i 都可以作为防空能力的度量。防空能力可以表示为：

$$D_{\text{aa},i} = \alpha_2 \left(\frac{R_i}{R_{\max}} + I_i + \rho_i \right) \quad (2-5)$$

其中： $R_{\max}$ 是所有目标防空射程的最大值； α_2 是权重系数，用于调节不同防空系统的影响。

电子对抗能力 $D_{\text{ew},i}$ 可以根据目标所部署的电子干扰设备（如 GPS 干扰、通信屏蔽等）来量化。假设目标 i 的电子对抗能力为 E_i ，其贡献可以表示为：

$$D_{\text{ew},i} = \alpha_3 E_i \quad (2-6)$$

其中： α_3 是权重因子； E_i 表示目标的干扰强度或反制能力；目标的机动性 $D_{\text{mob},i}$ 和隐身

性 $D_{ste,i}$ 可以量化为其移动速度 v_i 和雷达隐身系数 S_i 的线性函数:

$$D_{mob,i} = \alpha_4 v_i, D_{ste,i} = \alpha_5 S_i \quad (2-7)$$

其中: α_4 和 α_5 是权重因子; v_i 是目标的最大机动速度; S_i 是目标的雷达反射面积。

最终, 目标的防御能力 D_i 可以表示为各防御因子的加权和:

$$D_i = D_{phy,i} + D_{aa,i} + D_{ew,i} + D_{mob,i} + D_{ste,i} \quad (2-8)$$

在多人无人机集群协同作战的背景下, 针对高防御能力目标的打击通常需要集群内多个无人机协同合作。防御能力强的目标可能会导致攻击策略的调整, 例如, 使用不同的打击方式, 甚至通过干扰、电子战等手段削弱敌方的防御。

(4) 威胁度

战场中目标的威胁程度是战场态势模型中至关重要的特征之一, 它反映了目标对无人机集群或己方单位的潜在危害。在现代战争中, 敌方目标的威胁程度直接影响任务规划和打击优先级, 因为高威胁目标可能对无人机的安全构成直接威胁, 甚至可能摧毁部分或全部集群, 从而影响任务成功率。

威胁程度不仅仅是基于目标的攻击能力, 还涉及目标的位置、火力范围、威胁类型、攻击方式等多个因素。高威胁目标通常包括敌方的防空武器、反无人机系统、高火力的战斗单位(如坦克、反舰导弹发射平台等)以及战略性目标(如指挥中心、通信基站等)。这些目标对无人机或己方单位的攻击能力较强, 因此需要优先摧毁, 以确保集群完成任务。

目标的火力值 F_i 可以通过目标的武器系统、攻击能力以及攻击频率等因素来量化。假设每个目标的火力值通过一个量化函数 f_i 来表达, 火力值可以表示为:

$$F_i = \beta_1 f_i \quad (2-9)$$

其中: β_1 为权重系数, 用于调整火力值在威胁程度中的相对重要性; f_i 由目标类型(如防空系统、指挥中心等)和其攻击频率、威力等因素决定。

目标的射程和攻击能力 R_i 与目标的攻击范围、打击精度等相关, 通常表示为:

$$R_i = \beta_2 \left(\frac{d_{\max,i}}{d_{\max}} + P_i \right) \quad (2-10)$$

其中: β_2 为权重系数; $d_{\max,i}$ 是目标的最大射程; $d_{\max}$ 为所有目标射程的最大值; P_i 为目标的攻击精度。

目标可能具有一定的防御配套形成反制措施, 与其自身的防御能力正相关, 为方便建模, 以防御能力 D_i 表示该部分威胁度。

综合以上组成威胁度的若干因素, 目标所含有的威胁程度可以表示为上述各因素的加权和:

$$T_i = F_i + R_i + \beta_3 D_i \quad (2-11)$$

在多目标任务中, 威胁程度高的目标通常需要优先打击。通过以上对威胁程度的详

细分析和建模，无人机集群可以在复杂战场中根据目标的威胁程度合理分配资源，优先打击高威胁目标，从而提高集群作战的整体效率与安全性。

(5) 动态性

在开放战场环境中，敌我双方的战术、目标状态和资源配置等因素随着时间的推移不断变化。因此，动态性是战场态势模型中的一个重要特性。目标的状态可能在不同时间发生变化，例如目标可能随时间消失、新目标出现、防御力量改变等，都会对无人机集群的作战计划产生影响。

战场动态性反映了目标状态的时间演化过程。随着战场态势的不断变化，原本固定的目标可能由于攻击、移动或防御措施的变更而影响战斗策略。因此，无人机集群在执行任务时，必须实时感知并适应战场态势的变化，尤其是对目标动态性的准确建模，可以提高任务分配、目标优先级排序以及打击效果的预测精度。

目标的动态性可以通过状态转移函数建模：

$$State_i(t+1) = g(State_i(t), action_i, env_t) \quad (2-12)$$

其中： $State_i(t)$ 表示目标*i*在时间*t*的状态，包括存活、被摧毁、新增目标等； $action_i$ 表示无人机在*t*时间对目标的行动； env_t 是指战场环境的变化。

通过动态性建模，可以对战场态势进行预测和模拟，提前评估目标的潜在变化及其对任务的影响。这为战术决策和任务规划提供了科学依据，能够帮助无人机集群做出更加精准和有效的决策。结合强化学习方法，动态性建模可以用于无人机集群的在线决策过程。通过对动态变化的目标和资源状态进行实时建模，无人机集群可以使用 RL 算法不断优化任务分配和目标打击策略。

2.2.2 目标态势的数学模型

前文对目标的各特性做了定量分析，相互之间存在一定的关系。本节旨在将目标特性通过数学建模方法综合表示，形成目标态势的完整描述。通过构建每个目标的信息向量 T_j ，将目标的多个特性以统一的数学形式表达，并对部分特性采用概率函数描述，以支持复杂任务环境下的动态决策。

设敌方目标*j*的信息向量为 T_j ，则 T_j 可表示为：

$$T_j = \{P_j, L_j, V_j, D_j, M_j\} \quad (2-13)$$

式中， P_j 表示目标的位置与空间关系，表示为 $P_j = (x_j, y_j)$ ，其中 x_j, y_j 为目标坐标； L_j 表示目标类型，在开放战场中主要包括高价值目标和防御阵地； V_j 表示目标的战略价值，数值越大表示目标的重要性越高； D_j 是目标的防御能力，表示为需要摧毁该目标所需的火力资源； M_j 表示目标的动态性，反映目标状态变化情况。

通过建立信息向量的方式，每个目标的自身数学模型即可建立。需要特别说明的是，在目标态势中，防御阵地与高价值目标的特性具有显著差异。高价值目标主要以自身防御为主，对无人机的直接威胁较小，而防御阵地不仅具备较高的防御能力，还对无人机

的生存构成直接威胁。因此，需要对防御阵地的威胁特性进行特别建模，以便更准确地描述其对无人机的影响，为后续决策优化提供支持。

防御阵地的威胁不仅与自身属性相关，同时也与取决于以下因素：

d_{ij} ：第 i 架无人机与第 j 个防御阵地之间的距离；

R_j ：第 j 个防御阵地的威胁范围，其值越大，覆盖范围越广。

对于第 j 个防御阵地，拟将防御阵地对于无人机的摧毁能力描述为概率函数：

$$P_{ij} = \begin{cases} 1 - e^{\left(-\frac{R_j}{d_{ij}^2}\right)}, & d_{ij} \leq R_j \\ 0, & d_{ij} > R_j \end{cases} \quad (2-14)$$

当无人机 i 的位置在防御阵地 j 的威胁范围 R_j （即 $d_{ij} \leq R_j$ ）时，摧毁概率 P_{ij} 随距离的减小而增大。超出威胁范围 R_j 时，摧毁概率 P_{ij} 归零。

以图 2-3 所示的战场为例，将所有目标整合为总体态势模型。设敌方目标集合为 $\Pi = \{T_1, T_2, \dots, T_n\}$ ，则目标态势的数学模型表示为：

$$\Pi = \bigcup_{j=1}^n \{P_j, L_j, V_j, D_j, M_j\} \quad (2-15)$$




图 2-2 防御阵地对无人机集群的威胁关系示意图




图 2-3 某开放战场的目标示意图

态势模型能够为无人机提供精准的目标特性分析，支持任务优先级排序、资源分配优化和自适应杀伤链构建。模型通过动态性特性 M_j 适应战场变化，如目标状态更新或新目标出现，确保无人机决策具备实时性和灵活性。基于位置与空间关系、战略价值以及防御能力的综合评估，使得无人机集群能够优先打击高价值、低威胁目标，最大化作

战收益。

2.3 无人机集群作战资源模型

由多个无人机个体组成有组织、有规划的无人机集群是现代化战场的新质战斗力。在无人机集群作战中，无人机不仅需要执行各种任务，如打击、侦察、通信等，还必须管理和调度有限的资源。无人机集群作战资源指的是在集群执行任务过程中，为支持任务完成而需要的各种物理、信息和计算资源。资源是有限的且消耗随着时间推移，因此，合理的资源分配和管理是确保任务成功的关键。

2.3.1. 无人机质点模型

无人机质点模型是描述无人机集群运动与作战资源配置的基础模型。该模型将无人机视为具有质量和运动特性的质点，忽略其具体几何结构和气动细节，以简化动态分析和资源分配的复杂性。通过这种建模方式，可以更加聚焦于无人机在任务执行过程中的位置、速度和资源消耗等关键特性，为集群控制与决策提供理论支撑。

在建立无人机质点模型时，本文基于以下假设：

(1) 点质假设：将无人机视为质点，忽略其旋转、姿态变化等高自由度运动，仅考虑其在空间中的位置和速度变化。

(2) 均质假设：假设无人机的质量均匀分布，各无人机之间具有一致的动力学特性和资源消耗规律。

(3) 通信可达假设：无人机在通信范围内可与其他无人机保持稳定的数据传输，确保集群作战的实时性和可靠性。

无人机质点的运动状态可用三维位置 $P_i = (x_i, y_i, z_i)$ 和速度 $v_i = (v_{xi}, v_{yi}, v_{zi})$ 来描述。此外，假设无人机具有最大速度约束：

$$\|v_i\| \leq v_{\max} \quad (2-16)$$

该约束确保无人机在复杂战场环境中保持可控性和安全性。

无人机质点模型通过简化动力学和资源消耗描述，使得集群控制与规划计算量显著降低，适用于任务分配、路径规划和资源调度等应用场景。

2.3.2 无人机类型与集群资源

无人机作战类型资源指的是在执行任务时无人机所具备的不同核心功能与能力资源。这些资源决定了无人机在不同任务中的适应性和执行效果，在无人机集群的协同作战中发挥着不可或缺的作用。根据其作战任务和功能特点进行分类：

(1) 侦察无人机

侦察无人机是集群中的“眼睛”，其核心任务是情报收集与目标导引。由自身搭载配备的多种传感器，能够实时监测目标区域，提供高分辨率的地理与态势信息。一般而言，侦察特性包括有效侦察半径、分辨率和续航能力。目前，多用途侦察无人机的发展

如火如荼，以察打一体无人机为代表的侦察无人机被广泛应用于真实战场。在本研究中，侦察无人机主要用于探测敌方目标的数量与位置，更新目标态势，从而支持无人机集群的动态决策过程。

（2）通信无人机

通信无人机是集群中的“桥梁”，其任务是确保集群间及与指挥中心的通信畅通。其搭载高性能通信模块，可以实时传输任务信息、作战指令和感知数据，在高动态环境中维持集群的协调性与作战效率。通信特性包括通信带宽、抗干扰能力和覆盖范围等关键指标。

目前，通信无人机广泛应用于复杂作战环境，尤其是在电磁干扰强烈或地面通信基础设施受限的情况下，通信无人机能够充当空中通信中继节点，为无人机集群提供强有力的通信保障。在本研究中，通信无人机主要用于维持集群内部的协同工作与数据共享，并在通信中断或环境干扰情况下提供补救支持，从而确保任务顺利执行。

（3）攻击无人机是集群中的“矛”，其核心任务是完成对敌方目标的精确打击。攻击无人机通过搭载多种弹药（如精确制导炸弹、导弹等），具备远程打击和精准摧毁的能力，能够对敌方高价值目标和威胁性防御阵地实施致命攻击。攻击特性包括载荷能力、打击精度和射程范围等关键指标。

近年来，以高机动性和高精度为特点的攻击无人机技术发展迅速，察打一体无人机的广泛应用进一步增强了无人机在战场上的综合能力。在本研究中，攻击无人机主要用于摧毁敌方高价值目标和防御阵地，削弱敌方战斗力，并为其他无人机提供安全的作战环境，从而实现作战效能的最大化。

在实际作战中，无人机集群的配置需要综合考虑任务需求、作战环境和资源约束，以最大化作战效能。在本研究中，无人机集群的基本配置由以上三类无人机构成：通信无人机、侦察无人机和攻击无人机，如图 2-4 所示。




图 2-4 无人机集群作战资源配置图

配置无人机作战集群资源应满足以下条件：至少部署一台通信无人机作为基础配置，确保指令与数据的实时传递。在大规模或分散区域作战中，可部署多台通信无人机以增

强覆盖范围，提升抗干扰能力。侦察无人机是集群感知系统的关键组成部分，用于探测导引目标和更新态势信息。至少一台侦察无人机参与配置，以保障实时监控和情报收集。攻击无人机是执行打击任务的主要力量。其数量根据任务需求灵活配置，可视作集群的可扩展模块。对于目标密集或威胁较大的区域，增加攻击无人机的数量能够显著提升打击效能和任务完成度。

设无人机集群配置为集合 C ，则：

$$C = \{U_c, U_r, U_a\} \quad (2-17)$$

其中： U_c 表示通信无人机集合，应满足 $U_c \geq 1$ ； U_r 表示侦察无人机集合，应满足 $U_r \geq 1$ ； U_a 表示攻击无人机集合，应满足 $U_a \geq 0$ 。

无人机集群在任务执行过程中可基于实时情报与资源消耗情况调整配置。对于高动态战场环境，通信无人机数量可能增加以确保网络的稳定性；对于隐蔽的高价值目标区域，可增加侦察无人机的部署数量；对于高强度打击任务，则需大量配置攻击无人机以提升打击效率。

2.3.3 无人机作战资源数学模型

在无人机集群作战任务中，作战资源直接影响任务完成效率与成效。为了定量描述这些资源及其约束条件，需要对侦察资源、通信资源和攻击资源分别建模，并定义其核心参数及表达方式。

根据无人机的作战功能，可将其资源划分为以下三类：侦察资源、通信资源和攻击资源。每类资源都具有其独特的关键参数，这些参数不仅反映了资源的性能，还对任务执行过程中的约束和优化具有重要影响。具体定义如下：

（1）侦察资源 U_r

- ①有效侦察半径：侦察无人机能够有效探测目标的最大距离。
- ②分辨率：反映侦察数据的清晰度和精准度。
- ③探测能力：反映无人机在目标区域中识别目标的能力，通常表示为单位时间内探测到的目标数量。

（2）通信资源 U_c

- ①网络覆盖范围：无人机通信设备覆盖的半径范围，决定了与其他无人机或基地的通信能力。
- ②通信带宽：反映信息传输速率和容量。
- ③抗干扰能力：通信过程中面对敌方干扰时保持信息传输稳定的能力。

（3）攻击资源 U_a

- ①弹药数量：无人机携带的武器数量。
- ②打击半径：攻击武器能够覆盖的有效作战范围。
- ③命中概率：单次攻击对目标的命中概率。

基于以上不同资源的功能化分，为描述集群中单个无人机的作战资源，定义如下数学模型：

$$U = \{U_1, U_2, \dots, U_n\} \quad (2-18)$$

其中： n 为无人机数量。

每个无人机的资源定义为：

$$U_i = \{P_{Ui}, L_{Ui}, D_{Ui}, A_{Ui}\} \quad (2-19)$$

其中： P_{Ui} 表示无人机位置，描述其当前坐标； L_{Ui} 表示无人机类型，区分侦察、通信和攻击功能； D_{Ui} 为功能执行距离，具体地，对于侦察无人机， D_{Ui} 表示侦察半径；对于通信无人机， D_{Ui} 表示通信范围；对于攻击无人机， D_{Ui} 为武器攻击距离； A_{Ui} 为进攻能力，对于侦察和通信无人机而言，其自身并不具备攻击能力，表示为 $A_{Ui} = 1$ ，即具备自杀式攻击能力。对于攻击无人机而言，表示为 $A_{Ui} = n_{mis} + 1$ ， n_{mis} 是攻击机携带弹药的数量，即完成弹药攻击后具备自杀式攻击能力。

在无人机集群作战任务中，各类资源不仅需要明确描述其性能指标，还需充分考虑实际应用中的约束条件。这些约束源于资源的物理容量限制、作战环境需求，以及任务动态变化带来的资源消耗与分配策略。具体而言，每种资源均具有固定的容量上限 ($C_{\max}$)，即：

$$\begin{cases} U_r \leq C_{r,\max} \\ U_c \leq C_{c,\max} \\ U_a \leq C_{a,\max} \end{cases} \quad (2-20)$$

其中： $C_{r,\max}$ 为侦察资源的最大可用范围，在此用集群可用侦察无人机的最大数量表示； $C_{c,\max}$ 为通信资源的容量限制，用通信无人机的数量表示； $C_{a,\max}$ 为攻击资源的上限，资源分配时使用攻击机的携带弹药量表示。

这些约束条件不仅限制了资源的分配与使用，还对集群任务的整体规划与决策提出了更高的要求。在动态战场环境中，如何高效地分配和调整这些资源是无人机集群任务优化的核心问题之一。

2.4 无人机集群目标攻击杀伤链模型

在无人机集群作战任务中，侦察无人机、通信无人机和攻击无人机各自扮演着至关重要的角色，它们通过协同作战共同完成对目标的攻击任务。导引无人机负责提供目标信息并通过通信无人机传递至攻击无人机，最终由攻击无人机执行目标摧毁。此作战模式中的任务协同与资源配置对集群作战效率与成功率起着关键作用。

2.4.1 攻击条件与杀伤链模型

为了有效地摧毁目标，作战资源必须满足特定的条件。对于无人机集群，侦察无人机和通信无人机为攻击无人机摧毁目标提供战场支援：侦察无人机在其导引锁定目标范围内提供不间断的目标信息，并通过通信无人机传递给攻击无人机，最后由攻击无人机

发射武器来摧毁目标。因此，完成对目标的攻击需要满足如下条件：

$$\begin{cases} R_{U_r T_j} \leq D_{U_r} \\ R_{U_a T_j} \leq D_{U_a} \\ R_{U_c U_r}, R_{U_c U_a} \leq D_{U_c} \\ \sum A_{U_{ai}} \geq D_{T_j} \end{cases} \quad (2-21)$$

其中： $R_{U_r T_j}$ 表示侦察无人机与第 j 个目标的距离； D_{U_r} 表示该侦察无人机的目标导引范围； $R_{U_a T_j}$ 表示攻击无人机与第 j 个目标的距离； D_{U_a} 表示该攻击无人机的武器攻击距离； $R_{U_c U_r}$ 和 $R_{U_c U_a}$ 分别表示通信无人机与侦察无人机和攻击无人机的距离； D_{U_c} 表示通信无人机的通信距离； $A_{U_{ai}}$ 表示第 i 个攻击无人机的进攻火力； D_{T_j} 表示第 j 个目标防御能力。

上述不等式条件可以归纳为实现攻击第 j 个目标的协同作战要求：

(1) 攻击目标 T_j 必须至少有一架侦察无人机和一架攻击无人机，以确保信息的传递与任务的执行；

(2) 目标攻击必须由侦察无人机、通信无人机和攻击无人机组成有效的杀伤链或杀伤网，这意味着各类无人机必须在一定范围内互相协同，确保目标信息的实时传递和武器的精确打击。

(3) 集群中所有参与攻击的无人机，其攻击火力总和须大于目标的防御能力。

2.4.2 无人机作战决策模型

在集群任务中，每类无人机的飞行决策与作战行为基于集群的群体决策模型进行协同。这些行为决定了无人机如何协作、如何分配资源以及如何完成摧毁目标任务。具体而言，以下是各类无人机的飞行决策模型：

(1) 通信无人机

通信无人机的首要任务是保持无人机集群之间的通信联络。在飞行过程中，它应尽量规避敌方防御阵地，避免受到威胁，确保任务信息能够实时传递。一旦进攻无人机的攻击资源耗尽，通信无人机将转入进攻状态，与攻击无人机组协同进行自杀式攻击。

(2) 侦察无人机

侦察无人机负责目标信息的提供与传递。根据集群决策结果，侦察无人机飞向目标区域，并在目标周围进行绕飞或悬停。侦察无人机通过其传感器实时监控目标信息，并将这些信息传递给通信无人机，最终传输给攻击无人机。

(3) 攻击无人机

攻击无人机根据集群决策结果，飞向目标并发射机载武器摧毁目标。在接收侦察无人机传递的目标信息后，攻击无人机开始进入打击状态，并根据预定攻击方式实施精准打击。

根据以上协同作战机制和决策模型，明确了不同类型无人机之间的任务分配与相互配合，以及如何在动态战场环境中实现资源的最优配置和目标的成功摧毁。通过这些协

同策略的制定和优化，无人机集群能够更高效地完成复杂的战术任务，增强作战效能。

2.5 本章小结

本章建立了开放战场态势模型，首先基于敌方目标特性对目标态势进行数学建模，给出了本文所研究的敌方目标数学模型，详细分析了敌方目标的特性及其对作战决策的影响。在此基础上，提出了无人机集群作战资源模型，并对侦察、通信和攻击资源进行了定量建模，明确了资源约束条件与分配机制。进一步，章中探讨了无人机集群的作战策略与飞行决策模型，阐明了通信、侦察和攻击无人机在协同作战中的角色与任务分配。特别地，通过设定攻击条件与杀伤链模型，明确了各类无人机如何在目标摧毁任务中协同作战，实现资源的高效利用与任务目标的成功达成，为后续的无人机集群自主决策与作战优化提供了理论框架与基础模型。

第3章 动态战场下的摧毁目标决策和区域目标分群

高效处理众多目标是无人机集群自主决策的前提条件，在建立目标态势数学模型的基础上，本章对开放战场环境下众多目标进行评价筛选。考虑各种类型目标的综合价值，将高价值目标纳入摧毁目标集。进而将目标集按照区域和属性分群，力求各目标群内区域紧凑且任务量均衡，为后续无人机集群任务分配奠定基础。

3.1 摧毁目标集决策与区域目标分配问题描述

在动态战场环境下，无人机集群的作战目标是尽可能摧毁高优先级敌方目标，同时优化资源分配，以应对高动态复杂战场态势。为实现这一目标，本节从摧毁目标决策和区域目标分配的角度建立数学模型，明确问题的关键要素及其相互关系。主要建模目标包括：

(1) 摧毁目标决策：在目标数量超过集群资源能力的情况下，根据目标的重要程度、威胁程度、防御程度等因素，将战场上的目标划分为摧毁目标集和非摧毁目标集。

(2) 目标集区域划分：对摧毁目标决策得到的目标集进行区域划分，基于无人机资源类型特点（侦察、通信、攻击）、分布特性和任务均衡性为各目标合理区域分群，确保完成任务的同时优化资源利用。

3.1.1 摧毁目标集决策问题描述

根据无人机群体作战资源与敌方重要目标态势的数学模型，战场每个敌方目标信息均可由 $T_j = \{P_j, L_j, V_j, D_j\}$ 来表征。考虑到无人机的续航能力基本能够覆盖所处战场，因此在进行摧毁目标决策时，主要考虑的信息为 $\bar{T}_j = \{L_j, V_j, D_j\}$ ，同时对于选择摧毁的目标集防御能力应小于无人机集群整体的进攻能力。基于智能决策的摧毁目标决策所实现的功能展示如图 3-1 所示：




图 3-1 摧毁目标决策示意图

由此，摧毁目标决策可以转化为如下二分类问题：

给定目标信息样本集： $\overline{T}_j = \{\overline{T}_1, \overline{T}_2, \dots, \overline{T}_j, \dots, \overline{T}_m; \overline{T}_j = (L_{T_j}, V_{T_j}, D_{T_j}) \in R^3\}$ ，将其划分为两簇，并满足：

$$\begin{cases} \overline{T} = \{\overline{T}_Y, \overline{T}_N\} \\ \overline{T}_Y \neq \emptyset \text{ 且 } \overline{T}_N \neq \emptyset \\ \overline{T}_Y \cup \overline{T}_N = \overline{T} \\ \overline{T}_Y \cap \overline{T}_N = \emptyset \\ \sum_{\overline{T}_Y} X_T \leq \sum_U A_U \end{cases} \quad (3-1)$$

相应的特征函数形式为：

$$D(\overline{T}_i, \overline{T}_j) = F(V_{T_i}, D_{T_i}, V_{T_j}, D_{T_j}, \eta) \quad (3-2)$$

式中， η 为“距离”度量可调参数矢量。

3.1.2 目标集区域划分

通过摧毁目标决策，战场目标可分为摧毁目标和非摧毁目标，无人机集群区域目标分配则主要针对摧毁目标集。在无人机集群实施攻击的过程中，考虑到如下因素：

- (1) 攻击每个目标均需要构成侦察无人机、通信无人机和攻击无人机的杀伤网；
- (2) 相比于攻击无人机，侦察无人机和通信无人机的数量相对较少；
- (3) 侦察无人机的侦察锁定距离明显低于通信无人机的通信距离。

因此，无人机区域目标分配决策将以侦察无人机为聚类中心，首先对摧毁目标集进行智能划分，然后根据摧毁目标集的分群结果进一步对攻击无人机进行划分，通信无人机提供通信保障，当攻击无人机进攻资源耗尽后，编入攻击无人机组，与侦察无人机一起进行自杀式攻击。

以侦察无人机为聚类中心，摧毁目标集的智能划分所实现的功能如下：




图 3-2 摧毁目标集的划分结果示意图

由于每个目标的摧毁均需侦察无人机进行抵近锁定，因此，在进行以侦察无人机为聚类中心，摧毁目标集的智能划分时，与摧毁目标决策不同，目标的位置信息必须引入至智能划分中的“距离”度量中。对于摧毁目标集 $\overline{T_Y}$ ，扩充目标位置信息，得到 $T_Y = \{T_1, T_2, \dots, T_j, \dots, T_l; T_j = (P_{Tj}, L_{Tj}, V_{Tj}, D_{Tj}) \in R^5\}$ ，其中 l 为摧毁目标集的目标数量， P_{Tj} 表征目标在二位平面内的位置矢量。此时，智能聚类划分问题可以描述为：

$$\begin{cases} T_Y = \{B_1, B_2, \dots, B_k\}, k < l \\ B_i \neq \emptyset, i=1, 2, \dots, k \\ \bigcup B_i = T_Y \\ B_i \cap B_j = \emptyset, i, j = 1, 2, \dots, k \text{ 且 } i \neq j \end{cases} \quad (3-3)$$

式中， k 为侦察无人机数量。

相应的特征函数形式为：

$$D(T_i, T_j) = G(U_d, P_{Ti}, V_{Ti}, D_{Ti}, P_{Tj}, V_{Tj}, D_{Tj}, \delta) \quad (3-4)$$

式中， U_d 表征导引无人机集群信息； δ 为“距离”度量可调参数矢量。

通过以侦察无人机为聚类中心，摧毁目标集的智能聚类划分，摧毁目标集被划分为与侦察无人机一一对应的区域目标集 B_i 。

3.2 基于随机森林算法的摧毁目标集决策

3.2.1 随机森林算法原理

随机森林（Random Forest, RF）是一种基于集成学习（Ensemble Learning）思想的监督学习算法，广泛应用于分类和回归任务中。该算法通过构建多个决策树并结合投票或平均预测结果的方式，有效提高了模型的泛化能力和预测精度，具有较强的鲁棒性和抗过拟合能力^[85]。

随机森林算法的核心思想是通过“随机采样”和“集成学习”实现多模型协同训练，从而提升模型性能。首先采用自助采样法（Bootstrap Sampling）从原始训练集随机抽取多个子集，允许重复抽样，以形成多个训练样本集。随后在每棵决策树的训练过程中，随机从全部特征中选择一个子集，并基于该子集进行分裂节点的选择，以减少相关性并增强模型多样性。之后基于采样得到的训练集和特征子集，构建多棵相互独立的决策树，每棵树单独训练，并对输入样本做出预测。对于分类任务而言，采用“多数投票法”确定最终分类结果；对于回归任务，采用“平均值法”作为最终输出结果。

随机森林作为一种基于决策树的集成学习算法，具有以下优势：

- （1）能够处理非线性和多维特征的数据；
- （2）对于特征之间的重要性具有良好的解释能力；
- （3）在训练过程中可以内置对随机性的处理，适合动态环境中的数据变化；

因此，引入随机森林算法对目标集进行分类决策，决策模型如图 3-3 所示。




图 3-3 基于 RF 的摧毁目标集决策模型

3.2.2 基于 RF 实现目标集决策

基于 3.1.1 摧毁目标集决策问题描述节摧毁目标集决策模型，由于目标属性间存在显著的非线性关系，传统规则化分类方法难以有效处理。将随机森林算法用于无人机集群对地目标摧毁任务的目标集划分，包括提取目标的空间位置、威胁程度、防御能力等特征数据，构建训练集和测试集，之后通过随机森林算法学习目标特性，完成目标分类，将目标划分为摧毁目标集与非摧毁目标集，为后续任务规划提供输入。

为了使数据适合随机森林模型的训练和推断，需要对原始数据进行以下处理：

（1）特征归一化

由于目标的战略价值 V_j 和防御能力 D_j 的取值范围可能不同，为避免不同量纲的特征在模型训练中产生偏差，需要对这些数值型特征进行归一化处理。归一化方法为：

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)} \quad (3-5)$$

其中： x 为特征原值； $\min(x)$ 、 $\max(x)$ 分别表示特征的最小值和最大值。

（2）类别型变量编码

对于目标类型 L_j 这样的类别型变量，需要通过编码转换为数值形式，在此选择独热编码的方式，即为每个类别分配一个独立的二进制特征。以常见的两种类型防御阵地（type=1）和指挥所（type=2）为例，其编码结果为：

$$\begin{cases} \text{type} = 1 \rightarrow [1, 0] \\ \text{type} = 2 \rightarrow [0, 1] \end{cases} \quad (3-6)$$

（3）数据清洗

检查数据集中是否存在缺失值或异常值，对缺失值可采用插值处理，对异常值则通过 Z-Score 检测进行识别和修正。使用的插值和检测方法如下：

①线性插值

$$x_k = x_i + \frac{k-i}{j-i}(x_j - x_i) \quad (3-7)$$

式中, x_k 为待插值的缺失点; x_i, x_j 为缺失点两侧的已知值; i, j 为已知值的索引位置; k 为缺失值的索引。

②Z-Score 检测方法处理异常值

给定特征列的数据集 $x_1, x_2, \dots, x_n$, 计算每个数据点的 Z-Score:

$$Z_i = \frac{x_i - \mu}{\sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2}} \quad (3-8)$$

式中, Z_i 表示第 i 个数据点的标准分数; x_i 为第 i 个数据点的值; μ 是特征列的均值。

通常情况下, 若数据点的 $|Z_i| > 3$, 则认为该点是异常值, 使用特征列的中位数代替异常值。

将数据集划分为训练集 (70%) 和测试集 (30%), 确保模型泛化能力。训练样本使用模拟生成的战场目标数据, 构成敌方目标的属性数据集 $\bar{T}_j$, 模型输出为目标分类标签 $\bar{Y}_j$:

$$\bar{Y}_j = \begin{cases} 1, & \bar{T}_j \in T_Y \\ 0, & \bar{T}_j \in T_N \end{cases} \quad (3-9)$$

RF 并联地创建多个决策树模型, 每个决策树模型之间是相互独立的, 使用相同训练样本集。在构建决策树模型时, 每棵决策树利用 Bootstrap 抽样方法从训练样本集中进行有放回的随机抽样, 生成新的训练样本集, 同时随机选取训练样本集的部分特征组成新的特征向量进行训练。每棵决策树的训练样本和特征各不相同, 因此得出的训练结果也不相同, 提高了模型的鲁棒性和泛化能力。决策树在生成过程中不进行剪枝处理。假设训练样本数据集的容量为 n , 则 RF 创建决策树的具体流程如算法 1 所示。

算法 1 RF 创建第 k 棵决策树算法

输入: 训练样本集 $\bar{T}_j = \{\bar{T}_1, \bar{T}_2, \dots, \bar{T}_m\}$, 最大深度和最大特征数。

1. 利用 Bootstrap 抽样方法从训练样本集中进行有放回的随机抽取第 k 个训练样本, 抽取的样本容量和输入的原训练样本相同;
2. 随机抽取特征向量子集, 选择最优的特征属性;
3. 根据当前选择的最优特征属性, 将数据集划分成两个部分, 建立当前节点的左、右子节点;
4. 判断决策树训练是否结束, 若训练结束, 则生成第 k 棵决策树; 否则, 对左、右子节点递归调用第 1~3 步。

输出: 第 k 棵完整的分类决策树。

通过分析创建决策树算法流程可以发现, RF 模型在构建过程中, 为了保证森林中决策树的多样性, 需要对训练数据执行随机抽样操作。这既包括对样本的随机选择, 也有对特征的随机选择。随后, 根据最优特征属性进行节点的构建。决策树构造节点的过程如图 3-4 所示, 其分裂依据是基尼系数最小化原则。




图 3-4 决策树节点分裂流程图

基尼系数是一种用于衡量系统混乱程度的指标，其计算公式如下：

$$Gini(D) = 1 - \sum_{i=1}^m p_i^2 \quad (3-10)$$

式中， p_i 是类别为 i 的样本在样本集 D 中出现的概率。使用选择的属性进行分类后的基尼系数公式为：

$$Gini(D) = \frac{s_1}{s_1 + s_2} Gini(D_1) + \frac{s_2}{s_1 + s_2} Gini(D_2) \quad (3-11)$$

式中， s_1 、 s_2 是划分成两类的样本量， $Gini(D_1)$ 和 $Gini(D_2)$ 分别为划分后的两个类别的基尼系数。

基尼系数的值越高，标志着系统的混乱程度越严重。决策树的构建过程通过不断选择最优属性进行节点分裂，从而逐步划分样本，减少训练样本集的混乱度，最终实现将同类别的样本归类到同一节点。

3.3 基于粒子群优化算法的目标集区域划分

由随机森林算法得到摧毁目标集信息，考虑到无人机实施任务过程中以集群方式进行打击，故而无人机集群需要根据战场目标的属性、位置和战略价值对目标集进行合理区域划分，以便实现高效的任务分配和目标摧毁。由于目标状态及任务环境的动态变化，传统的目标区域划分方法（如 K-means）往往难以适应目标属性的变化，陷入局部最优，而粒子群优化（Particle Swarm Optimization, PSO）算法作为一种全局优化算法，具有良好的动态适应性和全局搜索能力，本节采用 PSO 算法，对目标集进行区域划分。

3.3.1 PSO 算法原理与设计

PSO 算法起源于对鸟群或鱼群等群体捕食行为的观察和研究，大自然中这些生物群体所展现出的高度协作性与高效适应性引发了研究者的深刻思考。该算法于 1995 年由 Kennedy 与 Eberhart 提出^[86]，后经过不断的修改，逐渐完善。其核心思想是通过巧妙模拟粒子群体在复杂解空间中的协作与竞争动态过程，逐步且高效地逼近全局最优解。都被视为一个潜在的问题解决方案，它们凭借自身过往的运动经验以及从群体中获取的共享经验，持续不断地灵活调整自身的位置和速度，逐渐向目标函数的最优解靠拢，最终实现收敛。PSO 算法具有全局搜索能力和较快的收敛速度，在实际问题中得到了广泛应用。

假设 PSO 算法中有 N 个粒子，每个粒子在搜索空间中有 D 个维度。每个粒子的位置用一个 D 维向量表示，表示第 i 个粒子在每个维度上的位置，记为：

$$x_i = (x_{i1}, x_{i2}, x_{i3}, \dots, x_{iD}) \quad (3-12)$$

每个粒子还有一个 D 维速度向量， v_i 表示第 i 个粒子在每个维度上的速度。如下式所示：

$$v_i = (v_{i1}, v_{i2}, v_{i3}, \dots, v_{iD}) \quad (3-13)$$

PSO 算法的核心是粒子群之间紧密的合作以及高效的信息共享机制。每个粒子通过个体经验和群体经验两个方面来更新自己的速度和位置。粒子根据自己的适应度函数值来评估自己的个体经验，即当前位置对应的适应度值。同时，粒子还会考虑群体中所有粒子的最优位置对应的适应度值，称为群体经验。个体经验和群体经验都会影响粒子的速度和位置更新。

粒子的速度和位置更新公式如下：

$$v_{id(t+1)} = \omega * v_{id(t)} + c_1 * r_1 * (p_{id(t)} - x_{id(t)}) + c_2 * r_2 * (p_{gd(t)} - x_{id(t)}) \quad (3-14)$$

$$x_{id(t+1)} = x_{id(t)} + v_{id(t+1)} \quad (3-15)$$

其中： ω 为惯性权重； c_1 和 c_2 为加速因子； r_1 和 r_2 为 0 到 1 之间的随机数； $p_{id(t)}$ 为第 i 个粒子的个体最优位置； $p_{gd(t)}$ 为整个群体的最优位置； $v_{id(t+1)}$ 表示第 i 个粒子在第 d 个维度上的速度更新值； $x_{id(t+1)}$ 表示第 i 个粒子在第 d 个维度上的位置更新值。

惯性权重 ω 的计算公式如下：

$$\begin{cases} \omega = \mu + \sigma \cdot N(0,1) \\ \mu = \mu_{\min} + (\mu_{\max} - \mu_{\min}) \cdot rand(0,1) \end{cases} \quad (3-16)$$

在算法的初始阶段，需要随机初始化每个粒子的位置和速度，并将每个粒子的个体最优位置初始化为当前位置。在迭代搜索过程中，根据适应度函数值的变化，不断更新粒子的速度和位置。每个粒子根据自己的个体经验和群体经验来更新速度和位置，从而逐渐趋向于全局最优解。

3.3.2 PSO 算法实现目标集区域划分

在目标集区域划分中,研究目标是基于战场中目标点的分布特性,对目标进行合理的区域划分。结合 PSO 算法特点可以建模为一个优化簇中心的位置问题,通过优化簇中心的选择和分布,最小化目标点到其所属簇中心的距离和,同时满足特定的约束条件。

粒子群优化算法中的每个粒子 x_i 表示一个可能的解。在本问题中,粒子的位置表示为一个区域中心的坐标集合:

$$x_i = \{C_1, C_2, \dots, C_k\} \quad (3-17)$$

其中: $C_k = (x_k, y_k)$ 表示第 j 个区域中心的二维空间坐标,在战场上表示目标群中心的位置; k 为所分区域的数量。

为了衡量区域中心位置的优劣,设计适应度函数如下,其目标是 minimized 所有目标点到其所属区域中心的距离、同时考虑目标价值和防御力,从而确保目标点分配的合理性和区域划分的紧凑性。

$$f = \sum_{i=1}^N \min_j (\omega_p \|T_i - C_j\|^2 + \omega_v v_i + \omega_d d_i) \quad (3-18)$$

式中: $T_i = (x_i, y_i)$ 表示第 i 个目标点的位置坐标; $C_j = (x_j, y_j)$ 表示第 j 个簇中心的位置; ω_p 、 ω_v 、 ω_d 分别表示空间距离、目标价值以及目标防御力的权重系数; N 为目标集内所有目标的总数;

适应度函数在区域划分时不仅考虑了目标位置,让每个目标点都被分配到距离最近的簇中心,从而减少区域内目标点的空间分散性,同时还考虑价值和防御力,通过调整权重 ω_p 、 ω_v 和 ω_d ,可以灵活地在空间距离和目标属性之间进行权衡,显著提高目标区域划分的合理性和实用性。

考虑到动态战场环境的复杂性,同时提高目标区域划分的合理性与任务分配效率,本研究在目标划分中引入以下约束条件。这些约束条件的设计旨在充分利用目标的多维属性,优化资源分配并保证算法的适应性。

(1) 区域中心优先选则高价值目标

在动态战场中,高价值目标往往具有更高的战略重要性,需要优先被纳入划分区域的中心点,以保障战场资源的高效利用。约束条件定义为每个目标群的初始中心必须从高价值目标点集合中选择,即:

$$C_j \in \{T_j \mid L_j = 2\}, j = 1, 2, \dots, k \quad (3-19)$$

其中: C_j 表示第 j 个区域的中心; T_i 表示目标集中的第 i 个目标点; k 为区域的数量。

在适应度函数计算过程中,目标点 T_i 的初始分配依据其到区域中心 C_k 的距离,同时高价值目标点更倾向于作为中心点,以降低整体距离和,提高分配合理性。

(2) 区域内目标数量均衡

战场目标划分的均衡性对于无人机集群的任务分配效率具有重要意义。如果某些区域内目标数量过多，可能导致无人机任务超载；而某些区域内目标过少，则可能造成资源浪费。约束条件应确保各划分区域内目标数量尽量均衡，假设将目标集划分为 k 个区域，数学表达如下：

$$|S_j| \approx \frac{N}{k}, \quad j=1,2,\dots,k \quad (3-20)$$

其中： S_j 表示区域 j 内的目标点集合； N 表示战场目标点的总数量。

每次迭代中，通过计算每个区域内的目标数量，当区域内数量偏离理想值时，更新区域中心位置以减少偏差。

(3) 动态调整区域中心

由于动态事件的影响，目标点的位置及状态皆可能随时间变化。为了适应这种动态变化，区域中心需要根据当前目标点的分布和状态变化不断调整，以保持区域划分的有效性。在每次迭代中，重新计算区域中心的位置。新的区域中心 C_j 由区域内所有目标点的几何中心决定：

$$C_j = \frac{1}{|S_j|} \sum_{P_i \in S_j} P_i \quad (3-21)$$

其中： C_j 表示第 j 个区域的中心； S_j 表示区域 j 内的目标点集合； $|S_j|$ 表示区域 j 内的目标点数量； $P_i = (x_i, y_i)$ 为目标点的二维坐标。

动态调整区域中心的位置，具体包括：重新计算每个区域内目标点集合 S_j ，根据集合内目标点的分布更新区域中心 C_j ，将更新后的区域中心作为下一轮迭代的输入。通过动态调整区域中心，适应度函数的优化目标不断逼近全局最优解，减少目标点到区域中心的整体距离和。

根据 PSO 算法的设计，为实现基于粒子群优化算法的目标集区域划分，实验流程设计了一个完整的优化迭代过程，实验流程图如图 3-5 所示，主要包括初始化、目标分配、区域中心更新和迭代停止判定四个步骤。每一步都围绕优化区域中心位置这一核心目标展开，确保最终的区域划分结果合理且具有收敛性。

首先，在初始化阶段，为了确定区域中心的初始位置，从目标点中筛选出高价值目标点，这些点具有更高的战略重要性。随后，从筛选出的高价值目标点集合中随机选择 k 个点作为初始区域中心。与此同时，粒子群的速度和位置也被初始化，其中粒子的位置由区域中心的坐标组成，这一步骤为 PSO 的迭代优化提供了基础。

进入目标分配阶段，实验通过计算每个目标点到所有区域中心的欧几里得距离，完成目标点到簇的归属分配。具体而言，对于每个目标点 T_i ，通过计算目标点 T_i 到区域中心的距离，并将目标分配到距离最小的区域中心对应的簇 S_j 。此过程确保了目标点与区域中心的分配关系依据距离最优原则，从而初步实现了合理的目标点分群。




图 3-5 基于 PSO 算法的目标集区域划分流程

完成目标分配后，需要对区域中心进行更新，以更好地反映区域内目标点的分布情况。在这一阶段，对于每个区域 S_j ，将区域内所有目标点的几何中心作为新的区域中心。新区域中心的位置由公式 3-21 计算。通过这种更新机制，新区域中心的位置能够更加贴近区域内目标点的分布，从而减少区域内的目标点分散性，提高分群结果的紧凑性和合理性。更新后的区域中心将作为下一轮迭代的输入，以进一步优化目标点的划分结果。

为了控制算法的运行时间并确保收敛性，设置了明确的迭代停止条件。在每次迭代中，计算当前迭代的区域中心位置与上一轮迭代的变化幅度 ΔC_j ，其公式为：

$$\Delta C_j = \|C_j^{(t+1)} - C_j^{(t)}\| \quad (3-22)$$

当所有簇中心的变化幅度小于设定的收敛阈值或迭代次数达到最大值时，算法停止运行并输出最终的划分结果。如果上述条件均不满足，则返回目标分配步骤，继续进行下一轮优化。

通过上述流程设计，PSO 算法能够逐步优化区域中心位置，提高目标区域划分的合理性与效率。优化结果不仅具有良好的分布特性，还能够适应动态战场的需求，为无人机群的任务分配提供了可靠的基础。

3.4 面向动态事件的近端策略优化目标分群

PSO 算法虽然能够通过迭代优化区域中心的位置提升分群效果，但其在动态环境下的表现仍有不足。然而，动态战场环境中目标的分布和属性可能随着时间发生变化，例如高价值目标的出现、普通目标的损毁、或任务优先级的调整。PSO 无法直接处理目标属性随时间变化的情况，且其收敛速度和全局优化能力受限于参数设置和初始解的质量。这些不足表明，传统方法在处理动态战场环境中的目标分群问题时，缺乏足够的灵活性和自适应能力。

近端策略优化（Proximal Policy Optimization, PPO）算法作为强化学习中的一种在线学习方法，具有显著的优势，能够有效弥补传统方法的不足。PPO 是一种基于策略的强化学习算法，通过优化策略网络的参数，直接生成决策策略^[87]。与传统方法相比，PPO 在动态环境中具有更强的适应能力和鲁棒性。本节将提出基于时间动态的近端策略优化目标分群方法，针对战场目标的分布特征和任务需求将目标点划分为若干区域问题，实现动态战场环境下对目标区域的实时优化，同时兼顾分群的紧凑性、均衡性和重要目标的优先性，确保无人机集群能够高效完成任务。

3.4.1 PPO 算法原理与优势

近端策略优化算法是一种基于策略梯度的强化学习方法，其在动态环境中表现出的稳定性和高效性，使其成为解决复杂决策问题的理想选择。策略梯度算法的核心思想是，通过最大化期望回报来优化策略，而不是像值函数算法那样先求解值函数再从值函数中得到策略。策略梯度算法的优点是可以直接优化策略，不要求解值函数，能够应对高维、连续动作空间等复杂情况。

PPO 算法的核心思想是通过限制策略更新的幅度，保证策略优化的稳定性。与传统的策略梯度方法不同，PPO 在优化目标函数时引入了裁剪（Clipping）机制，通过约束策略变化的范围，防止策略的过度更新导致训练不稳定。具体而言，PPO 的优化目标函数定义为：

$$L^{CLIP}(\theta) = \mathbb{E}_t[\min(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon)\hat{A}_t)] \quad (3-23)$$

式中， $r_t(\theta)$ 是一个关于策略参数 θ 的函数，表示当前策略在状态 s_t 下采取动作 a_t 的概率与旧策略在状态下采取动作 a_t 的概率之比， $r_t(\theta)$ 越大，表示当前策略在状态 s_t 下采取动作 a_t 的概率越大，相对于旧策略来说更新幅度也就越大。具体地， $r_t(\theta)$ 的定义如下：

$$r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)} \quad (3-24)$$

$\hat{A}_t$ 为优势函数，衡量当前状态和动作相对于平均策略的优劣程度。它表示当前状态和动作的价值与平均价值的差值，用于计算近端比率裁剪损失中的裁剪幅度。优势函数的定义如下：

$$\hat{A}_t = Q_{\pi_{\theta_{old}}}(s_t, a_t) - V_{\pi_{\theta_{old}}}(s_t) \quad (3-25)$$

其中： $Q_{\pi_{\theta_{old}}}(s_t, a_t)$ 表示在状态 s_t 下采取动作 a_t 的价值， $V_{\pi_{\theta_{old}}}(s_t)$ 表示在状态 s_t 下的平均价值。优势函数的值越大，表示当前状态和动作越优秀，应该得到更大的奖励。 ϵ 是超参数，用于控制裁剪幅度； $\text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon)$ 为裁剪操作，用于限制概率比值的更新范围。

上述目标函数通过裁剪操作，在优化策略时平衡探索与稳定性。当策略更新过大，即 $r_t(\theta)$ 超出 $[1-\epsilon, 1+\epsilon]$ 时，将其限制在该区间内，从而避免策略更新过度导致性能波动。

同时，PPO 还采用多次采样更新策略，即在每次策略迭代中多次更新参数，提高优化效率。

为了增强对环境动态变化的感知能力，PPO 结合了值函数 $V(s)$ ，用于评估当前状态的价值。值函数通过最小化以下损失函数进行优化：

$$L^V(\theta) = \frac{1}{2} \mathbb{E}_t[(V_\theta(s_t) - \hat{V}_t)^2] \quad (3-26)$$

其中： $V_\theta(s_t)$ 为状态 s_t 的预测价值； $\hat{V}_t$ 为目标价值，由奖励和折扣因子计算得到。

为了进一步提升算法的性能，PPO 结合了多项优化目标，最终的总损失函数可以表示为：

$$L(\theta) = L^{CLIP}(\theta) - c_1 L^V(\theta) + c_2 S[\pi_\theta] \quad (3-27)$$

其中： c_1 和 c_2 是超参数，用于平衡不同损失函数的权重； $S[\pi_\theta]$ 是策略的熵，用于增加策略的探索性。

策略熵 $S[\pi_\theta]$ 是衡量策略探索性的关键指标，反映了策略在每个状态下的动作概率分布的随机性。策略熵的计算公式为：

$$S[\pi_\theta](s_t) = -\mathbb{E}_{a \sim \pi_\theta}[\log \pi_\theta(a|s_t)] \quad (3-28)$$

其中： $\pi_\theta(a|s_t)$ 是策略在状态 s_t 下选择动作 a 的概率。

公式 3-28 表示在状态 s_t 下，计算所有动作的概率 $\pi_\theta(a|s_t)$ 及其对数，然后对这些对数概率求加权平均。策略熵的意义在于：熵值越大，策略的动作概率分布越均匀，探索性越强；熵值越小，策略更倾向于选择确定性动作。通过在总损失函数中加入熵项，PPO 能够保持一定的探索能力，避免陷入局部最优。

通过同时优化策略网络和价值网络，PPO 算法能够高效学习动态环境下的最优策略。在目标分群问题中，PPO 算法的优势体现在以下几个方面。首先，PPO 能够动态感知目标点的分布变化，并通过策略网络实时生成新的分群决策，避免传统方法需要反复迭代计算的高时间复杂度问题。其次，PPO 可以结合时间维度的信息，将目标点的状态变化作为输入的一部分，从而实现时间动态的目标分群策略。最后，PPO 允许灵活设计奖励函数，将分群结果的紧凑性、均衡性以及高价值目标的优先处理要求综合到优化目标中，保证了分群结果的全局合理性。

3.4.2 PPO 算法设计与创新

为了适应动态战场环境中的目标分群需求，本文基于近端策略优化算法，结合任务特性进行了设计与创新。在 PPO 算法的具体实现中，明确了状态空间和动作空间的定义，设计了多特性奖励函数以体现任务的优化目标，并提出了训练过程中提升收敛效率和分群效果的改进策略。

(1) 状态空间

在设计基于动态事件的近端策略优化目标分群算法中，状态空间的定义对于智能体

准确感知环境并做出合理决策至关重要。在状态空间的定义中,充分考虑了目标点的属性特征和目标分群中心的动态变化过程。目标点的主要属性包括描述目标点在空间中分布的位置坐标 (x, y) 、目标类型、目标的价值和防御能力等。这些特征为策略的决策提供了基础信息。同时,为了刻画目标分群的整体特性和分布特征,定义了包括分群内目标数量、目标点的分布特性、分群目标到中心的平均距离,以及分群内目标的价值总和、防御能力总和及其比值,用以反应不同分群的任务量。其中,群内目标数量、价值总和、防御力总和及其比值采用 Z-Score 标准化并通过 tanh 函数映射到 $[-1, 1]$ 区间,对于分群内目标位置 x 、 y 坐标的标准差以及群内目标到中心的平均距离则采用 Min-Max 标准化,使其取值在 $[0, 1]$ 之间,进一步规范了特征的尺度,使得特征在后续的计算与决策过程中具有更好的稳定性与可比性。因此,对于每一个目标分群,形成的状态特征如下所示:

$$s_{g_1} = \left[x_{std} \quad y_{std} \quad d \quad c_t \quad v_{sum} \quad d_{sum} \quad \frac{v_{sum}}{d_{sum}} \right] \quad (3-29)$$

最后,将各目标分群的所有特征组合成如下所示的状态矩阵,为智能体提供全面且经过处理的环境状态信息。

$$S = \begin{bmatrix} s_{g_1} \\ \vdots \\ s_{g_n} \end{bmatrix} \quad (3-30)$$

(2) 动作空间

动作空间的设计是目标分群问题的核心创新之一。针对战场目标的动态事件,为实现灵活高效的分群优化,采用了多步骤决策,即三层离散动作空间。每次动作包含三个维度:选择源群(目标所在的初始目标群)、选择目标、选择目标的新归属分群。这种设计充分体现了动作与分群操作的深度耦合,通过动态调整分群中心和目标的分布,优化分群结果的紧凑性和任务均衡性。




图 3-6 多步骤决策动作空间设计

在具体实现中，三层动作空间通过 Categorical 分布来处理多类别选择。首先，策略网络的输出为每个动作组合的概率分布，通过 softmax 层对每个动作的概率进行归一化处理，从而生成明确的动作选择概率分布。在执行动作时，根据策略输出的分布，对动作进行采样，从而决定执行的具体动作。以此机制为基础，PPO 算法能够对复杂的分群问题进行分层次优化，既支持分群中心的微调，也支持目标的动态迁移，从而更高效地调整目标的分配。

为确保动作的有效性和合理性，对输入的动作进行了严格的合法性检查，包括以下几方面：

①群组编号合法性检查：确保源群和目标群的编号在规定范围内。

②目标索引合法性检查：确保选择的目标点索引在源群目标集合范围内，不存在越界选择的情况。

③源群与目标群的区别性检查：若源群和目标群相同，则动作无意义，这类动作将被直接过滤。

只有当动作通过上述合法性检查时，才会执行目标点在群间的迁移操作。迁移完成后，相应更新目标的分群归属信息，包括源群和目标群的目标集合、索引信息和群内统计特征等。这一严格的动作合法性验证机制不仅避免了不合理分群操作的发生，还提高了算法在复杂场景中的稳定性和可靠性。

在实际应用中，三层动作空间的设计能够细化到每一步分群操作，并将策略网络的输出与分群操作直接映射。通过动态调整分群中心与目标归属，PPO 算法在优化分群的紧凑性和均衡性方面表现出极高的灵活性。同时，结合合法性检查和分布采样，该设计为 PPO 算法提供了高效且鲁棒的动作选择机制，确保在动态战场环境中分群策略的实时性和合理性。

（3）奖励函数

奖励函数是引导无人机集群进行有效目标分群的关键因素。综合考虑目标数量均衡性、群体紧凑性和群任务量均衡性，基于上述因素设计奖励函数。具体而言，奖励函数包含三个主要部分：目标数量均衡性、群体紧凑性和群任务量均衡性。每个部分的奖励值计算方式如下：

①目标数量均衡性奖励

目标数量均衡反映了不同群体之间目标数量的均衡性。为了衡量目标数量的均衡程度，计算各群体目标数量的方差。方差越小，说明目标数量越均衡，奖励越高。这有助于避免出现某些群目标过多或过少的情况，使得集群资源能够更合理地分配到各个群中执行任务。因此，目标数量均衡性奖励函数设计为目标数量方差的倒数。

$$R_{count} = \frac{1}{1 + \sigma_{count}^2} \quad (3-31)$$

式中，

$$\sigma_{count}^2 = \frac{1}{G} \sum_{i=1}^G (c_i - \mu_{ct})^2 \quad (3-32)$$

其中, c_i 为分群内目标数量; μ_{ct} 为全体分群的目标数量均值; G 为分群数。

②群体紧凑性奖励

群体紧凑性衡量了每个群体内目标位置的聚集程度, 通过计算各群体内目标位置的标准差来评估。标准差越小, 表示群体越紧凑。紧凑的群结构有利于无人机集群在执行任务时进行协同操作, 减少通信和协调成本。通过计算各群体内目标在 x 和 y 轴上的标准差来衡量群体紧凑性。各群内的目标位置聚集度表示为 $std_x(i)$, $std_y(i)$, 则群体紧凑性奖励 $R_{compact}$ 为所有群体标准差的平均值的倒数, 计算公式如下:

$$R_{compact} = \frac{1}{1 + \sigma_{avg_x} + \sigma_{avg_y}} \quad (3-33)$$

式中,

$$\sigma_{avg_x} = \frac{1}{G} \sum_{i=1}^G std_x(i), \quad \sigma_{avg_y} = \frac{1}{G} \sum_{i=1}^G std_y(i) \quad (3-34)$$

③分群任务量均衡性奖励

群任务量均衡性考虑了每个群体任务的分配是否均衡, 这样可以确保各个群在执行任务时承担相对均衡的任务压力, 避免某些群任务过重而其他群闲置的情况。任务量通过群体中各目标的“目标价值”和“防御力”之比来衡量。为此, 首先计算每个群体的任务量指标, 该指标是群体中目标重要性与防御力之比的累加和。然后, 计算所有群体任务量指标的方差, 方差越小, 任务量分配越均衡。计算公式如下:

$$R_{task} = \frac{1}{1 + \sigma_{ts}^2} \quad (3-35)$$

式中,

$$\sigma_{ts} = \frac{1}{G} \sum_{i=1}^G \left(\frac{v_{sum}}{d_{sum}}(i) - \mu_{ts} \right)^2 \quad (3-36)$$

综合以上三个因素, 给予不同的权重来计算最终的奖励, 权重系数可以根据任务的重要性进行调整, 得到综合奖励函数公式为:

$$\begin{cases} R_{total} = \alpha R_{count} + \beta R_{compact} + \gamma R_{task} \\ \alpha = 0.3 \\ \beta = 0.3 \\ \gamma = 0.4 \end{cases} \quad (3-37)$$

其中, α 、 β 、 γ 为权重系数, 满足 $\alpha + \beta + \gamma = 1$, 可以通过实验进行调节以优化模型性能。

3.5 摧毁目标决策和区域目标分配仿真分析

3.5.1 摧毁目标集决策仿真

收集不同战场环境得目标态势数据共 500 组，用于训练和测试随机森林决策模型，其中训练数据 350 组，测试数据 150 组。采用网格搜索的方法得到决策树数量、最大深度以及特征选择数，具体仿真参数如表 3-1 所示。

表 3-1 RF 决策模型仿真参数

参数	值
决策树数量	80
最大深度	14
特征选择数	2
训练样本占比	70%
测试样本占比	30%

对于摧毁目标集与非摧毁目标集的决策模型性能评估，可以使用混淆矩阵直观清晰的展示模型的预测结果与真实标签之间的对比情况，矩阵中对角线上的元素表示分类别数，非对角线上的元素表示分类错误的类别数量。图 3-7 比较了 RF 算法和决策树算法的混淆矩阵，从图中数据可以观察到 RF 决策模型在每个类别上都具有良好的分类表现，正确分类的效果更佳。




图 3-7 混淆矩阵对比图

根据混淆矩阵，进而计算 RF 算法的准确率、精确率、召回率和 F1 分数，作为衡量模型分类性能的数字指标，数字评价指标越接近 1，表示模型的分类性能越好，具体结果如表 3-2 所示。相较于决策树算法，准确率提高了 9.4%。

表 3-2 不同算法分类结果比较

算法类型	准确率	精确率	召回率	F1 分数
决策树	90%	91.7%	92.2%	91.9%
RF	99.4%	99.1%	99.5%	99.3%

为了进一步评估 RF 摧毁目标集决策算法的鲁棒性和泛化能力，使用相同数据集对不同分类算法进行对比测试，以某一战场中的 200 个目标数据作为测试样本，摧毁目标集决策结果如下所示：




图 3-8 摧毁目标集决策结果

分析不同的方法得到的决策结果，可以看到 RF 分类纳入摧毁目标集的结果较决策树算法更少，这是因为决策树对数据的细微变化非常敏感，导致更多目标被分类为“摧毁目标集”，而 RF 通过集成消除了这些局部过拟合的影响，因此分类结果更符合全局模式，减少了“摧毁目标集”的数量。

表 3-1 计算了不同算法在测试数据集的准确率、精确率、召回率和 F1 分数，与决策树算法相比，RF 分类准确率高 10.1%。

表 3-3 不同算法在测试集分类结果比较

算法类型	准确率	精确率	召回率	F1 分数
决策树	88.2%	91.2%	89.7%	90.4%
RF	98.3%	98.8%	99.2%	99%

3.5.2 基于粒子群算法的区域目标仿真分析

为验证粒子群优化（PSO）算法在目标集区域划分中的有效性，本节详细描述仿真所用的数据集、参数设置以及具体的仿真流程。

(1) 数据集描述

实验中采用由随机森林决策得到的战场目标数据集，目标点所含数据包括以下维度：

- ①目标编号：标识目标的唯一编号，用于区分不同的目标点；
- ②位置坐标：目标点在二维平面战场中的空间位置；
- ③目标类型：目标被分为两类，包括高价值目标和防御阵地；
- ④目标价值：目标的重要程度，用于衡量其在任务分配中的优先级；

(2) 算法参数设置

根据实验需要，设置 PSO 关键参数如下表所示：

表 3-4 PSO 目标区域划分仿真参数

参数	值
初始簇数量	8
最大迭代次数	10
粒子数量	20
个体学习因子	1.5
社会学习因子	1.5
惯性权重	0.8
收敛阈值	0.001

实验中所有目标点及参数均为模拟生成，确保数据多样性和实验的可重复性。

实验在多次迭代后得到了最终的目标区域划分结果。结果表明，各目标点被合理分配到不同的群中，区域中心的分布能够充分反映目标点的分布特性，并满足战场动态环境的需求。如图 3-9 所示，每个群用不同颜色表示，区域中心以黑色“×”标记。高价值目标被优先分配到群中心，表现出算法对战略性目标的优先处理能力。而普通目标则根据其到群中心的距离合理分配到各个区域内，从而实现了目标点的有效区域划分。




图 3-9 基于粒子群优化的目标集区域划分

在收敛性分析中，PSO 算法通过多次迭代对区域中心位置进行优化，逐步减小适应度函数值，直至达到稳定状态。如图 3-10 所示，适应度函数值随迭代次数的变化曲线显示，算法在 $t=8$ 次迭代时已基本收敛。这表明，PSO 算法能够在较少的迭代次数内找到较优的目标区域划分方案，具有较高的收敛效率。

通过实验分析，基于 PSO 算法的目标集区域划分方法在动态战场环境下表现出了一定的适应性和优化能力。PSO 算法能够通过动态调整区域中心位置，完成对目标点的区域划分，初步验证了其在目标分群任务中的可行性。




图 3-10 PSO 算法收敛曲线

3.5.3 基于 PPO 的区域目标分配仿真分析

为了验证基于动态事件的近端策略优化算法在动态战场目标分群任务中的有效性，通过模拟生成战场目标数据集，并详细设计实验设置和步骤。实验主要涵盖数据描述、算法参数设置以及训练流程，确保实验过程严谨有效，且具有较高的可复现性和分析价值。

实验中使用的战场目标数据集是通过模拟生成后经 RF 决策得到的摧毁目标集数据，包含目标点的空间分布和多维属性信息。每个目标点具有以下关键特征：位置坐标 (x, y) 、目标类型、价值以及防御能力。目标点的分布遵循战场环境下的复杂性假设，包括高价值目标密集分布在关键区域，而普通目标分布较为分散。此外，目标集按照战场任务需求划分为多个初始簇，为算法提供初始分群参考。这些数据充分模拟了实际战场中的目标布局 and 特性，有助于评估算法的动态适应能力和优化效果。

在算法参数设置方面，PPO 采用了合理的超参数配置，以确保训练过程的稳定性和收敛速度。具体参数如下表所示：

表 3-5 PPO 目标分群超参数配置

参数	值
学习率	0.0003
折扣因子	0.99
裁剪范围	0.2
更新周期	10
熵正则项权重	0.015
批量大小	64
最大训练轮次	1000

实验训练流程包括数据预处理、环境初始化、策略训练和结果生成四个阶段。在数据预处理中，首先对目标数据集进行标准化处理，包括对目标重要性、防御力等关键属性采用 Z-Score 标准化，映射到 $[-1, 1]$ 区间；对簇内分布特征如距离和方差进行 Min-Max 归一化，以确保数据尺度一致性。随后，通过初始簇划分，将目标点按任务属性和几何距离进行初步分组，为后续训练提供参考基准。

在环境初始化阶段，定义状态空间和动作空间，并建立基于 Gym 框架的环境模型。状态空间通过统计各分群内目标的特征信息（如目标数量、均匀性、紧凑性等）进行编码，动作空间采用三层离散结构（选择源群、目标、新归属分群）以支持灵活的分群操作。此外，环境还设置了动作合法性检查机制，确保输入动作满足边界条件和分配规则，避免无效操作对训练过程产生干扰。

训练过程从策略网络和价值网络的初始化开始，通过采样交互过程逐步优化策略。首先，环境根据当前策略生成动作分布，并通过采样选择具体动作。随后，执行动作并更新环境状态，同时计算即时奖励。奖励函数设计兼顾分群的紧凑性、均衡性和重要性优先等多个目标，实时反馈动作效果，引导策略优化方向。根据经验回报计算优势函数，并利用 PPO 损失函数对策略和价值网络进行更新。在每个更新周期结束后，通过评估适应度函数的变化判断收敛性，若满足停止条件，则结束训练。

最终分群结果通过将目标点分配到最优簇中生成，评估指标包括群内目标分布紧凑度和群间任务量均衡性。

考虑到仿真结果与 PSO 方法的可对比性，采用由随机森林决策得到的战场目标数据集，通过绘制奖励函数随迭代轮次的变化曲线，进一步评估 PPO 算法在训练过程中的收敛性能。图 3-11 显示了奖励函数值随训练轮数的变化情况。




图 3-11 奖励函数曲线

从图中可以看出,奖励值在初始阶段波动较大,表明算法正在探索不同的分群方案;随着迭代的进行,奖励值逐渐趋于平稳,在第 400 轮训练中基本收敛。这表明 PPO 算法在有限的迭代次数内就能找到较优的分群策略,并在后期保持稳定,进一步证明了算法的高效性和鲁棒性。

使用收敛后的网络对随机森林决策的目标集进行区域划分,通过分群结果可视化展示最终的目标分布和簇中心位置,以直观反映算法的优化效果。图 3-12 显示了经过训练后的目标分群情况,不同颜色表示不同分群。




图 3-12 PPO 训练后的区域划分结果

分群结果表明, PPO 算法在动态环境中能够灵活调整簇中心的位置,同时确保各簇内目标的紧凑性和簇间的均衡性。具体而言,簇内目标的分布呈现出较强的集聚特性,目标点到簇中心的距离较短,且各簇规模相对均衡,这充分验证了 PPO 算法对复杂环境下目标分群问题的优化能力。

最后,为进一步验证 PPO 算法的优越性,将其与粒子群优化算法进行对比分析,仿真结果表明,相较于 PSO 算法, PPO 算法在分群紧凑性和任务均衡性方面表现更优。具体而言, PPO 算法能够通过策略优化动态调整簇中心,使得簇内目标的空间分布更加紧凑,距离标准差降低了 15.3%。同时, PPO 算法在均衡性上表现突出,各簇目标数量的标准差较 PSO 算法降低了 12.8%,有效避免了部分簇过度拥挤或空置的现象。进一步证明了 PPO 算法在动态战场环境中实现智能分群和任务分配的可行性与实用性,为后续复杂任务规划和优化算法的研究提供了重要的理论依据和实践指导。

3.6 本章小结

本章围绕动态战场环境下无人机集群的目标摧毁决策与区域目标分配问题展开研究,旨在提升划分子群区域紧凑性和任务均衡性。通过问题建模,综合分析目标的重要性、防御强度和地理分布特性,依次提出基于随机森林的目标摧毁决策模型、基于粒子

群优化的区域目标划分方法，以及基于动态事件的近端策略优化的目标分群方法，为无人机集群任务分配提供了理论支撑和算法实现。

本章所提出的随机森林算法解决了目标选择中的非线性关系与特征冗余问题，确保了高价值目标的优先纳入摧毁目标集；PSO 算法兼顾分群紧凑性与均衡性，但其在高动态场景下灵活性不足。为此，结合强化学习框架设计 PPO 算法，将目标分群建模为决策优化问题，实现对动态环境的灵活适应。仿真结果表明，PPO 在分群紧凑性（簇内目标距离减少 15.3%）、均衡性（簇目标数量差异减少 12.8%）以及动态适应性上优于 PSO，展现了更高的效率与鲁棒性。本章工作为无人机集群在动态战场中的智能决策提供了有效支持，并为后续结合深度强化学习构建自适应杀伤链奠定了基础。

第4章 无人机集群打击次序决策及自适应杀伤链构建

摧毁目标决策和区域目标分配给出了无人机集群攻击战场目标的决策结果,在该决策结果上无人机集群需动态灵活的应对战场态势变化,通过打击次序决策和动态支援等方式构建自适应杀伤链,实时响应战场动态事件,保障集群自主任务决策的有效性和可靠性。

4.1 问题描述与数学建模

在开放战场环境中,无人机集群的任务执行过程中,经常面临复杂多变的情况,例如多目标、多约束以及敌方防御系统的威胁。如何在动态环境下制定高效的打击次序决策,最大化任务收益,同时优化资源协调和分配,是一项重要的研究课题。具体地,包括以下内容:

(1) 无人机集群的资源协调挑战

战场任务复杂多样,不同目标的地理位置、防御水平和重要性各异,无人机集群需高效分配有限资源完成任务。无人机的打击能力、航程大小等资源限制对任务完成率产生显著影响。

(2) 目标集打击次序决策

在无人机集群作战任务中,确定目标的打击次序是决定任务成败的关键。由于战场环境的动态性和敌方防御系统的复杂性,打击次序的决策需要综合考虑目标的重要性、防御水平以及空间分布特征,以最大化任务收益和资源利用效率。

(3) 任务执行中的动态调整需求

在任务执行过程中,部分无人机可能由于敌方防御或其他突发事件被摧毁,导致资源变化与任务失败风险。无人机集群需要具备动态响应能力,根据战场变化及时调整打击顺序和资源配置,确保任务完成。

为解决上述问题,本章提出基于资源评估、动态支援和强化学习的打击次序决策与自适应杀伤链构建方法。首先,通过蒙特卡洛分析进行资源评估,确定任务完成率阈值;其次,采用深度强化学习和深度Q网络(DQN)优化打击次序决策,确保任务收益最大化;最后,设计无人机集群的动态支援机制,优化无人机集群间的任务重分配,以应对突发损耗。

4.1.1 作战资源评估及资源协调问题建模

无人机集群在复杂战场环境中需要合理评估作战资源,并通过有效的资源协调策略完成任务目标。然而,由于资源限制和动态变化,资源评估和协调问题成为影响任务成功率的关键因素。

资源评估的目标包括:(1)量化无人机集群的作战能力,衡量集群任务完成概率;

(2) 确定任务完成率阈值，确保任务执行过程中资源耗尽或损毁后仍能完成主要任务目标。(3) 优化资源协调分配，提高无人机集群执行效率，降低资源浪费。

假设战场中的无人机集群集合为：

$$U = \{U_1, U_2, \dots, U_m\} \quad (4-1)$$

该无人机集群的资源属性包括不同类型无人机的数量 N_d 、每架无人机的载弹量 w 、以及该集群的任务可完成率 P 。与该集群对应的目标任务集为：

$$T = \{t_1, t_2, \dots, t_n\} \quad (4-2)$$

每个目标的属性包括分布位置 (x_j, y_j) 、战略价值 V_j 以及目标的防御能力 D_j 。

根据无人机集群可用资源和目标需求，计算集群执行任务的完成率：

$$P = \frac{\sum_{i=1}^t N_i \times w}{\sum_{j=1}^h p_j \times (1 + d_j)} \quad (4-3)$$

式中， w 为作战资源（无人机）的载弹量； N_i 为不同类型作战无人机的数量； p_j 表示目标的防御强度； d_j 表示目标与当前无人机集群的距离。

同时，无人机资源需满足目标群打击需求：

$$C_a \geq \sum_{j=1}^n D_j \quad (4-4)$$

式中， C_a 为无人机集群 a 的打击能力，必须大于目标群的总体防御强度。

4.1.2 目标集打击次序决策问题建模

在无人机集群作战任务中，如何确定各区域目标的打击次序是决定任务成败的关键问题。目标集打击次序决策问题存在以下特点：

(1) 多目标特性

战场上存在多个目标，每个目标具有不同的重要性和防御能力，对任务收益的贡献不同。无人机集群需要根据目标的重要性和威胁程度合理安排打击顺序，以优先摧毁高威胁或高价值目标。

(2) 动态变化特性

在作战过程中，目标可能会改变位置或状态，集群内的无人机也可能因敌方打击而损毁，导致资源和能力的变化。决策过程需要具备动态调整的能力，以适应突发情况和任务需求的变化。

(3) 资源与时间约束

无人机集群的执行任务能力受时间、航程和弹药等资源限制，需要合理规划打击顺序，避免资源浪费或任务失败。打击次序需要最小化执行时间，同时确保在有限资源内完成关键目标的摧毁。

针对上述特点，打击次序决策问题可建模为一个多目标优化问题，主要目标是：

- (1) 最大化任务收益：优先打击重要目标，并考虑防御削弱机制提升整体收益；
- (2) 最小化资源损耗：优化路径规划和任务分配，减少时间与资源消耗。
- (3) 动态适应性：引入动态更新机制，使无人机集群能够根据实时状态调整打击顺序。

对于包含 n 个目标的集合 $T = \{t_1, t_2, \dots, t_n\}$ ，每个目标 t_j 包含属性：

$$t_j = \{P_j, L_j, V_j, D_j\} \quad (4-5)$$

其中， P_j 为目标的位置与空间关系，表示为 $P_j = (x_j, y_j)$ ，其中 x_j, y_j 为目标坐标； L_j 表示目标类型，在开放战场中主要包括高价值目标和防御阵地； V_j 为目标的战略价值，数值越大表示目标的重要性越高； D_j 是目标的防御能力，表示为需要摧毁该目标所需的火力资源；

相应的 m 架无人机组成的无人机集群为 $U = \{U_1, U_2, \dots, U_m\}$ ，每个无人机的资源定义为：

$$U_i = \{P_{Ui}, L_{Ui}, D_{Ui}, A_{Ui}\} \quad (4-6)$$

其中： P_{Ui} 表示无人机位置，描述其当前坐标； L_{Ui} 表示无人机类型，区分侦察、通信和攻击功能； D_{Ui} 为功能执行距离，具体地，对于侦察无人机， D_{Ui} 表示侦察半径；对于通信无人机， D_{Ui} 表示通信范围；对于攻击无人机， D_{Ui} 为武器攻击距离； A_{Ui} 为进攻能力，对于侦察和通信无人机而言，其自身并不具备攻击能力，表示为 $A_{Ui} = 1$ ，即具备自杀式攻击能力。对于攻击无人机而言，表示为 $A_{Ui} = n_{mis} + 1$ ， n_{mis} 是攻击机携带弹药的数量，即完成弹药攻击后具备自杀式攻击能力。

对于上述优化问题，目标函数描述如下：

$$R = \sum_{j=1}^n [V_j \cdot S_j - \alpha D_j - \beta D_{decay}(j)] \quad (4-7)$$

式中， S_j 表示目标 j 是否被摧毁（1 为摧毁，0 为未摧毁）； $D_{decay}(j)$ 表示目标 j 受周围目标防御削弱影响后的防御值； α 和 β 是权重系数，用于平衡收益与损耗。

同时，存在以下约束条件：

(1) 路径最短约束

无人机执行打击任务时，需要满足路径最短约束，以降低飞行时间和资源消耗：

$$\min \sum_{j=1}^{n-1} d(t_j, t_{j+1}) \quad (4-8)$$

式中， $d(t_j, t_{j+1})$ 表示目标 t_j 与目标 t_{j+1} 之间的距离。

(2) 资源约束

无人机每次打击需要消耗一定弹药，且总弹药消耗不得超过载荷：

$$A_j \leq A_{\max, j}, j = 1, 2, \dots, m \quad (4-9)$$

4.1.3 无人机集群动态调整支援问题建模

无人机在任务执行过程中可能由于防御拦截或环境因素损毁，导致部分任务无法继续执行。此时，需要其他无人机提供动态支援，调整任务分配以完成未完成任务，保证任务收益最大化。动态调整支援问题的目标如下：

(1) 无人机损毁后资源重新分配，保证剩余无人机的任务能力不低于设定阈值。

(2) 降低任务中断损失，实现快速响应和自适应任务调整。

在无人机损毁或任务中断的情况下，需要对未完成任务进行重分配。假设无人机集群在执行过程中，存在损毁无人机集合：

$$U_d = \{u_d\} \quad (4-10)$$

剩余可用无人机集群：

$$U_a = \{u_1, u_2, \dots, u_m\} \quad (4-11)$$

需要重新分配未完成任务集：

$$T_r = \{t_1, t_2, \dots, t_n\} \quad (4-12)$$

进行重分配时，应最小化剩余无人机到目标的路径距离及资源损耗，相应的目标函数为：

$$\min \sum_{j \in U_a} \sum_{i \in T_r} [d(u_j, t_i) \cdot C_a^{-1}] \quad (4-13)$$

式中， $d(u_j, t_i)$ 表示无人机集群 u_j 到目标 t_i 的距离； C_a^{-1} 表示无人机集群 u_j 的剩余打击能力。

此外，为了确保无人机能够在有限资源约束下完成动态支援任务，需要综合评估其资源充足率和路径规划。无人机集群的资源充足率与任务完成率定义相同：

$$P_j^{res} = \frac{\sum_{i=1}^t N_i \times w}{\sum_{j=1}^{j_t} p_j \times (1 + d_j)} \quad (4-14)$$

式中， w 为无人机集群的载弹量； N_i 为不同类型作战无人机的数量； p_j 表示目标的防御强度； d_j 表示目标与当前无人机集群的距离。

根据资源充足率 P_j^{res} ，优先选择剩余资源较为充足的无人机执行支援任务，以保证支援过程中的可靠性和持续性。支援路径规划的目标是最小化路径总长度，同时兼顾资源消耗和时间约束：

$$\begin{aligned} \min & \sum_{k=1}^p d_k \\ \text{s.t. } & P_j^{res} \geq P_{\min} \end{aligned} \quad (4-15)$$

式中， p 表示支援路径中的目标数； d_k 为目标之间的欧氏距离； $P_{\min}$ 为最低资源充足率阈值。

4.2 作战资源评估与任务完成率阈值分析

针对 4.1.1 节提到的作战资源评估及资源协调问题，本节将深入探讨基于现有模型的资源评估方法及阈值确定过程，确定作战资源评估指标体系，并基于蒙特卡洛模拟设定任务完成率阈值，通过实例与分析揭示其在作战决策中的关键作用。

4.2.1 作战资源评估指标体系

有效的资源配置可以提升任务完成率，减少资源浪费，同时应对战场中的动态变化。本节基于无人机集群的资源属性和目标群的属性，提出了一套完整的作战资源评估指标体系，通过该体系可以评估无人机集群是否合理地配置资源，避免出现资源冗余或不足的情况，从而优化作战效能。

无人机集群的作战资源评估体系不仅包含无人机集群资源属性，同时考虑待打击目标群属性影响。其中，无人机集群资源属性包括：

- (1) 无人机类型及数量：不同类型的无人机在集群中主要负责功能不尽相同，其数量决定了集群的总体作战能力；
- (2) 无人机的载弹量：每架无人机的载弹量决定了其能够打击的目标数量；
- (3) 无人机航程：根据任务路径规划和飞行距离来评估无人机的航程对该集群任务完成的影响。

目标群的属性包括目标的地理位置、重要性、防御强度等。在任务执行中，目标的分布和优先级决定了无人机资源的分配。目标群属性的评估指标有：

- (1) 目标的防御能力：目标的防御强度是影响打击成功率的关键因素。通过对目标防御强度和打击能力的匹配分析，可以评估无人机集群的资源配置是否满足任务要求。
- (2) 目标的重要性：目标的重要性使用目标属性中的价值衡量，它直接决定了其优先级。在进行任务分配时，高优先级目标应当优先被选择进行打击，以实现资源的最优利用。
- (3) 目标的空间分布：目标的位置分布会影响无人机的飞行路径和任务执行时间，进而影响资源的消耗。

综合以上无人机集群资源属性和目标群的属性，可定义任务完成率用以评估无人机集群作战资源是否合理配置，任务完成率反映了无人机集群在规定资源条件下能够顺利执行的任务概率，如下式所示：

$$P = \frac{\sum_{i=1}^t N_i \times w}{\sum_{j=1}^h p_j \times (1 + d_j)} \quad (4-16)$$

式中， w 为作战资源（无人机）的载弹量； N_i 为不同类型作战无人机的数量； p_j 表示目标的防御强度； d_j 表示目标与当前无人机集群的距离。

该公式体现了在资源约束下，目标群被摧毁的效果与资源配置的关系。任务完成率

越高,说明在现有无人机资源配置条件下,对既定目标群完成打击任务的概率越大,相应的该集群资源配置越合理,反之则表明存在资源冗余或不足的情况。

通过这一评估指标体系,能够全面考量无人机集群的资源状态与任务需求,从而为作战任务中的资源配置和任务分配提供科学依据。合理的资源配置可以提高任务完成率,避免资源浪费或任务失败。

4.2.2 基于蒙特卡洛分析的任务完成率阈值设定

在实际的无人机集群作战任务中,不同的资源配置对任务完成率有着显著影响。因此,为了更加准确地评估无人机集群资源配置的合理性,采用了场景模拟与蒙特卡洛分析相结合的方法来设定任务完成率的阈值。通过多次模拟战场环境与资源配置,结合概率统计分析,得出一个可靠的任务完成率阈值范围,从而为实际任务中的资源配置提供参考,具体步骤如图 4-1 所示。

场景模拟是通过构建虚拟战场环境,模拟无人机集群在不同资源配置下执行任务的过程。在每一个模拟场景中,考虑以下几个变量:

(1) 目标类型与分布:包括目标的位置、重要性和防御能力。

(2) 无人机集群的资源配置:包括侦察无人机、攻击无人机的数量,每架无人机的载弹量、无人机集群的动态位置等资源的初始配置。

(3) 动态变化因素:如集群内的无人机损毁、目标防御变化等因素。

在每个模拟场景中,无人机集群将按预定的打击次序执行任务,并根据任务完成情况计算任务完成率。通过对大量场景模拟的结果进行统计分析,得到一个可靠的任务完成率数据集。




图 4-1 任务完成率阈值设定流程图

基于场景模拟结果,进一步采用蒙特卡洛分析方法进行任务完成率的统计分析。蒙特卡洛分析通过大量的随机模拟实验,能够在不同的资源配置和环境变化下,评估任务完成率的概率分布情况。在蒙特卡洛分析中,着重关注以下几个方面:

(1) 资源配置的敏感度：分析不同资源配置对任务完成率的影响，确定集群中哪些资源是影响任务完成率的关键因素。

(2) 任务完成率的可靠性：通过模拟实验和统计分析，评估在不同资源配置下，任务完成率达到某个阈值的概率。

每次模拟都生成一个随机的任务完成率结果，并通过多次实验计算任务完成率的平均值和方差，从而得到任务完成率的可靠估计。通过以上分析，为无人机集群提供了科学的资源配置评估标准，帮助决策者在实际作战中合理配置资源，避免过度配置或资源不足的情况，从而提高作战效率和任务完成率。

4.3 基于 DQN 的打击次序决策

无人机打击次序决策问题属于 NP-hard 问题，尤其是在高动态战场环境中，通常使用强化学习或进化算法来寻求近似最优解。本节提出了一种基于强化学习的无人机自主决策算法，旨在最小化无人机的任务总飞行距离并提高打击收益，算法在强化学习的框架下使用深度 Q 网络（Deep Q-Network, DQN）来实现无人机的自主打击路径决策，以最小化无人机的总飞行距离并优化任务完成效率，引导无人机在任务区域中依次完成目标打击。

4.3.1 DQN 算法原理与优化

DQN 是一种将深度学习与 Q 学习相结合的强化学习算法，通过神经网络逼近 Q 值函数，用于无人机集群的动态决策问题^[88]。采用前馈神经网络结构，使用多层感知机 (MLP) 结构，包含输入层、隐藏层和输出层，输入当前状态特征 (S)，输出各动作 (A) 的 Q 值，网络结构图如图 4-2 所示。




图 4-2 网络结构图

其中，输入层传入无人机集群和目标状态特征，隐藏层采用两层全连接网络，并使用 ReLU 激活函数增强非线性表示能力，输出层的输出维度等于动作空间的大小，即当前目标数，每个输出表示无人机选择对应目标的 Q 值，决策时选择 Q 值最大的动作。

网络结构公式为：

$$Q(s, a; \theta) = f(w_2 \cdot f(w_1 \cdot S + b_1) + b_2) \quad (4-17)$$

式中， w_1 和 w_2 为权重参数， b_1 和 b_2 为偏置参数， f 表示 ReLU 激活函数。

采用均方误（MSE）作为损失函数，优化目标为最小化预测 Q 值与目标 Q 值的误差：

$$L(\theta) = \mathbb{E}[(y - Q(s, a; \theta))^2] \quad (4-18)$$

其中目标 Q 值为：

$$y = r + \gamma \max_{a'} Q(s', a'; \theta') \quad (4-19)$$

式中， r 为即时奖励， γ 为折扣因子， $Q(s', a')$ 为下一个状态的最大的 Q 值。

针对 DQN 在无人机集群任务规划中的应用特点，进行以下优化：

（1）经验回放机制

采用经验回放缓解训练样本相关性问题，通过存储历史决策数据进行随机采样训练，提升模型泛化能力。具体而言，经验回放将每个时间步的状态转移（包括当前状态、所选动作、所获得的奖励以及下一个状态）存储在一个经验回放池（Replay Buffer）中^[89]。该池中的存储容量为有限，通常采用先进先出（FIFO）的策略进行管理。当训练进行时，DQN 从回放池中随机采样一个小批量的样本，进行 Q 值的更新。通过这种方式，模型能够更好地泛化，避免在训练过程中由于数据的高相关性而导致的过拟合。

经验回放的核心优势在于，它通过打破时间相关性，使得每次训练不再仅仅依赖于相邻的样本序列。随机采样有助于提升样本的多样性，从而提高模型的稳定性和训练效率，具体流程如图 4-3 所示。




图 4-3 经验回放机制流程

每次无人机在执行任务时，记录当前的状态 s_t ，执行的动作 a_t ，收到的奖励 r_t ，以及转移后的状态 s_{t+1} 。在状态转移发生后，将其存入经验回放池中。如果回放池已满，则根据 FIFO 原则删除最旧的样本以腾出空间。在训练时，从回放池中随机采样一个小批量样本，进行 Q 值更新。

（2）引入注意力机制

在无人机集群打击次序决策任务中，目标的重要性、防御水平和空间分布存在显著差异。传统的强化学习算法在处理多目标动态决策问题时，容易受限于特征表示能力，

导致模型对高价值目标关注不足，从而降低打击效果和资源利用效率。为了解决这一问题，引入注意力机制（Attention Mechanism），通过计算目标的重要性权重，提升模型的训练效率和决策精度。注意力机制能够动态调整模型对各个目标的关注程度，使无人机集群优先考虑高价值目标，从而优化打击次序和资源配置。

注意力机制的核心思想是：在众多候选目标中，分配更高的注意力权重给重要性更高的目标，以引导模型专注于关键任务区域，将其应用于目标集群内的次序决策原理图见图 4-4。




图 4-4 注意力机制原理图示

首先根据目标的重要性特征（如位置、重要性、防御值等）计算注意力得分。目标的重要性可以通过重要性权重 W_i 、防御水平 D_i 以及距离约束 d_{ij} 衡量，重要性权重反映目标的任务价值或优先级，防御能力较低的目标更容易被摧毁，因此权重更高，此外，距离较近的目标可降低资源消耗，获得较高关注度。

在计算注意力得分时，采用软注意力机制（Soft Attention）计算目标 i 的注意力得分 A_i ：

$$A_i = \frac{\exp(W_i)}{\sum_{j=1}^n \exp(W_j)} \quad (4-20)$$

式中， n 为目标数量， W_i 表示目标 i 的重要性权重，通过线性组合重要性、防御水平和距离等特征获得：

$$W_i = \alpha_1 W_{imp} + \alpha_2 (1 - D_i) + \alpha_3 (1/d_{ij}) \quad (4-21)$$

式中， $\alpha_1, \alpha_2, \alpha_3$ 是特征加权系数，用于平衡各因素的影响。

式 4-20 采用 Softmax 函数将注意力分布归一化，保证所有目标的注意力权重和为 1，便于后续训练和计算。

注意力机制通过动态调整关注权重，对无人机打击决策过程产生以下优化效果：通过关注高权重目标，有效减少模型对低优先级目标的计算开销，加快训练收敛速度。注意力机制使无人机集群优先打击关键节点，最大化毁伤效果，同时减少资源浪费。如在

资源不足或时间紧迫的情况下，模型会优先摧毁重要性高、防御值低的目标。注意力机制能够实时调整权重，适应动态变化的战场环境，确保决策灵活性和鲁棒性。

4.3.2 打击次序决策环境构建

战场目标打击次序及路径决策问题可以描述为：根据整个任务流程，由前述步骤给定多个待打击的目标点 $T = \{t_1, t_2, t_3, \dots, t_n\}$ ，无人机从基地出发，依次完成对目标的打击并返回基地。定义每个目标点 t_i 的二维坐标为 (x_i, y_i) ，无人机在打击目标时，需完成以下目标：

(1) 最小化总飞行距离：无人机应以最短路径依次打击每个目标并返回基地，以减少燃料消耗和暴露时间。定义无人机从位置 t_i 到位置 t_j 的距离为 d_{ij} ，基地位置为 t_0 ，则总飞行距离 D 可以表达为：

$$D = \sum_{i=0}^n d_{\pi(i), \pi(i+1)} \quad (4-22)$$

其中， π 表示目标访问的次序排列，满足 $\pi(0) = 0$ 和 $\pi(n+1) = 0$ （即从基地出发并最终返回基地）。

因此优化目标为：

$$\min_{\pi} D = \min_{\pi} \sum_{i=0}^n d_{\pi(i), \pi(i+1)} \quad (4-23)$$

该公式通过求解访问次序 π 的最优排列来使总飞行距离 D 最小化，从而实现燃料消耗和暴露时间的最小化。

(2) 合理打击顺序：为了在所有可能路径中选择最优次序，使无人机能够快速、高效地打击高优先级目标，引入目标优先级函数 p_i （ p_i 值越高表示目标优先级越高）。合理打击顺序的优化目标可以表述为：

$$\max_{\pi} \sum_{i=1}^n \frac{p_{\pi(i)}}{D_{\pi(i)}} \quad (4-24)$$

其中， $D_{\pi(i)} = \sum_{k=0}^{i-1} d_{\pi(k), \pi(k+1)}$ 表示在打击目标 $t_{\pi(i)}$ 之前的累积飞行距离。这一公式体现了无人机优先选择高优先级目标并同时优化路径的决策原则。

结合以上两个目标，通过一个加权组合模型实现，同时最小化总飞行距离和最大化优先级收益：

$$\max_{\pi} (\alpha \sum_{i=1}^n \frac{p_{\pi(i)}}{D_{\pi(i)}} - \beta D) \quad (4-25)$$

其中， α 和 β 为权重系数，控制优先级与距离的权重。

基于无人机集群任务的特点，设计自定义的强化学习环境，该环境包括以下元素：

(1) 目标数据：每个目标点具有二维坐标信息 (x, y) 、目标类型及目标重要性等多维特征数据，用于描述目标在任务区域中的空间分布和自身属性。

(2) 无人机位置：对于非动态战场环境而言，无人机从基地出发，任务执行期间实时更新当前位置，直到完成任务并返回基地。

(3) 打击状态：定义目标未打击或已打击状态，使无人机在环境中能够识别哪些目标已被打击，哪些仍未打击。

明确了基于无人机集群任务构建的强化学习环境所涵盖的关键元素后，进一步剖析其状态空间、动作空间以及奖励函数的设计细节成为实现高效任务执行策略学习的核心环节。这些要素相互关联、协同作用，共同塑造了无人机集群在复杂任务环境中的决策逻辑与行为模式，以下将对其展开深入探讨。

(1) 状态空间

状态空间用于描述环境的当前状态，具体定义如下：

- ①目标状态：包括目标位置、防御力和价值；
- ②无人机集群状态：包括无人机集群剩余资源以及当前位置；
- ③动态环境信息：考虑目标存在状态以及无人机损毁情况。

将上述信息组合成状态向量 S 作为模型的输入，即：

$$S = \{x_i, y_i, d_i, v_i, x_{uav}, y_{uav}\} \quad (4-26)$$

其中， x_i, y_i 为目标位置， x_{uav}, y_{uav} 为无人机位置， d_i 描述目标防御力属性， v_i 表示目标的价值，即重要性衡量。

(2) 动作定义

动作空间定义无人机可执行的动作集合，在次序决策问题中，每一个动作对应无人机集群在环境中的一次打击决策，即选择一个目标并执行打击操作。具体来说，动作的定义和选择过程涉及以下内容：

①动作空间 A ：表示无人机可选的打击目标集。假设当前存在 n 个潜在目标，每个动作 a_i 代表选择一个特定目标 t_i 进行打击。因此，动作空间的规模直接取决于目标的数量 n 。每一轮决策中，无人机需从中选择一个目标执行打击。

②动作选择机制：为了优化决策的有效性，采用深度 Q 网络模型来评估每个动作的价值，并选择具有最高价值的动作。在每一个状态下，DQN通过前向传播计算每个可能动作的 Q 值（即该动作在该状态下的期望回报），并选择 Q 值最高的动作 a_i 作为当前的最优打击目标。动作的选择过程可以表述为：

$$a_i = \arg \max_{a \in A} Q(s, a; \theta) \quad (4-27)$$

其中， $Q(s, a; \theta)$ 表示DQN网络参数为 θ 时，状态 s 下执行动作 a 的 Q 值。通过每次选择 Q 值最高的动作，DQN能够引导无人机逐步逼近最优打击路径。

综上所述，在模型中每一个动作 a_i 代表无人机选择一个目标并执行打击，该动作选择机制由DQN网络评估的 Q 值指导，能够动态适应战场环境并实现最优打击次序。

(3) 奖励设计

根据无人机打击任务的需求，奖励函数的设计用于引导无人机在任务中逐步优化打击路径与目标优先级选择，确保其在最小化路径的同时优先打击高价值目标。设计了以下奖励机制，以引导模型实现最优解：

①负距离奖励：每当无人机从当前位置 p_{cur} 移动到目标位置 p_{tar} 时，获得负的飞行距离奖励，以鼓励选择更短的路径。设两点之间的欧几里得距离为 $d(p_{cur}, p_{tar})$ ，则负距离奖励 R_{dist} 为：

$$R_{dist} = -d(p_{cur}, p_{tar}) \quad (4-28)$$

②重复打击惩罚：若无人机选择了一个已打击的目标，则给予高惩罚-10，避免重复访问。定义重复打击惩罚 R_{rep} 为：

$$R_{rep} = \begin{cases} -10, & \text{若目标已被打击} \\ 0, & \text{若目标未被打击} \end{cases} \quad (4-29)$$

③合理打击顺序奖励：为确保无人机优先打击高优先级目标，提高任务完成效率，定义合理打击顺序的奖励。假设每个目标 i 的重要性为 p_i ，若无人机在打击顺序中选择了高优先级目标，则给予额外的奖励 R_{pri} ：

$$R_{pri} = \sum_t \left(\frac{p_i}{rank_i} \right) \quad (4-30)$$

其中， p_i 表示目标 i 的优先级值， $rank_i$ 表示目标 i 在整个打击序列中的顺序。该奖励项确保高优先级目标能够尽早打击，从而优化任务完成的速度和效果。

综合以上奖励项，得到无人机打击任务的最终奖励函数 R ：

$$R = R_{dist} + R_{rep} + R_{pri} \quad (4-31)$$

通过该奖励函数，模型能够在最小化路径的同时，实现对高优先级目标的快速、有效打击，从而引导无人机优先打击关键节点，逐步收敛至最优打击路径。

4.3.3 区域目标打击决策流程

基于上述强化学习建模与优化设计，无人机集群打击次序动态决策流程通过环境交互、状态更新、动作选择、奖励反馈和迭代优化，实现无人机在动态环境下的自主决策和持续学习能力，设计打击次序决策流程如图 4-5 所示。

环境初始化是对任务场景进行初始化，设置无人机集群和目标集的初始状态，补充随机扰动因素增加场景动态性，包括区域内目标被其他方式摧毁以及随着任务进行出现的新增目标。随后将无人机和目标的特征映射到状态空间 S ，状态初始化的目标是为后续的训练过程提供完整的输入特征描述。

状态更新即在每个决策步骤，算法根据无人机与目标的交互更新状态，反映最新的战场信息。基于当前状态 S 通过 DQN 网络预测动作值 $Q(s, a)$ ，选择最大 Q 值对应的动作，同时采用 ϵ -greedy 策略平衡探索与利用，以概率 ϵ 随机选择动作进行探索，初始时鼓励探索， ϵ 较大，随训练过程逐步减小，最终趋于稳定策略。




图 4-5 无人机集群打击次序决策流程

无人机集群根据选定动作对目标执行打击，并记录动作结果，更新任务状态和资源消耗，根据打击结果计算即时奖励 R ，执行动作后更新环境状态，生成新的状态 S_{t+1} ，进入下一轮决策迭代。

为缓解训练样本相关性和非平稳分布问题，采用经验回放缓冲池存储训练数据，从缓冲池中随机抽样小批量数据，用于模型训练，提升泛化能力。通过多轮训练，算法不断调整策略，最大化累积奖励。在训练过程中，算法动态调整探索策略和资源配置，当任务目标减少或无人机损毁时，自动重新规划打击顺序和资源配置，结合注意力机制，适应关键节点优先级变化，提高决策灵活性。

4.4 无人机集群动态支援机制设计

4.3.1 无人机集群任务执行突发状况剖析

在复杂战场环境中，无人机集群执行任务时难以避免的会遭遇突发情况，如集群中的无人机被摧毁，导致资源不足或任务失败。这些突发问题对集群的协同作战能力提出了严峻挑战，必须通过动态支援机制进行及时补救和调整，以保障任务顺利完成。

根据攻击条件与协同作战模型，同一个集群内的包含不同功能类型的无人机，在集群执行任务过程中存在以下两类无人机被外界因素摧毁的状况，如图 4-6 所示，包括集群内的攻击无人机被毁和侦察无人机被毁两种状况。

攻击无人机在任务执行过程中承担火力打击和目标摧毁的关键任务。一旦攻击无人

机被敌方摧毁，可能导致以下问题：

- (1) 打击能力下降，无法及时摧毁重要目标，延误任务执行进度。
- (2) 剩余无人机面临资源分配不均，原有的任务分工与资源配置平衡被打破，无法承担过多火力任务，导致任务失败风险增加。




图 4-6 无人机集群中的不同类型无人机被摧毁

为有效应对这一严峻局面，可实施以下针对性解决方案。其一，构建火力支援机制。通过动态监测与智能决策系统，迅速从其他无人机集群中调用具有相应攻击能力的无人机，及时补充损失的火力。同时，对剩余的任务进行全面且合理的重新分配，在资源有限的条件下，确保重要目标能够获得优先打击的资源保障，维持整体打击效能的相对稳定。其二，开展任务调整与路径优化工作。基于当前的战场态势和剩余无人机的性能状况，运用路径规划算法与任务调度模型，重新规划任务分配方案和打击顺序。在规划过程中，充分考虑无人机的飞行性能、弹药储备以及目标的分布与防御情况等因素，通过合理设计飞行路径，尽可能缩短打击路径长度，减少不必要的资源消耗，从而提升整体作战效率，降低任务失败的可能性，保障无人机集群在遭遇攻击无人机损毁等突发情况时仍能维持较高的任务完成能力。

同理，侦察无人机的核心职能在于对目标进行精准定位并实现实时信息传输，为后续的打击行动和战术决策提供关键情报支撑。倘若被敌方防御阵地摧毁，将导致以下问题：

- (1) 目标状态信息的连续性遭到破坏，出现丢失或延迟现象，影响打击精度和战术规划。
- (2) 无法更新动态环境数据，导致决策失误或资源浪费。

针对侦察无人机被摧毁所引发的困境，需采取一系列有效应对措施。一方面，建立信息支援机制至关重要。临近的无人机集群应迅速响应，在资源富余的前提下派遣备用侦察无人机赶赴任务区域，以最快速度恢复侦察能力，维持对目标及环境的持续监测。另一方面，实施任务交接与重规划策略。将损毁侦察无人机所在集群原本承担的任务合理分配给其他无人机集群，并依据新的任务分配情况和战场态势，重新调整支援无人机集群的飞行路径。

4.3.2 支援机制设计

为解决集群内无人机损毁或资源不足导致的任务失败问题，本节提出了一套动态支援机制建模方案。该模型通过支援需求评估和支援方式设计，实现任务调整与资源重分配。

(1) 支援需求评估

支援需求评估是支援机制触发的前提条件，根据任务执行进度和目标摧毁状态，动态评估剩余任务量 T_r ：

$$T_r = T_{tot} - T_{comp} \quad (4-32)$$

式中， T_{tot} 为集群的任务总量， T_{comp} 为已完成任务量。

同时，统计个无人机集群的剩余作战资源和打击能力 C_r ：

$$C_r = \frac{F_r}{F_{\max}} \cdot \frac{A_r}{A_{\max}} \quad (4-33)$$

式中， F_r 和 A_r 分别为无人机集群的剩余可用航程和载弹量， $F_{\max}$ 和 $A_{\max}$ 为最大资源容量。

支援请求的触发条件设定为：

$$\begin{cases} T_r > T_{\text{threshold}} \\ C_r > C_{\text{threshold}} \end{cases} \quad (4-34)$$

即当剩余任务量大于设定阈值且其它无人机集群的剩余作战资源在执行自身任务富余的情况下触发支援机制，重新分配任务和资源。

(2) 支援方式设计

为应对无人机集群任务执行中的突发状况，设计合理的支援方式至关重要。针对集群内不同类型的无人机动态摧毁事件，设计考虑集群间资源重分配和任务调整与支援路径优化两个环节的支援方式。

① 集群间资源重分配

根据支援需求，系统需依据动态变化的战场态势，调度邻近无人机提供火力或情报支援。资源重分配采用最小资源浪费原则，通过对任务需求的精准分析与评估，优先确保关键任务需求得到充分满足，以实现资源利用的高效性与合理性，避免不必要的资源损耗对任务执行产生负面影响。

② 任务调整与支援路径优化

无人机集群的支援机制在重新规划任务时，首先需要根据现存侦察无人机数量对目标群进行重划分，确保每个无人机集群覆盖合理数量的目标：

$$G_k = \{t_1, t_2, \dots, t_m\}, k \in [1, K] \quad (4-35)$$

式中， G_k 表示第 k 个目标群，包含 m 个目标； K 为剩余侦察无人机的数量。

在重新分群和任务调整后，支援无人机需要重新规划航线，以满足资源和时间约束。路径优化主要目标是最小化无人机的总飞行距离和执行时间，同时考虑资源消耗和任务

完成率。

4.5 仿真实验与分析

4.5.1 任务完成率阈值设定仿真分析

采用 4.2.2 节所介绍的方法场景模拟方法，面向不同战场环境下的资源配置，进行上千次模拟。取其中某次模拟过程，该场景下的无人机作战资源及目标参数如下表所示：

表 4-1 无人机作战资源配置参数表

无人机类型	位置	数量	载弹量
通信无人机	(0,-2000)	1	0
侦察无人机	(0,-2000)	3	2
攻击无人机	(0,-2000)	12	6

表 4-2 战场目标参数表

目标类型	数量	价值	防御力
指挥部	2	0.9	2
防御阵地	8	0.4	5
地面装甲	13	0.2	3
通信枢纽	3	0.8	2
雷达监测站	2	0.7	1

所有目标的位置随机生成，并考虑高价值目标附近的防御阵地出现的概率较大，其位置分布如图 4-7 所示。




图 4-7 作战资源场景配置及目标分布一览图

对于该场景下的资源配置，由式 4-16 计算得到的任务完成率 $P=0.72$ 。在模拟过程中，针对不同战场环境下的资源配置进行大量模拟实验，得到了任务完成率的分布情况，如图 4-8 所示。




图 4-8 蒙特卡洛模拟任务完成率分布图

实验结果表明，模拟得到的任务完成率接近正态分布，但具有一定的右偏态。随着资源配置的增加，任务完成率逐渐提高，但增幅在高配置条件下趋于减小。任务完成率分布中大部分场景集中在 50%到 70%之间，表现出较好的可靠性。

为了确保无人机集群在绝大多数作战场景中能够完成任务，采用 95%分位数作为安全阈值标准。具体分析结果如下：

- (1) 根据仿真结果，任务完成率的 95%分位数为 79%；
- (2) 这表明在资源配置合理的条件下，有任务完成率达到 79%时可以满足大部分作战场景需求，保证了作战任务的可行性和安全性。

进一步分析资源配置的冗余性，以确保资源利用效率。表 4-3 给出了在同一场景下不同资源配置下的任务完成率和冗余分析结果：

表 4-3 不同参数资源配置下的冗余情况表

配置编号	通信机数量	侦察机数量	攻击机数量	火力强度	任务完成率	资源冗余量
1	1	2	13	82	87%	3
2	1	1	8	50	71%	\
3	1	1	11	68	80%	0

表中的火力强度是该配置下的集群内无人机携带的载弹量总和，从表中可以得知配置 1 的资源存在一定冗余，作战效率较高但资源浪费较大，配置 3 在满足任务完成率阈

值的前提下，资源配置最为合理，无明显冗余。在三类不同的作战资源中，攻击无人机持有的载弹量最多，对于任务完成率的影响最明显。因此，在进行不同场景的资源配置时，应着重考虑攻击无人机的对任务完成率的影响，避免造成资源冗余，提升资源利用效率。

本节分析结果为无人机集群任务规划和资源优化提供了理论依据，同时也为自适应杀伤链构建中的资源配置决策提供了参考标准。

4.5.2 打击次序决策仿真分析

实验旨在验证基于 DQN 算法的无人机集群打击决策模型在动态任务规划中的有效性，并评估其在任务完成率、资源利用率和路径优化方面的性能表现。此外，通过对比传统 DQN 与引入注意力机制后的改进模型，分析注意力机制对模型训练效率和打击效果的提升。

实验中的无人机集群以及该集群对应的打击目标集在环境初始中随机设定，且满足任务完成率阈值要求，选择训练收敛速度作为评价指标，当平均奖励值达到稳定时认为训练结束，算法超参数设置如下表所示：

表 4-4 DQN 算法超参数设置

参数	值
折扣因子	$\gamma = 0.9$
学习率	$\alpha = 0.001$
探索率	$\epsilon_{\max} = 0.95, \epsilon_{\min} = 0.1$
批量训练大小	64
经验回放池大小	500

为了评估模型的训练稳定性与收敛性，实验记录了训练过程中每个时间步的奖励值，并绘制了奖励变化趋势图，如图 4-9 所示。该奖励图展示了模型在不断学习的过程中，其奖励随训练轮数的变化情况。

从奖励图可以观察到，模型在初始训练阶段奖励波动较大，表现出较高的探索性。这一阶段，模型试图通过不同的动作序列来发现最优策略，因此奖励的波动反映了策略的不稳定性。随着训练的进行，模型逐渐收敛，奖励的波动性减小，呈现出以下几个特征：

(1) 平均奖励提升：奖励值随训练步数逐步上升，表明模型逐渐学习到了更优的路径规划和目标选择策略。特别是在某个关键步数后，平均奖励迅速提升，表明模型在积累了一定经验后能够做出更合理的决策。

(2) 波动性减少：在训练后期，奖励值波动逐渐减小，趋于稳定，表明模型的策略趋于稳定，不再频繁探索低效的路径或重复打击。这一趋势证明了模型逐渐从探索转向利用，更频繁地选择在历史训练中表现较好的动作。

(3) 收敛点确定：从图中可以看到，奖励曲线在一定步数后趋于平稳，表明模型在该步数后基本收敛，训练策略不再发生显著变化。此时，模型的选择行为趋于最优，达到了任务的预期目标。




图 4-9 奖励随训练轮次变化图

以 3.5.1 节战场目标摧毁目标集分群结果为测试对象，选择红色矩形框区域内的目标，模拟无人机在该环境中进行打击目标及路径决策并返回基地的过程。




图 4-10 选择打击次序测试目标群

通过对模型生成路径的观察，可以看到 DQN 模型在打击次序上的规化效果。在实验结果图中，模型优先选择距离较近的目标，形成一条相对紧凑、无重复的打击路径，避免了不必要的路径往返，提升了整体任务的执行效率。图 4-11 表明 DQN 模型生成的

路径显示出清晰的打击次序，优先考虑了距离较近的目标，同时兼顾了高优先级目标的选择。这种优化有助于无人机在执行过程中节约时间和资源，符合实际应用需求。实验结果证明了 DQN 模型在路径规划中的应用潜力，能够在复杂环境中合理安排无人机的打击次序，提高了任务的执行效果。




图 4-11 DQN 生成的目标集打击次序

4.5.3 无人机集群支援机制仿真分析

本实验旨在验证无人机集群支援机制在突发事件中的动态调整能力，包括集群中的攻击无人机和侦察无人机分别被摧毁的两类动态事件，并评估支援算法在动态环境下的稳定性和适应性。

实验中含 8 组无人机集群，根据无人机集群配置条件约束，各无人机集群资源配置包括至少一架侦察机及若干攻击机，在初始资源分配时均满足任务完成率阈值需求，各无人机集群资源配置如图 4-12 所示。

初始化无人机与目标状态，模拟攻击无人机被损毁事件，随机选择其中某无人机集群中攻击机被摧毁，如图 4-13 所示，模拟突发事件。根据剩余任务量和资源配置动态调整任务分配。采用局部搜索算法选择资源富余的无人机集群提供可支援攻击机，并更新无人机状态。

经支援算法计算，该无人机集群内的 17 号攻击机损毁后的集群任务完成率为 81.3%，未达到支援机制触发条件，集群内的无人机资源不做调整，故在该任务场景下各无人机集群不做动态调整，以现有配置形式继续参与后续打击任务。




图 4-12 无人机集群资源配置




图 4-13 随机选择某集群内的攻击机被摧毁

在相同无人机集群资源配置前提下，模拟集群内侦察无人机被摧毁事件，测试支援机制对不同类型无人机摧毁事件的泛化性。随机选择某无人机集群中侦察机被摧毁，启

用动态支援机制，采用启发式算法重分配侦察无人机集群内的其余攻击机以满足重分簇的目标群任务完成率要求，并更新无人机集群状态。




图 4-14 随机选择某集群内的侦察机被摧毁




图 4-15 侦察机被摧毁的集群其余无人机重分配决策




图 4-16 侦察机被摧毁的集群其余无人机重分配结果

设置无支援机制对照实验组，该对照组以静态任务规划进行作战资源配置，无支援和动态调整功能。分别计算两组实验下的无人机集群任务完成率均值如下表所示：

表 4-5 有无支援机制的任务完成率

场景类型	启用支援机制（%）	无支援机制（%）	提升幅度（%）
攻击无人机损毁	87.4	68.9	+18.5
侦察无人机损毁	82.5	62.1	+20.4

实验结果表明，支援机制能够显著提升任务完成率，特别是在无人机损毁等突发情况时表现出较强的自适应能力。启发式算法和局部搜索法在任务分配和路径规划方面表现出较高的计算效率和调整灵活性，有效减少了计算复杂度和资源消耗。

4.6 本章小结

本章围绕无人机集群在高动态战场环境下的自主决策问题，提出了基于资源评估、强化学习与动态支援机制的解决方案，重点研究了无人机集群的资源协调与打击次序优化建模、深度强化学习算法在路径决策中的应用，以及突发情况下无人机资源的动态重分配方法。通过设计无人机集群动态调整支援机制和引入注意力机制优化强化学习模型，建立了完整的无人机集群自适应任务规划框架，提升了任务完成率和资源利用效率。

仿真结果表明，通过蒙特卡洛分析方法进行场景模拟并设定任务完成率阈值，实现了 95%场景下资源配置达到任务完成率要求，确保资源合理分配和任务可行性。在目标分群打击次序决策方面，引入注意力机制的 DQN 打击次序决策算法，能够有效缩短飞

行路径、优先摧毁高价值目标，并显著提高任务完成率。利用启发式算法的动态支援机制设计实现高效资源协调和任务调整，与无支援机制对比任务完成率提升约 20%。综上，本章提出的动态打击决策算法与支援机制为无人机集群自适应作战提供了理论依据和算法支持。

第 5 章 面向典型场景下的无人机集群对地打击自主决策仿真

基于前两章对战场目标划分和无人机集群自适应杀伤链的研究，本章旨在通过联合仿真，包括静态目标场景、动态目标变化场景以及作战资源损失场景等多种仿真情形，验证无人机集群在典型动态场景下对地目标打击任务级决策方法的有效性。

5.1 仿真设置及总体框架

5.1.1 仿真环境与关键参数设置

本章的研究基于高效的仿真平台，该平台能够模拟无人机集群在动态战场环境中的运行状态和任务执行过程。仿真采用 Python 编程语言作为主要开发环境，结合 TensorFlow 框架进行强化学习模型的训练与推理。Python 提供丰富的科学计算库以及可视化工具，为算法实现和结果分析提供了高效支持。同时，仿真过程中涉及到的数学建模与算法验证部分，部分模块借助 MATLAB 平台进行辅助验证，确保算法设计的正确性和收敛性。此外，为更好地模拟无人机的真实作战环境，平台还集成了目标分群、作战资源分配和动态支援机制等模块，支持多目标动态决策的精确计算。

在仿真环境的设置中，考虑了典型战场中的任务特点和无人机集群的实际应用需求，模拟无人机集群在对地打击任务中的典型作战场景。在环境设计上，假设无人机在二维平面上活动，且通信无人机的通讯覆盖面积始终涵盖战场范围，具体属性参数如下表所示。

表 5-1 各类型无人机属性参数

类型	数量（架）	载弹量（枚）	巡航速度（ m/s ）	最大航程（公里）
通信无人机	3	0	70	800
侦察无人机	8	2	70	1600
攻击无人机	30	6	70	2200

每个目标的位置、类型和特征均通过预设规则确定，包括指挥所、防御阵地、通信枢纽、雷达监测站以及地面装甲五类目标，其中指挥所战略价值最高，防御阵地的防御能力最高，预设在高价值目标附近出现防御阵地的概率更大原则生成 200 个不同类型的战场目标，随机分布于 $40\text{ km} \times 30\text{ km}$ 的矩形战场，无人机基地位于距离战场中心以南 150 公里处，任务开始时所有无人机均从基地出发。

此外，仿真还考虑了开放战场动态环境特性，包括战场目标新增、目标被其它方式摧毁和无人机损失等情况，以模拟实际任务执行过程中的不确定性和突发状况。仿真平台还支持图形化输出，以直观展示目标分布、资源分配和打击次序等结果。特别是在目标分群部分，通过不同颜色和形状标记各类目标及其分群情况，并动态更新分群结果，便于观察模型在不同场景中的适应性。此外，在无人机打击序列的可视化方面，采用有

向箭头标注打击顺序，进一步提升仿真分析的清晰度。

5.1.2 总体仿真流程框架

仿真流程的设计以静态场景和动态场景为主线，涵盖目标初始分群、资源配置、打击次序决策以及任务执行过程中动态变化的实时调整和重新规划，通过 RF 算法、PSO 算法、近端策略优化以及 DQN 等方法适配结合形成自适应智能动态决策模型（Adaptive Intelligent Dynamic Decision Model, AID²M），具体流程及其关键步骤如图 5-1 所示。




图 5-1 仿真流程设计 1

在仿真开始阶段，对战场环境进行初始化，包括设定无人机数量、目标分布、目标特征以及任务类型等参数。这一阶段为后续无人机集群任务分配与决策提供基础数据支持。

在静态分配决策阶段，采用基于聚类算法的目标分群策略，通过 K-means 算法对目标进行初分类。分群依据目标的空间位置、类型及威胁程度等特征，将战场目标划分为多个相对集中的区域，每个区域中的目标数量保持相对均衡。随后根据分群结果，结合无人机集群的任务类型及资源特点（侦察、打击等），对无人机资源进行静态配置，以确保资源合理分布，满足不同目标区域的需求。在此基础上，通过 DQN 算法对打击次

序进行决策，输出具体的打击顺序，最终确定各无人机的任务执行路线和优先级。

任务开始执行后，仿真进入动态响应阶段。在这一阶段，无人机集群需要应对战场环境的实时变化，包括目标的新增和消失、无人机损毁等突发事件。当目标新增或消失时，系统通过 AID²M 进行在线决策，重新评估战场资源和目标分布，动态调整无人机资源配置和任务分配。例如，在目标新增场景中，系统会将新增目标纳入已有目标集中，并依据距离和优先级进行区域划分和资源调整。同时，基于 PPO 算法对新目标区域进行规划，确保决策的连续性和高效性。




图 5-2 仿真流程设计 2

当无人机集群到达战场执行任务过程中，集群内个体被摧毁时（包括攻击机和侦察机两类情况），仿真流程会触发 AID²M 框架的在线响应机制，实时评估作战资源的剩余情况。对于攻击机被摧毁的情况，系统会基于距离和任务完成率选择替代无人机支持，或者对资源进行重分配。此外，通过重新评估目标分布和资源情况，利用 DQN 算法优化打击次序决策，并通过 PPO 算法对区域目标进行重新划分。对于侦察机被摧毁的情况，仿真流程同样会调整任务分工，重新划定任务区域，并配置剩余无人机资源执行支援任务。

整体流程以动态调整和实时优化为核心，充分考虑战场环境的复杂性和多变性，确保无人机集群在面对突发情况时能够快速响应并保持任务执行的连续性和效率，形成了

一个完整的无人机集群对地目标自主决策仿真框架。后续章节将围绕该流程分别对静态场景和动态场景中的关键决策步骤进行仿真验证。

5.2 静态场景下的无人机集群对地目标决策仿真

明晰战场环境和目标信息后，需对目标和作战资源分别进行分析，涉及目标筛选与分群、资源配置以及打击次序优化等步骤。本节主要围绕静态场景下无人机集群对地目标决策仿真展开研究，旨在分析和验证无人机集群在预设战场环境中的任务规划与执行过程。

5.2.1 静态场景下的决策过程

根据仿真环境及总体仿真流程框架，在静态场景设定中，战场环境在任务开始前已经确定，目标位置、类型、防御值和重要性等特征已知，无人机集群的资源状态和数量固定不变。消除了动态因素的影响，使得决策过程可以专注于静态条件下的任务规划与优化。基于这一前提，仿真流程的具体实现如下：




图 5-3 静态场景下的决策流程

首先，通过随机森林算法筛选出需要优先摧毁的目标集。该决策依据目标的重要性、防御强度以及位置分布等因素进行权衡，并采用 PSO 算法对目标进行分析，以形成相对独立且紧凑的目标群。这种聚类方式有助于减少无人机任务分配中的复杂性，提高执行效率。对于分群过程，模型将目标的空间位置、类型和防御值作为输入特征，通过欧氏距离衡量目标间的相似性，从而生成不同的目标群。

在完成目标分群后，进入无人机集群资源配置阶段。资源配置模型充分考虑无人机平台的任务类型（侦察或打击）、武器负载以及航程等约束条件，通过优化算法合理分配无人机资源以覆盖所有目标群，以满足任务完成率阈值要求。在此过程中，模型约束确保每个目标群至少由一架侦察无人机负责，同时避免资源冗余或无人机跨越多个目标

群执行任务导致效率降低。

资源配置完成后,仿真进入打击次序决策环节。该阶段采用基于强化学习的决策优化策略,通过 DQN 算法对无人机任务执行顺序进行动态规划。决策模型的目标是最大化整体任务收益,同时最小化打击过程中的资源消耗。奖励函数设计充分考虑目标的重要性和防御值,并引入距离衰减机制,使远距离目标的打击顺序得以动态调整。此外,防御衰减机制的建模进一步提升了仿真合理性,当某些目标被摧毁后,其周边目标的防御值相应下降,有效降低后续打击的难度与资源需求。

上述流程形成了一个完整的无人机集群静态任务决策框架。从目标筛选、分群到资源配置与次序优化,各模块相互协作,确保无人机集群在已知条件下实现最优决策与任务分配。

5.2.2 仿真结果及分析

本节展示静态场景下无人机集群对地目标决策仿真的关键结果,并对各模块的性能与优化效果进行分析。通过可视化手段直观展示目标分群、资源配置以及打击次序决策的具体表现,从而验证模型的有效性与合理性。仿真采用如图 5-4 所示数据集,包含 200 个不同类型的战场目标。




图 5-4 战场目标一览图

将战场目标及其属性经数据预处理后输入到已经训练好的 RF 模型中,得到对于面向该战场目标的摧毁目标集结果,如图 5-5 所示,三维图中的红色菱形点代表摧毁目标,灰色方形点表示非摧毁目标,结果表明具有高综合价值的目标被纳入摧毁目标集。图 5-

6 展示了纳入摧毁目标集的目标详细信息，包括位置分布及目标类型属性。




图 5-5 RF 摧毁目标集决策结果




图 5-6 摧毁目标集结果平面图

得到摧毁目标集决策结果后，应用 PSO 算法进行目标分群，根据仿真参数设置以及无人机集群资源配置约束条件，作战资源中包括 8 架侦察无人机，因此目标集最大分群数为 8，结果如图 5-7 所示，不同颜色的标记表示被划分到不同群的目标，区域中心以黑色“×”标记。划分结果表明，PSO 算法成功将目标划分为多个紧凑区域，且相邻目标距离较近，为后续任务规划和执行提供了便利条件。




图 5-7 基于 PSO 算法的目标区域分群

之后进行无人机集群资源配置，在已有作战资源的基础上，合理配置每个集群的无人机数量，使其满足任务完成率阈值需求。为避免配置情况在图上显示重叠，选择各无人机集群从基地飞往各自任务目标 5min 后的各集群状态绘制，资源配置结果表明，无人机资源被合理分配到各目标群，满足任务需求的同时避免了资源浪费，配置结果图展示资源分布情况，不同颜色标记的无人机集群与目标群颜色对应关系一致。






图 5-8 无人机集群资源配置


对于打击次序决策模块，仿真结果显示基于 DQN 的优化策略成功规划了每个无人机集群对应的目标群打击路线与执行顺序，以下打击次序图详细展示各集群的打击路线，并在图中用箭头标记了打击顺序。




(a) 目标群 1 打击次序规划结果




(b) 目标群 2 打击次序规划结果




(c) 目标群 3 打击次序规划结果



(d) 目标群 4 打击次序规划结果



(e) 目标群 5 打击次序规划结果



(f) 目标群 6 打击次序规划结果




图 5-9 各目标群打击次序规划结果

综上所述,仿真结果充分验证了静态场景下无人机集群对地目标决策模型的可行性和优越性。无论是在摧毁目标集决策、目标分群、资源配置还是打击次序规划方面,模型均表现出较高的效率和适应性,为后续动态场景下的仿真研究提供了坚实基础。

5.3 动态场景下的无人机集群自主决策仿真

本节主要探讨动态变化场景下无人机集群自主决策的仿真过程与实现方法,研究如何在任务执行过程中应对目标新增、目标消失以及无人机资源损耗等动态变化因素,确保任务规划的连续性和决策结果的有效性。通过引入动态更新机制,本节分析无人机集群在面对突发情况时的适应性与响应能力,重点关注决策过程的灵活性和鲁棒性。

5.3.1 场景描述与动态变化设定

在仿真环境中,动态变化场景的设定是基于实际战场需求和复杂条件构建的。具体包括目标的新增与消失、无人机资源损耗以及战场态势的实时更新。这些变化模拟了无人机集群在执行任务过程中可能遇到的各种突发情况,例如新目标的出现需要迅速调整任务规划,而已分配目标的消失可能导致资源浪费或决策冲突。此外,无人机本身在执行任务过程中可能遭受损伤或失效,进一步加剧了决策过程的复杂性。针对以上几种典型场景,设定动态变化如下:

(1) 目标消失

模拟开放战场中的目标被其它方式摧毁、撤退或失去侦测信号导致的消失情况。目标消失可能出现在任务执行中任意时间点,要求系统更新目标集以避免资源浪费或重复打击,在仿真中将该动态事件放置在集群飞往战场途中的任一时刻点。消失目标的动态变化影响无人机资源配置及打击顺序,需要快速调整决策方案。

(2) 目标新增

模拟集群在任务执行过程中侦测到新的敌方目标,需将其纳入任务规划。新增目标出现的时间点随机分布或基于特定事件触发,例如任务执行中途通过侦察发现隐藏目标。

新增目标具有具体的位置信息、类型、防御值和重要性等属性，需要及时评估其优先级并调整任务分配。在仿真框架中将其置于无人机集群飞往战场途中的任一时刻点。

(3) 无人机资源损耗

模拟无人机在执行任务过程中被敌方防御摧毁或突发故障导致的性能下降或完全失效。对于执行任务中的集群而言，包括侦察机和攻击机分别被摧毁两类事件。损耗发生的时间点与任务执行相关联，例如长时间飞行或与高防御目标交战时资源损耗加剧。在仿真中，该事件置于各集群到达任务战场且执行任务过程中随机发生。

通过上述动态变化场景的设定与实时状态监测，模拟无人机集群在复杂环境中的实际作战能力，为后续仿真分析提供基础条件。

5.3.2 原有目标消失仿真结果及分析

根据目标消失动态事件设定顺序，基于静态决策结果继续仿真，模拟目标消失对无人机集群决策过程和执行效果的影响，并分析 AID^2M 在实际任务中的表现。重点展示目标消失后系统对任务状态的实时更新、资源重新分配及打击顺序调整的效果。无人机集群在飞往战场途中 t_1 时刻属于摧毁目标集的某随机目标（22 号、26 号、40 号）被其它方式摧毁，如图 5-10 所示。




图 5-10 摧毁目标集中随机目标消失

由于目标集内的目标消失造成资源冗余，根据目前各无人机集群现有资源配置情况计算各集群的任务完成率，添加 RF 决策中的综合价值次优的目标以最大化资源利用率，

避免无人机集群资源的浪费, 并利用 PPO 进行目标区域划分, 得到新的目标分群结果如图 5-11 所示。






图 5-11 基于 PPO 对更新目标集分群

对于新分群后的各目标群, 与静态决策的结果不同, 需要重新决策。将每个目标群的目标分布位置及其属性输入已训练好的 DQN 网络, 仿真结果显示优化策略成功规划了每个无人机集群对应的目标群打击路线与执行顺序, 以下打击次序图详细展示各集群的打击路线, 并在图中用箭头标记了打击顺序。




(a) 目标群 1 打击次序规划结果


(b) 目标群 2 打击次序规划结果




(c) 目标群 3 打击次序规划结果




(d) 目标群 4 打击次序规划结果




(e) 目标群 5 打击次序规划结果



(f) 目标群 6 打击次序规划结果



(g) 目标群 7 打击次序规划结果



(h) 目标群 8 打击次序规划结果

图 5-12 重规划后的目标群打击次序规划结果

5.3.3 新增目标出现仿真结果及分析

在前述目标消失仿真结果的基础上, 进一步模拟新增目标对无人机集群自主决策过程的影响, 并分析 AID^2M 对任务规划与资源配置的实时调整能力。重点展示目标新增后的任务状态更新、资源分配变化和打击顺序重构效果。

新增目标仿真以 5.3.2 原有目标消失仿真结果及分析节中动态调整后的状态作为初始条件,即目标消失后的任务规划已经完成,所有无人机资源处于执行任务状态。此时,无人机集群已根据剩余目标完成打击路径次序规划。无人机集群在继续飞往任务区域的 t_2 时刻战场随机出现新目标若干(201 号, 202 号), 如图 5-13 所示。




图 5-13 开放战场中新增随机目标

针对战场中新增目标的出现,首先通过随机森林算法对新增目标是否纳入摧毁目标集进行预测分析。将新增目标的属性特征输入训练好的 RF 模型进行分类预测,根据预测结果,筛选满足重要性和防御条件的新增目标纳入摧毁目标集,更新目标集并可视化结果,如图 5-14 所示。新增目标预测分析及纳入摧毁目标集示意图显示了新增目标的分布与预测结果,红色虚线框标记表示被 RF 模型识别为高优先级且纳入摧毁目标集的目标。

在确定新增目标纳入摧毁目标集后,基于近端策略优化对更新后的目标集进行分群处理。利用 PPO 算法,根据无人机资源状态和目标分布特征,将目标集划分为与侦察机数量匹配的 8 个目标群,以便执行进一步的打击规划。将更新后的目标集输入模型,PP O 算法根据群聚中心和无人机数量约束条件动态划分目标群,新的目标群划分结果如图 5-15 所示。新增目标分群结果图展示了目标群划分情况,各子群以不同颜色标记,不同形状表示不同类型的目标,被纳入摧毁集的新增目标被合理分配到各个子群,分群结构保持均衡,无明显任务遗漏,分群结果验证了 PPO 算法在复杂动态环境中的适应性和有效性。




图 5-14 新增随机目标经 RF 决策后纳入目标集




图 5-15 新增目标后的群划分结果

针对更新后的目标群，进一步计算其任务完成率，以验证任务分配和资源配置的合理性。设定任务完成率阈值为 79%，若低于此值，则触发资源配置调整机制；若满足要

求, 则资源配置不变。计算与新增目标所在的群匹配的无人机集群任务完成率分别为 82.6%和 80.7%, 满足阈值需求, 无需重新调整资源配置。新增目标的引入未对整体任务执行效率造成显著影响, 进一步验证了分群策略与资源分配模型的鲁棒性。

在分群与资源配置稳定后, 将重划分后的目标群输入训练好的深度 Q 网络模型, 进行各群内打击次序优化。DQN 模型通过学习目标特征和资源状态信息, 输出最优打击顺序, 最大化任务收益。由于新增目标影响的分群只有两个, 故输出这些目标群的打击次序规划结果即可, 如图 5-16 所示。




图 5-16 新增目标的目标群打击次序规划结果

通过新增目标仿真分析了无人机集群在动态变化环境下的任务调整能力, 并验证了 RF、PPO 和 DQN 模型的有效性。RF 模型能够准确筛选新增目标并更新摧毁目标集, 为后续任务规划提供基础支持。PPO 算法动态调整目标分群, 确保任务分配均衡, 资源利用率达到最佳状态。DQN 模型优化打击次序规划, 提高了任务收益和执行效率, 表现出较高的动态调整能力。

5.3.4 无人机资源损失仿真结果及分析

处理完集群在飞行过程中的动态变化后, 针对无人机集群在任务执行过程中可能遭遇的资源损失动态事件, 分析无人机资源损失对任务规划及资源配置的影响。主要讨论集群内攻击无人机与侦察无人机分别被摧毁时的动态决策流程, 并基于总体仿真流程框架详细展示仿真结果及分析。

在任务执行过程中, 某个无人机集群中的攻击无人机由于敌方防御火力或系统故障被摧毁, 导致集群的打击能力受损。为了维持任务的连续性和完成率, 需要动态调整资源配置并生成新的决策方案。本流程基于动态支援机制, 通过实时态势评估和动态规划实现无人机集群的任务恢复, 具体流程如图 5-17 所示。

系统实时检测集群内攻击无人机的损失情况, 并更新战场态势信息, 根据当前集群剩余攻击无人机数量和打击任务需求, 判断是否能够继续执行任务。如果剩余资源足够,

则直接执行原有任务规划，无需调整。若进攻资源不足，系统将进一步评估其他集群内的剩余攻击资源，判断是否能够提供支援。若其他集群存在冗余资源，启动动态支援机制，通过动态支援机制将冗余资源分配至受损集群，确保任务完成率最大化；若无冗余资源，则直接保留原有决策结果，并提示任务可能无法按计划完成。下文将结合具体仿真场景与数据，分析攻击无人机被摧毁后的动态响应效果及支援机制的实际表现。




图 5-17 集群内攻击无人机被摧毁的决策流程

无人机集群到达任务战场区域，并开始执行既定的打击任务。任务目标及优先级分配沿用 5.3.3 的规划结果，保持目标分群及打击次序不变。在仿真过程中，某集群在执行任务的初始阶段，1 架攻击无人机遭受敌方防御火力打击损毁，如图 5-18 所示。




图 5-18 集群内攻击机被摧毁示意图

损毁事件发生后，系统首先对受损集群剩余资源进行快速评估，判断其是否能够独立完成后续任务。在发现资源不足后，动态决策模块计算其他集群的冗余资源情况，并评估支援可行性。仿真结果表明，邻近绿色集群作战资源富余，可提供支援。因此，系统触发动态支援机制，并重新调整集群网络资源分配，调整后的无人机集群配置如图 5-19 所示。




图 5-19 受损无人机集群得到邻近支援

支援资源成功到位后，受损集群恢复最低打击能力，能够继续执行任务目标的打击规划。仿真结果表明，该机制有效降低了因资源损毁导致任务失败的风险，并确保任务进度不受显著影响。

仿真过程中，系统检测到攻击无人机损毁后，完成资源评估和动态支援分配的平均时间为 4.5 秒。这一结果验证了动态决策模块的高效性，能够满足战场实时性需求。在支援资源投入后，受损集群恢复任务完成率达到 83.5%（相较于支援前仅剩 72.1%）。这一恢复率表明支援机制能够显著缓解资源损失带来的性能下降。仿真结果表明，该机制具有较强的实时性与鲁棒性，能够有效应对无人机资源损失带来的任务中断风险。此外，该机制确保任务分群及打击顺序不变，提高了无人机集群的协同作战能力。

随着无人机集群任务继续执行，某集群内的侦察无人机被摧毁，导致目标探测和分群能力受损。为了维持任务的连续性和完成率，需要动态调整资源配置并生成新的决策方案。本流程基于动态支援机制，通过实时态势评估和动态规划实现无人机集群的任务恢复，具体流程如图 5-20 所示。




图 5-20 集群内侦察无人机被摧毁的决策流程

系统实时检测集群内侦察无人机的损失情况，并更新战场态势信息，根据无人机集群配置原则要求，损毁侦察无人机的集群无法继续执行任务，触发支援机制。由于摧毁目标集的划分与作战资源中的侦察机数量相匹配，故需要重新划分目标群，确保分群数量与侦察机数量匹配。侦察机的损失意味着目标分群数的减少，在目标总量不变的前提下每个目标群的目标数量增多，这对之前的无人机集群资源配置提出了挑战。为了满足任务完成率阈值要求，调配受损无人机集群内的攻击机支援其他无人机集群，以应对增加的任务量。此外，伴随着目标分群的调整，各分群内的目标打击次序也需要重新规划，确保任务实施的连续性与高效性。下文将结合具体仿真场景与数据，分析侦察无人机被摧毁后的动态响应效果及支援机制的实际表现。

依据总体仿真流程框架，无人机集群已进入任务战场区域，并根据 5.3.3 的规划结果执行打击任务。任务执行过程中，某集群内的侦察无人机（5 号、9 号）遭到敌方防御火力打击而被摧毁，导致其目标侦察与定位能力受损，如图 5-21 所示。该损毁直接破坏集群资源配置原则，必须通过动态支援机制进行调整，以确保任务连续性和完成率。

此外，由于受损集群侦察机数量不足，无法维持当前目标分群数量，因此需要对目标集重新分群，使分群数量与现有侦察机数量匹配。利用 PPO 进行目标区域划分，得到新的目标分群结果如图 5-22 所示。调整后的目标分群重新输入打击规划模块，并用于后续的任务调配与分配。

在重新分群后，为保障各集群的任务完成率达到设定阈值（79%），系统进一步分析受损集群打击资源情况，计算剩余攻击无人机可支援其他集群的数量，优先将作战资

源调配到任务完成率低于阈值的集群，提升其打击能力。经支援策略计算后形成调配方案，如图 5-23 所示。




图 5-21 无人机集群内的侦察无人机被摧毁




图 5-22 目标划集划分与侦察机匹配的数量




图 5-23 应用支援机制形成调配方案

按照资源调配方案，新集群形成后，继续执行分群目标的打击任务，保障任务执行连贯性，如图 5-24 所示。




图 5-24 动态响应支援方案后的无人机集群

对于新分群后的各目标群，与沿用的决策结果不同，需要重新规划打击次序。将每个目标群的目标分布位置及其属性输入已训练好的 DQN 网络，仿真结果显示优化策略成功规划了每个无人机集群对应的目标群打击路线与执行顺序，以下打击次序图详细展示各集群的打击路线，并在图中用箭头标记了打击顺序。




图 5-25 重分群后的打击次序规划结果

表 5-2 总结了无人机集群在静态场景和动态场景下执行任务的关键性能指标统计结果，包括每个子群的任务量标准差、每个子群中心与目标距离和的均值，以及任务完成率的均值。该表旨在对比分析两类场景下无人机集群在任务分配均衡性、目标打击效率和整体任务完成效果方面的表现差异。其中，任务量以该群内目标的价值与防御度的比值衡量，其标准差反映了各子群之间任务分配的均衡性，子群中心与目标距离和的均值评估了子群划分的紧凑程度，而任务完成率均值则衡量了集群在不同场景下的整体作战效果。

表 5-2 不同场景执行任务的关键性能指标统计结果

场景类型	目标集数量	子群任务量标准差	子群中心与目标距离和均值	任务完成率均值
静态场景	62	4.62	4737.1	72.1%
动态场景	64	1.43	3859.6	83.5%

相较于静态场景，AID²M 模型不仅可以处理新增目标等动态事件，且其性能也有所提升。子群的任务量标准差减少到 1.43，有效减少了个别子群目标众多的情况，且子群中心与各目标的距离和的均值从 4737.1 米降低到 3859.6 米，反映出各群内目标分布更紧凑。加入支援机制后集群内攻击无人机被摧毁后的任务完成率提高了 11.4%。通过对这些关键指标的统计分析，可进一步验证本文提出的自主决策模型在动态变化环境中的适应性和鲁棒性。

5.4 本章小结

本章为了验证 AID²M 的自主决策能力，构建了高效的仿真环境，并模拟静态和动态场景以验证决策模型的有效性。针对目标动态变化及无人机资源损毁等典型场景，设计动态响应流程，包括更新战场态势、资源重新评估与分配以及打击次序调整等关键机制，确保无人机集群在面对突发事件和环境变化时能够快速适应、动态调整任务规划，并保持高效的任务执行能力和决策鲁棒性。

联合仿真结果表明，AID²M 在线决策模型在开放战场高动态环境下，可针对战场中目标被其它方式摧毁、出现其它新目标以及在任务执行过程中集群内不同类型的作战资源被敌方防御摧毁等典型动态场景下能够有效应对突发事件，验证了系统的自适应调整能力。相较于静态场景下的决策结果，AID²M 在线决策模型得到的结果中每个子群的任务量均衡性及分布紧凑型方面具有显著优势，任务量标准差降低了 3.19，子群簇中心与各目标的平均距离之和减少了 877.5 米，有效缓解了部分集群过高任务量的情况。动态支援机制使任务完成率提升了 11.4%，充分证明了动态调整机制的适应性和鲁棒性。综上，本章构建的自主决策仿真框架为复杂战场环境下无人机集群任务规划与优化提供了技术参考。

第6章 全文总结与展望

6.1 全文总结

无人机集群对地打击任务级决策涉及数学、控制及计算机等多领域学科交叉，需要进行系统分析。本文围绕基于强化学习的无人机集群对地打击自主决策方法展开研究，针对动态战场环境中的目标优先级评估、任务分配与自适应打击次序优化问题，提出了基于随机森林、近端策略优化和深度 Q 网络相结合的建模与算法设计方案，并通过仿真环境进行验证，旨在提升无人机集群在复杂环境中的自主决策能力和任务执行效率。主要研究工作如下：

(1) 聚焦动态战场中的目标摧毁决策与区域目标分配问题，提出了基于随机森林的目标筛选模型和基于粒子群优化的目标分群规划方法，确保了高价值目标优先纳入摧毁目标集。进一步在强化学习框架中结合近端策略优化算法，针对动态场景中目标变化与任务需求调整，实现分群紧凑性与均衡性优化。仿真结果表明，该方法在动态场景中分群性能优于传统方法，提高了任务分配的适应性和鲁棒性。

(2) 针对高动态战场环境中的无人机资源协调与打击次序优化问题，提出了基于深度强化学习的打击次序规划与动态支援机制。设计了任务完成率评估指标和启发式动态调整算法，有效解决了突发情况下无人机资源损耗与任务重规划的难题。仿真结果表明，该方法通过引入注意力机制优化 DQN 算法，提高了路径执行效率和目标优先级决策效果，同时结合动态支援机制，在攻击无人机和侦察无人机损毁场景下，任务完成率分别提升了 18.5% 和 20.4%，验证了模型的高效性与适应性。

(3) 构建了无人机集群自主决策仿真环境，分别在静态和动态场景下验证了决策方法的有效性。通过集成 RF、PSO、PPO 和 DQN 等算法，形成 AID²M 在线决策模型，实现动态事件下的任务自适应调整与优化。仿真结果表明，相较于静态传统决策方法，动态决策模型显著降低任务量标准差（减少 3.19）、子群中心与目标距离和（减少 877.5 米），任务完成率提高 11.4%。验证了该方法在动态环境中的实时响应能力、任务适应性与鲁棒性。

在以上研究内容的基础上，本文的主要创新点如下：

(1) 引入注意力机制优化 DQN 算法，使其能够有效捕捉任务关键要素，增强模型对重要目标的关注度，同时，该改进加速了模型的收敛速度，提升了决策精度与执行效率，为无人机集群智能决策提供了更加稳定和高效的算法支持。

(2) 针对动态环境中目标状态变化和无人机资源损耗问题，设计了自适应动态响应机制与支援策略。该机制显著增强了集群在突发事件中的鲁棒性与灵活性，使无人机集群具备快速响应和重规划能力，满足高动态战场条件下的决策需求。

(3) 本文创新性地将随机森林算法、PSO、近端策略优化和 DQN 相结合, 充分利用不同算法在任务决策流程中的优势, 提出自适应智能动态决策模型 (AID²M), 实现从静态规划到动态调整的过渡衔接, 有效提升了无人机集群在复杂战场环境中自主任务决策能力。

6.2 后续工作展望

本文在无人机集群对地目标自主决策方面取得了一定成果, 但仍存在进一步优化与扩展的空间。结合当前研究的局限性与未来发展需求, 后续工作可围绕以下两个方面展开:

(1) 提升无人机集群的编队控制精度与动态行为建模。本文研究中将无人机集群抽象为质点模型, 以简化系统复杂性和算法设计, 但这一假设在实际应用场景中存在一定局限性, 难以真实反映无人机集群的编队控制与机动特性。因此, 未来研究可进一步引入动力学模型和编队控制算法, 构建更精细的无人机个体及集群行为仿真框架。重点关注无人机个体的动态约束、航迹规划和编队保持等控制策略, 实现对无人机集群在复杂环境下的真实机动建模与动态协同控制。

(2) 开发可视化的仿真平台与交互式操作系统。本文研究基于编程环境构建仿真平台, 对无人机集群决策过程进行了验证, 但缺乏可视化的用户操作界面, 限制了研究成果的直观呈现与操作便利性。未来可进一步开发集成式软件平台, 搭建具备图形化交互界面的仿真系统, 以支持用户对无人机集群任务规划、目标选择和路径优化等功能的动态调整。该平台应具备任务设置、动态事件插入与结果可视化分析等模块, 并支持参数配置与算法扩展, 以满足实际工程应用需求。

未来研究将在更加真实的集群行为建模与交互式仿真平台搭建方面持续优化, 进一步推动无人机集群自主决策技术从理论研究向工程应用转化, 为无人集群智能作战系统的发展提供更加完善的解决方案和技术保障。

参考文献

- [1] 张旭东, 李少波, 李传江等. 无人机集群综述:技术、挑战与未来[J]. 无线电工程, 2023, 53(7): 1487-1501.
- [2] Wen W, Shi C, Zhou J. Stealthy Trajectories Planning Algorithm for UAV Cluster in Multivariate Threat Environment[C]. 2024 7th International Conference on Electronics Technology (ICET), 2024: 624-629.
- [3] 张鹏飞, 何印, 马振华等. 无人机集群协同控制技术综述[J]. 兵器装备工程学报, 2024, 45(4): 1-9.
- [4] Zhao J, Hu X, Qian H, Guo W. Force Demand Planning of UAV Cluster Adversarial via Hybrid Group Swarm Optimization[C]. 2024 7th International Conference on Advanced Algorithms and Control Engineering, 2024: 1479-1484.
- [5] 安蕾. 面向异构目标的无人机集群任务分配技术研究[D]. 南京信息工程大学, 2023.
- [6] 李晗, 苏京昭, 闫咏. 智能无人机集群技术概述[J]. 科技视界, 2017(26): 10-12.
- [7] 林晨. 面向无人机集群任务分配的分布式算法研究[J]. 电子科技大学, 2019(01).
- [8] 刘钢, 汤俊, 刘陈等. 无人飞行器集群协同行为建模技术综述[J]. 系统工程与电子技术, 2021, 43(8): 2221-2231.
- [9] 马建平. 无人机协同作战及其战场态势可视化[D]. 西安电子科技大学, 2021.
- [10] Karas R S. General Atomics, Dynetics outline Gremlins approaches as phase two begins[J]. Inside the Air Force, 2017, 28(12): 1-7.
- [11] 刘箴, 吴馨远, 许洁心. 无人机集群作战系统的新发展及趋势分析[J]. 弹箭与制导学报, 2022(06): 40-53.
- [12] Puente Castro Alejandro, Rivero Daniel, Pazos Alejandro, Fernandez Blanco Enrique. UAV swarm path planning with reinforcement learning for field prospecting[J]. Applied Intelligence, 2022(12): 1-18.
- [13] Moseley M B, Grocholsky B P, Cheung C, et al. Integrated long-range UAV/UGV collaborative target tracking[C]. Unmanned Systems Technology XI. 2009, 7332: 733204.
- [14] Zhao Y, Wang X, Wang C, et al. Systemic design of distributed multi-UAV cooperative decision-making for multi-target tracking[J]. Autonomous Agents and Multi-Agent Systems, 2019, 33(1): 132-158.
- [15] Gu J, Su T, Wang Q, et al. Multiple moving targets surveillance based on a cooperative network for multi-UAV[J]. IEEE Communications Magazine, 2018, 56(4): 82-89.
- [16] Xia C, Yongtai L, Liyuan Y, et al. Cooperative task assignment and track planning for Multi-UAV attack mobile targets[J]. Journal of Intelligent & Robotic Systems, 2020,

- 100(3): 1383-1400.
- [17] Wang D, Peng Z, Ju X, et al. Multi-UAV cooperative target tracking strategy based on formation control[C]. Chinese Control Conference. 2019: 6224-6229.
- [18] Zhou R, Feng Y, Di B, et al. Multi-UAV cooperative target tracking with bounded noise for connectivity preservation[J]. Frontiers of Information Technology & Electronic Engineering, 2020, 21(10): 1494-1503.
- [19] Yao P, Wang H, Ji H. Multi-UAVs tracking target in urban environment by model predictive control and Improved Grey Wolf Optimizer[J]. Aerospace Science and Technology, 2016, 55: 131-143.
- [20] Li P, Duan H. A potential game approach to multiple UAV cooperative search and surveillance[J]. Aerospace Science and Technology, 2017, 68: 403-415.
- [21] Ni J, Tang G, Mo Z, et al. An improved potential game theory based method for multi-UAV cooperative search[J]. IEEE Access, 2020, 8: 47787-47796.
- [22] Liu Y, Luo Z, Liu Z, et al. Cooperative routing problem for ground vehicle and unmanned aerial vehicle: The application on intelligence, surveillance, and reconnaissance missions[J]. IEEE Access, 2019, 7: 63504-63518.
- [23] Yang F, Ji X, Yang C, et al. Cooperative search of UAV swarm based on improved ant colony algorithm in uncertain environment[C]. International Conference on Unmanned Systems. 2017: 231-236.
- [24] Duan H, Zhao J, Deng Y, et al. Dynamic discrete pigeon-inspired optimization for Multi-UAV cooperative search-attack mission planning[J]. IEEE Transactions on Aerospace and Electronic Systems, 2020, 57: 706-720.
- [25] Sauter J A, Bixler K. Design of unmanned swarm tactics for an urban mission[C]. Unmanned Systems Technology XXI. 2019, 11021: 110210K.
- [26] Collier J. Unmanned systems technologies in contested urban environments[C]. Unmanned Systems Technology XXI. 2019, 11021: 1102105.
- [27] Puente-Castro A, Rivero D, Pazos A, et al. UAV swarm path planning with reinforcement learning for field prospecting[J]. Applied Intelligence, 2022, 52(12): 14101-14118.
- [28] 王志宏, 冷甦鹏, 熊凯. 面向无人机集群协同感知的多智能体资源分配策略[J]. 物联网学报, 2023, 7(01): 18-26.
- [29] Wu H, Peng Q, Shi M, et al. A survey of UAV swarm task allocation based on the perspective of coalition formation[J]. International Journal of Swarm Intelligence Research (IJSIR), 2022, 13(1): 1-22.
- [30] 赵林, 张宇飞, 姚明昨等. 无人机集群协同技术发展展望[J]. 无线电工程, 2021,

- 51(8): 823-828.
- [31] Huo Y, Fan J, Wen Y, et al. A cross-layer cooperative jamming scheme for social internet of things[J]. Tsinghua Science and Technology, 2021, 26(4): 523-535.
- [32] Kang R, Li H, Li W, et al. A novel PSO approach for cooperative task assignment of multi-UAV attacking moving targets[C]. 2022 34th Chinese Control and Decision Conference (CCDC). IEEE, 2022: 3670-3675.
- [33] Ravindran K. Task allocation and scheduling of concurrent applications to multiprocessor systems[M]. University of California, Berkeley, 2008.
- [34] 赵雪森, 王社伟. 基于改进量子粒子群优化算法的多UCAV协同任务分配研究[J]. 四川兵工学报, 2015, 36(10): 120-124.
- [35] 王树朋, 徐旺, 刘湘德等. 基于自适应遗传算法的多无人机协同任务分配[J]. 电子信息对抗技术, 2021, 36(1): 59-64.
- [36] Peng Q, Wu H, Xue R. Review of dynamic task allocation methods for UAV swarms oriented to ground targets[J]. Complex System Modeling and Simulation, 2021, 1(3): 163-175.
- [37] 李丽. 多无人机协同任务分配算法研究[D]. 南京航空航天大学, 2021.
- [38] Ismail S, Sun L. Decentralized hungarian-based approach for fast and scalable task allocation[C]. 2017 International Conference on Unmanned Aircraft Systems (ICUAS). IEEE, 2017: 23-28.
- [39] 潘楠, 刘海石, 陈启用等. 多基地多目标无人机协同任务规划算法研究[J]. 现代防御技术, 2021, 49(2): 49-56.
- [40] Duan X, Liu H, Tang H, et al. A novel hybrid auction algorithm for multi-UAVs dynamic task assignment[J]. IEEE access, 2019, 8: 86207-86222.
- [41] 冉华明. 基于两步分布协同拍卖的多机协同任务分配[J]. 电讯技术, 2020, 60(02):181-188.
- [42] Xing N, Zong Q, Dou L, et al. A game theoretic approach for mobility prediction clustering in unmanned aerial vehicle networks[J]. IEEE Transactions on Vehicular Technology, 2019, 68(10): 9963-9973.
- [43] Chen J, Wu Q, Xu Y, et al. Joint task assignment and spectrum allocation in heterogeneous UAV communication networks: A coalition formation game-theoretic approach[J]. IEEE Transactions on Wireless Communications, 2020, 20(1): 440-452.
- [44] Mittal V, Maghsudi S, Hossain E. Distributed cooperation under uncertainty in drone-based wireless networks: A Bayesian coalitional game[J]. IEEE Transactions on Mobile Computing, 2021, 22(1): 206-221.

- [45] 陈侠, 刘敏, 胡永新. 基于不确定信息的无人机攻防博弈策略研究[J]. 兵工学报, 2012, 33(12): 1510-1515.
- [46] Lukeman R, Li Y X, Edelstein-Keshet L. Inferring individual rules from collective behavior[J]. Proceedings of the National Academy of Sciences of the United States of America, 2010, 107(28): 12576-12580.
- [47] Leibo J Z, Zambaldi V, Lanctot M. Multi-Agent reinforcement learning in sequential social dilemmas[J]. preprint arXiv: 1702.03037v1, 2017.
- [48] Ryan L, Wu Y, Aviv T. Multi-Agent Actor-Critic for mixed cooperative-competitive environments[J]. preprint arXiv:1706.02275v3, 2018.
- [49] Zheng L M, Yang J C, Cai H. Magent: a many-agent reinforcement learning platform for artificial collective intelligence[J]. preprint arXiv:1712.00600v1, 2017.
- [50] Liu M, Chen Y. Safety-Guaranteed Learning-Based Flocking Control Design[J]. IEEE Control Systems Letters, 2024, 8: 19-24.
- [51] Reynolds C W. Flocks, herds and schools: A distributed behavioral model[J]. ACM SIGGRAPH Computer Graphics, 1987, 21(4): 25-34.
- [52] Xiao J, Yuan G, He J, et al. Graph attention mechanism based reinforcement learning for multi-agent flocking control in communication-restricted environment[J]. Information Sciences, 2023, 620: 142-157.
- [53] Xiao J, Yuan G, Wang Z. A multi-agent flocking collaborative control method for stochastic dynamic environment via graph attention autoencoder based reinforcement learning[J]. Neurocomputing, 2023, 549: 126379.
- [54] Wang C, Yan C, Xiang X, et al. A Continuous Actor-Critic Reinforcement Learning Approach to Flocking with Fixed-Wing UAVs[C]. Proceedings of The Eleventh Asian Conference on Machine Learning. PMLR, 2019: 64-79.
- [55] Wang C, Wu L, Yan C, et al. Coactive design of explainable agent-based task planning and deep reinforcement learning for human-UAVs teamwork[J]. Chinese Journal of Aeronautics, 2020, 33(11): 2930-2945.
- [56] Yan C, Xiang X, Wang C. Fixed-Wing UAVs flocking in continuous spaces: A deep reinforcement learning approach[J]. Robotics and Autonomous Systems, 2020, 131: 103594.
- [57] Yan C, Xiang X, Wang C, et al. Flocking and Collision Avoidance for a Dynamic Squad of Fixed-Wing UAVs Using Deep Reinforcement Learning[C]. 2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Prague, Czech Republic: IEEE, 2021: 4738-4744.

- [58] Yan C, Wang C, Xiang X, et al. Deep Reinforcement Learning of Collision-Free Flocking Policies for Multiple Fixed-Wing UAVs Using Local Situation Maps[J]. IEEE Transactions on Industrial Informatics, 2022, 18(2): 1260-1270.
- [59] Yan C, Xiang X, Wang C, et al. PASCAL: PopulAtion-Specific Curriculum-based MADRL for collision-free flocking with large-scale fixed-wing UAV swarms[J]. Aerospace Science and Technology, 2023, 133: 108091.
- [60] Wang W, Wang L, Wu J, et al. Oracle-Guided Deep Reinforcement Learning for Large-Scale Multi-UAVs Flocking and Navigation[J]. IEEE Transactions on Vehicular Technology, 2022, 71(10): 10280-10292.
- [61] Bai C, Yan P, Piao H, et al. Learning-Based Multi-UAV Flocking Control With Limited Visual Field and Instinctive Repulsion[J]. IEEE Transactions on Cybernetics, 2024, 54(1): 462-475.
- [62] Zhu P, Dai W, Yao W, et al. Multi-Robot Flocking Control Based on Deep Reinforcement Learning[J]. IEEE Access, 2020, 8: 150397-150406.
- [63] Meng L, Cheng J, Zhang H, et al. Deep Reinforcement Learning Approach for Flocking Control Problem of Multi-Agents in Obstruction Environment[C]. 2023 42nd Chinese Control Conference (CCC). 2023: 1-6.
- [64] 刘志飞, 曹雷, 赖俊等. 多智能体路径规划综述[J]. 计算机工程与应用, 2022, 58(20): 43-62.
- [65] Ramírez J, Yu W, Perrusquía A. Model-free reinforcement learning from expert demonstrations: a survey[J]. Artificial Intelligence Review, 2022, 55(4): 3213-3241.
- [66] Wang J, Zhang P, Wang Y. Autonomous target tracking of multi-UAV: A two-stage deep reinforcement learning approach with expert experience[J]. Applied Soft Computing, 2023, 145: 110604.
- [67] Wan K, Wu D, Li B, et al. ME-MADDPG: An efficient learning-based motion planning method for multiple agents in complex environments[J]. International Journal of Intelligent Systems, 2022, 37(3): 2393-2427.
- [68] Hu Z, Wan K, Gao X, et al. Deep Reinforcement Learning Approach with Multiple Experience Pools for UAV's Autonomous Motion Planning in Complex Unknown Environments[J]. Sensors, 2020, 20(7): 1890.
- [69] Pfeiffer M, Shukla S, Turchetta M, et al. Reinforced Imitation: Sample Efficient Deep Reinforcement Learning for Mapless Navigation by Leveraging Prior Demonstrations[J]. IEEE Robotics and Automation Letters, 2018, 3(4): 4423-4430.
- [70] Liu Y, Gao P, Zheng C, et al. A Deep Reinforcement Learning Strategy Combining Expert

- Experience Guidance for a Fruit-Picking Manipulator[J]. Electronics, 2022, 11(3): 311.
- [71] 赵国权. 基于分层强化学习的机械臂路径规划研究[D]. 东华大学, 2023.
- [72] 程先峰, 严勇杰. 基于 MAXQ 分层强化学习的有人机/无人机协同路径规划研究[J]. 信息化研究, 2020, 46(1): 13-19.
- [73] Le H, Jiang N, Agarwal A, et al. Hierarchical Imitation and Reinforcement Learning[C]. Proceedings of the 35th International Conference on Machine Learning. PMLR, 2018: 2917-2926.
- [74] Yang L, Yao H, Wang J, et al. Multi-UAV-enabled load-balance mobile-edge computing for IoT networks[J]. IEEE Internet of Things Journal, 2020, 7(8): 6898-6908.
- [75] 唐峯竹, 唐欣, 李春海等. 基于深度强化学习的多无人机任务动态分配[J]. 广西师范大学学报 (自然科学版), 2021, 39(06): 63-71.
- [76] Chen J, Cao X, Yang P, et al. Deep reinforcement learning based resource allocation in multi-UAV-aided MEC networks[J]. IEEE Transactions on Communications, 2023, 71: 296-309.
- [77] Afghah F, Zaeri-Amirani M, Razi A, et al. A coalition formation approach to coordinated task allocation in heterogeneous UAV networks[C]. 2018 Annual American Control Conference (ACC). IEEE, 2018: 5968-5975.
- [78] 陈璞, 严飞, 刘钊等. 通信约束下异构多无人机任务分配方法[J]. 航空学报, 2021, 42(08): 313-326.
- [79] Liu D, Dou L, Zhang R, et al. Multi-agent reinforcement learning-based coordinated dynamic task allocation for heterogeneous UAVs[J]. IEEE Transactions on Vehicular Technology, 2022.
- [80] Qi N, Huang Z, Zhou F, et al. A task-driven sequential overlapping coalition formation game for resource allocation in heterogeneous uav networks[J]. IEEE Transactions on Mobile Computing, 2022.
- [81] 宋佰霖, 许华, 齐子森等. 一种基于深度强化学习的协同通信干扰决策算法[J]. 电子学报, 2022, 50(6): 1301-1309.
- [82] Lizhi, Wang, Dawei, et al. A Complex Network Theory-Based Modeling Framework for Unmanned Aerial Vehicle Swarms.[J]. Sensors, 2018.
- [83] Wang L, Zhao X, Zhang Y, et al. Unmanned aerial vehicle swarm mission reliability modeling and evaluation method oriented to systematic and networked mission[J]. Chinese Journal of Aeronautics, 2020.
- [84] Xw A, Yuan Z A, Lwb C, et al. Robustness evaluation method for unmanned aerial vehicle swarms based on complex network theory-ScienceDirect[J]. Chinese Journal of

- Aeronautics, 2020, 33(1): 352-364.
- [85] 刘媛媛, 袁荣, 邵书义等. 改进鸽群优化的随机森林无人机故障预测技术[J/OL]. 现代防御技术, 1-10.
- [86] 薛永生, 吴立尧. 基于模拟退火的改进粒子群算法研究及应用[J]. 海军航空工程学院学报, 2018, 33(02): 248-252.
- [87] Schulman J, Wolski F, Dhariwal P, et al. Proximal Policy Optimization Algorithms[J]. 2017. arXiv.1707.06347.
- [88] 王一峰, 彭一明, 李龙等. 基于 DQN 的无人机主动捕捉拦阻回收方法研究[J/OL]. 航空学报, 1-13
- [89] Schaul T, Quan J, Antonoglou I, et al. Prioritized Experience Replay[C]. ICLR. 2016.

致 谢

在学期间发表的学术成果和参加科研情况

发表论文情况：

- [1] XXX, XXX, XXX, et al. Impact Time and Angle Cooperative Guidance for Multiple Unmanned Air Vehicles (UAVs) with Coupled Dynamics Among Velocity and Normal Accelerations[C]. International Conference on Autonomous Unmanned Systems (ICAUS). 2023:1916-1930. （第一作者，EI 检索）
- [2] XXX, XXX, XXX 等. 一种带高度控制的飞行器再入航迹规划控制方法[P].陕西省：CN202410524478.8. 2024-08-27. （第二作者，已公开，未授权）

参与科研情况：

- 1. 云控 XXXX 总体设计，纵向课题，2022-2024，XXXXXX；
- 2. 面向 KZ 编队智能决策的 ZS 机动策略自动生成技术研究，横向课题，2022-2023，中电XX所；
- 3. 无人机集群高动态对抗下的多任务规划决策技术，横向课题，2023-2024，XXXXXX 实验室。